



Universidad Nacional Autónoma de
México

Facultad de Ciencias



Almacenes y Minería de Datos
Semestre 2026-2

Proyecto final

Reporte formal

Profesora:	Jessica Santizo Galicia
Ayudante:	Diego Antonio Villalba González
Ayud. Lab.:	Ares Gael Castro Romero

Alumnos

Omar Fernando Gramer Muñoz
Kevin Steve Quezada Ordoñez
Jesús Antonio Romero Godoy
Edgar Salgado González

Junio de 2026

1. Introducción

Para el desarrollo del proyecto se seleccionó el dataset `atus_anual_2024.csv`, el cual registra los accidentes de tránsito terrestre registrados durante 2024. El dataset contiene 390,627 registros y 45 variables

La información permite caracterizar cada accidente a partir de elementos como su ubicación, fecha y hora, tipo de percance, vehículos involucrados, posible causa, características del conductor y número de personas heridas o fallecidas. Esta variedad de atributos ofrece una base adecuada para aplicar técnicas de análisis y minería de datos a lo largo del proyecto.

2. Tema, problema y justificación

Área temática: Transporte y movilidad.

1. ¿Cuál es el problema?

Los accidentes de tránsito terrestre en zonas urbanas y suburbanas de México representan un problema de movilidad y seguridad pública por su frecuencia y por la variedad de consecuencias que generan. El fenómeno se acota al año 2024 y al estudio de su severidad: accidentes con sólo daños materiales, accidentes no fatales y accidentes fatales. El punto central es distinguir qué condiciones del evento, del lugar, del momento, de los vehículos involucrados y del conductor presunto responsable se relacionan con consecuencias de mayor gravedad.

2. ¿Por qué es relevante?

Su relevancia es social y económica. Social, porque los accidentes afectan de forma directa la integridad de conductores, pasajeros, peatones y ciclistas, y económica porque incluso los eventos sin víctimas implican daños materiales, interrupciones en la movilidad y costos para personas, aseguradoras e instituciones públicas. En 2024 se identifican 374,949 accidentes reales después de separar los registros administrativos sin percance. De ellos, 306,841 se clasifican como sólo daños, 63,920 como no fatales y 4,188 como fatales. En conjunto, los registros reportan 85,980 personas heridas y 4,656 personas fallecidas, cifras suficientes para considerar el fenómeno como un problema significativo dentro del área de transporte y movilidad.

3. ¿Qué se busca lograr?

El objetivo es identificar patrones medibles que ayuden a diferenciar la severidad de los accidentes de tránsito. En términos concretos, se busca reconocer qué combinaciones de zona, temporalidad, tipo de percance, vehículos involucrados, causa presunta, superficie de rodamiento y características del conductor aparecen con mayor frecuencia en cada nivel de severidad. Esto permite caracterizar perfiles de accidentes y distinguir los eventos con sólo daños de aquellos que involucran personas heridas o fallecidas.

4. ¿Por qué este dataset?

El archivo `atus_anual_2024.csv` es pertinente porque proviene de una fuente oficial, pública y verificable, y describe una problemática real y vigente en México. Contiene 390,627 registros y 45 variables con cobertura municipal. Sus columnas incluyen información geográfica, temporal, categórica y numérica: ubicación del evento, tipo de accidente, zona urbana o suburbana, vehículos

involucrados, causa presunta, superficie de rodamiento, características del conductor y conteos de personas heridas o fallecidas. Además, la variable **CLASACC** clasifica directamente la severidad del accidente, lo que permite plantear análisis supervisado, al mismo tiempo, la variedad de atributos descriptivos permite formar grupos de accidentes con características similares.

3. Datos utilizados

El dataset seleccionado forma parte del programa *Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas* (ATUS), publicado por el Instituto Nacional de Estadística y Geografía (INEGI). Los datos pueden descargarse desde la página oficial:

https://www.inegi.org.mx/programas/accidentes/?ps=Microdatos#datos_abiertos

Dentro del apartado de microdatos se utilizó la opción de *Accidentes de tránsito terrestre en zonas urbanas y suburbanas, 1997–2024*. El archivo comprimido (.zip) disponible en esa sección incluye la siguiente estructura general:

- **catalogos/**: catálogos auxiliares de día, edad, entidad, hora, minuto, municipio y mes.
- **conjunto_de_datos/**: archivos anuales correspondientes al periodo 1997–2024.
- **diccionario_de_datos/**: descripción de las variables utilizadas.
- **metadatos/**: información complementaria sobre el conjunto.
- **leeme_faq.txt**: notas y preguntas frecuentes.

Para este proyecto se seleccionó **atus_anual_2024.csv**, ya que es el archivo anual más reciente incluido en la descarga y permite analizar el estado actual del problema.

Requisito	Justificación
Datos reales relacionados con México	Los registros provienen de INEGI y están relacionados con accidentes de tránsito ocurridos en zonas urbanas y suburbanas del país durante 2024.
Volumen mínimo	El archivo atus_anual_2024.csv contiene 390,627 filas y 45 columnas, por encima del mínimo de 100,000 registros y 8 variables relevantes.
Variables numéricas y categóricas	Incluye variables numéricas, como el número de vehículos, personas heridas y fallecidas, y variables categóricas, como el tipo de accidente, la causa presunta, el día de la semana y la clasificación del evento.
Fuente pública, verificable y citable	El conjunto se obtiene desde el portal oficial de datos abiertos del INEGI, mediante la liga indicada anteriormente.
Modelado supervisado y agrupamiento	La variable CLASACC permite plantear tareas de clasificación según la severidad del accidente. A su vez, los atributos temporales, geográficos, vehiculares y del conductor permiten agrupar registros con características similares.

4. Diccionario oficial de datos

El archivo `diccionario_de_datos_atus_anual_2024.csv`, publicado junto con los datos del INEGI, documenta las 45 columnas del dataset original. A continuación se presenta una versión resumida de sus descripciones oficiales. Las variables se agrupan por su función para facilitar la lectura, pero se conservan sus nombres y tipos de dato originales.

Los valores permitidos y las definiciones extensas permanecen disponibles en el diccionario oficial. En particular, deben considerarse los códigos especiales que representan información no especificada, conductores fugados o registros administrativos con valor **Certificado cero**.

4.1 Identificación, localización y tiempo

Variable	Tipo	Descripción resumida
COBERTURA	varchar	Área geográfica a la que se refieren los indicadores.
ID_ENTIDAD	varchar	Clave INEGI de la entidad federativa.
ID_MUNICIPIO	varchar	Clave INEGI del municipio, debe interpretarse junto con la entidad.
ANIO	int	Año en el que ocurrió el accidente.
MES	varchar	Mes de referencia del accidente.
ID_HORA	int	Hora del accidente, el código 99 indica hora no especificada.
ID_MINUTO	int	Minuto del accidente, el código 99 indica minuto no especificado.
ID_DIA	varchar	Día del mes, el código 32 indica día no especificado.
DIASEMANA	varchar	Día de la semana en que ocurrió el evento.
URBANA	varchar	Tipo de ubicación dentro de una zona urbana.
SUBURBANA	varchar	Tipo de vía o camino dentro de una zona suburbana.

4.2 Características del accidente y del conductor

Variable	Tipo	Descripción resumida
TIPACCID	varchar	Tipo de percance, como colisión, volcadura, salida del camino o incendio.
CAUSAACCI	varchar	Causa presunta registrada para el accidente.
CAPAROD	varchar	Tipo de superficie de rodamiento: pavimentada o no pavimentada.
SEXO	varchar	Sexo registrado del conductor presunto responsable.
ALIENTO	varchar	Registro de aliento alcohólico del conductor.
CINTURON	varchar	Uso registrado de cinturón de seguridad por parte del conductor.
ID_EDAD	varchar	Edad del conductor, 0 indica fuga y 99 edad desconocida.

4.3 Vehículos involucrados

Las siguientes columnas numéricas indican cuántos vehículos de cada categoría participaron en el accidente.

Variable	Tipo	Descripción resumida
AUTOMOVIL	int	Automóviles de hasta siete asientos.
CAMPASAJ	int	Camionetas de pasajeros de 8 a 15 asientos.
MICROBUS	int	Microbuses de 16 a 20 asientos.
PASCAMION	int	Camiones urbanos de pasajeros de 21 a 29 asientos.
OMNIBUS	int	Ómnibus de 30 o más asientos.
TRANVIA	int	Trenes eléctricos o trolebuses.
CAMIONETA	int	Camionetas destinadas al transporte de carga.
CAMION	int	Camiones destinados al transporte de carga.
TRACTOR	int	Tractores con o sin remolque.
FERROCARRI	int	Ferrocarriles involucrados.
MOTOCICLET	int	Motocicletas involucradas.
BICICLETA	int	Bicicletas involucradas.
OTROVEHIC	int	Otros vehículos no incluidos en las categorías anteriores.

4.4 Víctimas, severidad y publicación

Las variables de víctimas contabilizan personas fallecidas o heridas según su forma de participación en el accidente.

Variable	Tipo	Descripción resumida
CONDMUERTO	int	Conductores fallecidos en el lugar del accidente.
CONDHERIDO	int	Conductores heridos.
PASAMUERTO	int	Pasajeros fallecidos en el lugar del accidente.
PASAHERIDO	int	Pasajeros heridos.
PEATMUERTO	int	Peatones fallecidos en el lugar del accidente.
PEATHERIDO	int	Peatones heridos.
CICLMUERTO	int	Ciclistas fallecidos en el lugar del accidente.
CICLHERIDO	int	Ciclistas heridos.
OTROMUERTO	int	Otras personas fallecidas en el lugar del accidente.
OTROHERIDO	int	Otras personas heridas.
NEMUERTO	int	Víctimas fallecidas sin clasificación específica.
NEHERIDO	int	Víctimas heridas sin clasificación específica.
CLASACC	varchar	Severidad del accidente: fatal, no fatal o sólo daños.
ESTATUS	varchar	Estado administrativo de las cifras publicadas por INEGI.

Este diccionario permite distinguir entre atributos descriptivos, cantidades numéricas y variables administrativas. También orienta la preparación posterior: **CLASACC** puede utilizarse como variable objetivo para clasificación, mientras que **ESTATUS**, las columnas constantes y los códigos especiales requieren un tratamiento acorde con su significado.

5. Análisis exploratorio y preparación de los datos

5.1 Alcance del análisis

El notebook `analisis_exploratorio.ipynb` documenta la revisión inicial del archivo original, el análisis descriptivo de sus variables y la preparación de un conjunto limpio para las siguientes etapas del proyecto. El procedimiento se realizó conservando el archivo bruto sin modificaciones, de modo que cada decisión de limpieza pudiera rastrearse y reproducirse.

Elemento	Resultado inicial
Archivo analizado	<code>atus_anual_2024.csv</code>
Registros	390,627 filas
Variables	45 columnas
Tamaño aproximado en memoria	439.12 MB
Cobertura	Nivel municipal, con registros de las 32 entidades federativas
Documentación	Diccionario oficial de INEGI con las 45 variables

La inspección distinguió variables categóricas, identificadores geográficos, componentes temporales y cantidades numéricas relacionadas con vehículos, personas heridas y personas fallecidas. También se revisó el diccionario oficial para interpretar correctamente los códigos especiales antes de realizar transformaciones.

5.2 Calidad inicial de los datos

La primera revisión se concentró en identificar situaciones que pudieran alterar el análisis estadístico o introducir ruido en los modelos posteriores. En esta etapa se examinó el archivo original sin modificarlo.

Aspecto revisado	Hallazgo
Valores nulos	El archivo original no contiene celdas vacías. Sin embargo, algunos valores completos funcionan como códigos especiales y requieren un tratamiento semántico.
Filas duplicadas	Se identificaron 871 repeticiones exactas, equivalentes aproximadamente al 0.22 % del archivo original.
Columnas sin variación	COBERTURA, ANIO, NEMUERTO y NEHERIDO contienen un solo valor y no permiten diferenciar accidentes.
Registros administrativos	Se localizaron 15,678 filas con <code>TIPACCID=Certificado cero</code> . Estas filas indican que un municipio no reportó accidentes durante un mes determinado no representan percances reales.
Códigos especiales de edad	En <code>ID_EDAD</code> , el valor 0 indica que el conductor se fugó y el valor 99 indica que su edad se desconoce. En el archivo bruto aparecen 50,715 y 61,564 registros respectivamente.

La ausencia de celdas vacías no significa que toda la información esté disponible. Algunos valores completos funcionan como marcadores semánticos. Por ejemplo, **Certificado cero** no es una categoría de accidente, y los códigos 0 y 99 de **ID_EDAD** tampoco son edades reales.

Las filas duplicadas se documentaron antes de eliminarlas porque el archivo no incluye un identificador único para cada percance. Sin embargo, la coincidencia exacta en las 45 columnas es poco probable para eventos independientes y las repeticiones representan una fracción reducida del archivo. Esta observación se retomó durante la limpieza.

5.3 Vista auxiliar de accidentes reales

Para describir el fenómeno se construyó una vista auxiliar que excluye los 15,678 registros con **TIPACCID=Certificado cero**, sin modificar todavía el archivo original ni retirar duplicados. Esta vista contiene 374,949 accidentes y se utilizó para estudiar las distribuciones sobre eventos reales.

Conjunto considerado	Registros
Archivo original	390,627
Registros administrativos separados	15,678
Vista auxiliar de accidentes	374,949

Los registros administrativos se utilizan para indicar que un municipio no reportó accidentes durante un mes determinado. Además del valor **Certificado cero** en varias columnas categóricas, estas filas contienen valores de relleno: día 28, día de la semana lunes, cero vehículos, cero víctimas y clasificación de sólo daños. Conservarlas incrementaría artificialmente algunas frecuencias y podría crear agrupamientos carentes de significado.

5.4 Dimensión geográfica y temporal

El dataset contiene registros de las 32 entidades federativas y 2,349 combinaciones de entidad y municipio. Aunque **ID_MUNICIPIO** presenta sólo 570 valores distintos, una misma clave municipal puede repetirse en entidades diferentes. Por ello, la identificación correcta de cada municipio requiere utilizar **ID_ENTIDAD** e **ID_MUNICIPIO** en conjunto.

Entidad	Municipio	Registros
19	39	33,579
26	30	11,991
8	19	9,742
19	46	8,916
16	53	7,087

La tabla muestra las cinco combinaciones con mayor cantidad de registros como referencia exploratoria. Estas claves son identificadores de catálogo, no cantidades, para asignar nombres geográficos o cruzarlas con otras fuentes se deben relacionar con los catálogos oficiales de INEGI.

Las columnas ANIO, MES, ID_DIA, DIASEMANA, ID_HORA e ID_MINUTO describen el momento del percance. Como era esperable en un archivo anual, todos los registros corresponden a 2024, por ello, ANIO sirve como referencia, pero no permite realizar comparaciones internas. Las demás columnas temporales sí presentan variación.

Aspecto	Observación exploratoria
Mes	El archivo bruto presenta entre 30,062 y 34,665 registros mensuales. El menor conteo corresponde a julio y el mayor a mayo.
Día y día de la semana	Los 15,678 registros administrativos utilizan día 28 y lunes. Por esta razón, dichas frecuencias no deben interpretarse antes de retirar Certificado cero .
Hora	Los mayores conteos del archivo bruto aparecen a las 23:00 con 26,565 registros y a las 14:00 con 24,225.
Minuto	Los minutos terminados en cero son especialmente frecuentes: 00 aparece 58,300 veces, 30 aparece 33,707 y 20 aparece 22,680. Esto puede indicar que una parte de las horas fue capturada de forma aproximada.

Esta primera lectura permite reconocer patrones de captura y preparar análisis temporales posteriores. Las comparaciones definitivas deberán realizarse sobre el dataset limpio, una vez retirados los registros administrativos.

5.5 Zona y características del percance

Las columnas URBANA y SUBURBANA describen la zona del accidente y deben interpretarse conjuntamente. Cuando un evento corresponde a una zona urbana, la columna suburbana contiene **Sin accidente en esta zona**, cuando el evento corresponde a una zona suburbana ocurre lo contrario. Este texto no es un dato faltante.

Ubicación registrada	Accidentes
Zona urbana: intersección	259,153
Zona urbana: no intersección	86,281
Zona suburbana: carretera estatal	20,107
Zona suburbana: otro camino	5,224
Zona suburbana: camino rural	4,184
Total	374,949

En conjunto, 345,434 accidentes corresponden a zonas urbanas y 29,515 a zonas suburbanas. La tabla cruzada elaborada en el notebook confirma que ambas columnas son complementarias.

La variable TIPACCID identifica el tipo de percance. Las categorías no se distribuyen de forma uniforme: la colisión con vehículo automotor reúne 224,720 casos (59.93 %), seguida por la colisión con motocicleta con 61,869 (16.50 %) y la colisión con objeto fijo con 43,119 (11.50 %). Estas tres categorías concentran la mayor parte de los accidentes. En comparación con incendio y colisión con ferrocarril que aparecen con frecuencias considerablemente menores.




Figura 1: Cantidad de accidentes según el tipo de percance.

La causa presunta y la superficie de rodamiento aportan información adicional sobre el contexto del evento.

Variable y categoría	Accidentes	Porcentaje	Lectura
CAUSAACCI: conductor	360,051	96.03 %	Categoría ampliamente dominante.
CAUSAACCI: condición del camino	5,991	1.60 %	Segunda causa presunta más frecuente.
CAUSAACCI: falla del vehículo	3,978	1.06 %	Frecuencia reducida respecto al conductor.
CAPAROD: pavimentada	368,913	98.39 %	Superficie registrada en la mayoría de los eventos.
CAPAROD: no pavimentada	6,036	1.61 %	Superficie minoritaria en el archivo.

CAUSAACCI representa una clasificación presunta registrada en el dataset, no una demostración independiente de causalidad. De manera similar, la cantidad de accidentes en superficies pavimentadas no demuestra que éstas sean más peligrosas, pues el archivo no contiene medidas de exposición como longitud de vialidades o número de desplazamientos.

5.6 Vehículos involucrados

Las trece columnas vehiculares indican cuántas unidades de cada categoría participaron en un percance. No son variables excluyentes: un mismo accidente puede involucrar automóviles, motocicletas u otros vehículos simultáneamente. En la vista auxiliar se contabilizaron 710,403 vehículos, con un promedio de 1.89 por accidente.

Categoría	Vehículos	Porcentaje	Accidentes donde aparece
Automóvil	436,681	61.47 %	302,962
Motocicleta	86,124	12.12 %	80,101
Camioneta de pasajeros	79,558	11.20 %	69,664
Camioneta de carga	51,106	7.19 %	47,432




Figura 2: Cantidad total de vehículos involucrados por categoría.

Cantidad de vehículos por accidente	Accidentes
1	61,910
2	294,083
3	16,313
4	2,083
5 o más	560

La mayoría de los accidentes, aproximadamente el 78.43 %, involucra exactamente dos vehículos.

5.7 Información del conductor

La exploración revisó las características disponibles del conductor presunto responsable. En cuanto al sexo registrado, 278,004 accidentes corresponden a hombres (74.14 %), 61,908 a mujeres (16.51 %) y 35,037 a casos en los que el conductor se fugó (9.34 %).

Antes de calcular estadísticas de edad fue necesario separar los códigos especiales. Dentro de la vista auxiliar de accidentes, el valor 0 aparece en 35,037 registros y corresponde a conductores fugados, el valor 99 aparece en 61,564 registros y representa edad desconocida. Después de excluir ambos códigos quedan 278,348 edades válidas entre 12 y 98 años. La media es de 37.85 años y la mediana de 35 años, la mayor concentración se observa entre los 18 y 49 años.




Figura 3: Distribución de edades válidas según el sexo registrado.

Las variables **ALIENTO** y **CINTURON** contienen una cantidad relevante de casos desconocidos. Por ello conviene distinguir el porcentaje sobre todos los accidentes del porcentaje calculado únicamente entre casos conocidos.

Variable	Valor	Accidentes	Porcentaje	Entre casos conocidos
Aliento	Sí	15,915	4.24 %	6.24 %
alcohólico				
Aliento	No	239,170	63.79 %	93.76 %
alcohólico				
Aliento	Se ignora	119,864	31.97 %	No aplica
alcohólico				
Cinturón	Sí	42,451	11.32 %	49.51 %
Cinturón	No	43,285	11.54 %	50.49 %
Cinturón	Se ignora	289,213	77.13 %	No aplica

En el caso de **ALIENTO**, la columna registra la presencia de aliento alcohólico, pero no permite

determinar el grado de consumo ni afirmar que el alcohol causó el percance. Para CINTURON, la proporción de información desconocida es particularmente alta y la variable sólo describe al conductor presunto responsable, no al resto de ocupantes.

5.8 Víctimas, severidad y estatus

Las variables de víctimas contabilizan personas heridas y fallecidas según su tipo de participación. Es importante distinguir estas cantidades del número de accidentes, pues un mismo percance puede afectar a más de una persona.

Tipo de persona	Fallecidas	Heridas
Conductores	2,614	45,442
Pasajeros	972	26,828
Peatones	901	11,509
Ciclistas	142	2,097
Otras personas	27	104
Total	4,656	85,980

Los conductores concentran el mayor número de víctimas, seguidos por pasajeros y peatones. En total, 4,188 accidentes registraron al menos una persona fallecida y 64,845 incluyeron al menos una persona herida. Las columnas de víctimas no especificadas tienen valor cero en todos los registros.




Figura 4: Personas heridas y fallecidas según su tipo de participación.

La variable CLASACC resume la severidad del accidente y será central para el aprendizaje supervisado.

Clasificación	Accidentes	Porcentaje
Sólo daños	306,841	81.84 %
No fatal	63,920	17.05 %
Fatal	4,188	1.12 %

La cantidad de accidentes fatales coincide con los 4,188 eventos que registran al menos una persona fallecida, de manera consistente con el diccionario oficial. La distribución evidencia un desbalance considerable, especialmente para la clase **Fatal**.




Figura 5: Cantidad de accidentes según su clasificación de severidad.

Para el agrupamiento, **CLASACC** deberá excluirse de las variables de entrada con el fin de formar grupos sin proporcionar previamente la severidad. Por otra parte, **ESTATUS** indica el estado administrativo de las cifras: 356,109 accidentes corresponden a cifras definitivas (94.98 %) y 18,840 a cifras corregidas (5.02 %). Como esta variable no describe el percance, se conserva únicamente como referencia durante la exploración.

5.9 Limpieza y generación del dataset final

A partir de los hallazgos anteriores se generó un nuevo archivo sin alterar el CSV original. Las transformaciones se aplicaron de manera secuencial:

Transformación	Justificación y resultado
Eliminar duplicados exactos	Se retiraron 871 filas repetidas. El conjunto pasó de 390,627 a 389,756 registros y no quedaron duplicados exactos.
Eliminar columnas constantes	Se retiraron COBERTURA, ANIO, NEMUERTO y NEHERIDO, ya que no aportan variación para comparar registros ni entrenar modelos.
Retirar Certificado cero	Se eliminaron 15,678 filas administrativas. Después de esta operación permanecen 374,078 accidentes.
Separar códigos de edad	Se crearon CONDUCTOR_FUGADO y EDAD_DESCONOCIDA. Los códigos 0 y 99 se reemplazaron por valores nulos en ID_EDAD para evitar tratarlos como edades reales.
Eliminar ESTATUS	Se retiró esta variable porque describe la publicación de las cifras, no las características del percance.

El resultado se exportó como `atus_anual_2024_limpio.csv`. Este archivo contiene 374,078 filas y 42 columnas, conserva únicamente accidentes reales y no presenta duplicados exactos.

La diferencia entre los 374,949 accidentes de la vista auxiliar y los 374,078 registros del archivo final se debe a que la primera todavía conservaba filas duplicadas. Al aplicar la limpieza, los únicos valores nulos restantes se encuentran en ID_EDAD: 34,920 registros corresponden a conductores fugados y 61,302 a edades desconocidas, para un total de 96,222 valores faltantes intencionales. Es decir, permanecen 277,856 edades válidas.

El dataset limpio constituye el punto de partida para el análisis estadístico, la clasificación supervisada y el agrupamiento.