



Universidad Nacional Autónoma de
México

Facultad de Ciencias



Almacenes y Minería de Datos
Semestre 2026-2

Proyecto final

Reporte formal

Profesora:	Jessica Santizo Galicia
Ayudante:	Diego Antonio Villalba González
Ayud. Lab.:	Ares Gael Castro Romero

Alumnos

Omar Fernando Gramer Muñoz | 419003698
Kevin Steve Quezada Ordoñez | 318331241
Jesús Antonio Romero Godoy | 321144292
Edgar Salgado González | 321277086

Fecha de entrega: 8 de junio de 2026

Índice

1. Introducción	1
2. Tema, problema y justificación	1
2.1. ¿Por qué es relevante?	2
2.2. ¿Qué se busca lograr?	2
2.3. ¿Por qué este dataset?	2
3. Arquitectura y Estructura del Proyecto	3
3.1. Orden de ejecución de los notebooks	4
3.2. Diagramas UML	5
4. Descripción del Dataset	7
5. Diccionario oficial de datos	8
5.1. Identificación, localización y tiempo	8
5.2. Características del accidente y del conductor	8
5.3. Vehículos involucrados	9
5.4. Víctimas, severidad y publicación	9
6. Análisis exploratorio y preparación de los datos	10
6.1. Alcance del análisis	10
6.2. Calidad inicial de los datos	10
6.3. Vista auxiliar de accidentes reales	11
6.4. Dimensión geográfica y temporal	11
6.5. Zona y características del percance	12
6.6. Vehículos involucrados	13
6.7. Información del conductor	15
6.8. Víctimas, severidad y estatus	16
6.9. Limpieza y generación del dataset final	18
7. Análisis Descriptivo y Estadístico con Interpretaciones	19
7.1. ATUS Anual 2024	19
7.1.1. Localización y Caracterización General	19
7.2. Evidencia Gráfica de Distribuciones	20
7.3. Análisis de Variables Temporales y Demográficas Continuas	20
7.3.1. Análisis de Variabilidad y Dispersión Data-Driven	21
7.3.2. Análisis de Heterogeneidad, Concentración y Entropía	23
7.3.3. Análisis de Concentración e Inequidad Distribucional	25
8. Análisis de Correlaciones, Severidad y Factores de Riesgo	26
8.1. Evaluación Lineal de la Siniestralidad Global	26
8.1.1. Modelado de Evasión Conductual según la Severidad del Siniestro	27
8.2. Factores de Riesgo Condicionados y Tipología Vehicular	28

9. Modelo Supervisado de Clasificación	31
9.1. Planteamiento y variable objetivo	31
9.2. Selección de variables de entrada	31
9.2.1. Variables excluidas	32
9.2.2. Transformaciones aplicadas	32
9.3. División de los datos	32
9.4. Modelos entrenados	33
9.4.1. Línea base trivial	33
9.4.2. Random Forest	33
9.4.3. Importancia de características: Random Forest	34
9.4.4. XGBoost	35
9.4.5. Importancia de características: Xgboost	35
9.5. Evaluación con umbral por defecto	36
9.5.1. Interpretacion de matrices y curvas ROC	37
9.6. Ajuste de umbral de clasificación	38
9.6.1. Comportamiento del F1-macro al modificar el umbral	39
9.7. Modelo final — XGBoost con umbral ajustado	41
9.7.1. Métricas finales	41
9.8. Persistencia y reutilización	41
9.9. Limitaciones	42
10. Agrupamiento no supervisado	43
10.1. Planteamiento y motivación	43
10.2. Selección y exclusión de variables	43
10.2.1. Variables de entrada	43
10.2.2. Variables excluidas y justificación	44
10.3. Preprocesamiento	44
10.4. Selección del número de grupos	45
10.4.1. Método del codo	45
10.4.2. Coeficiente de silueta	45
10.4.3. Elección de $k = 4$	46
10.5. Comparación de algoritmos	46
10.6. Reducción de dimensionalidad	46
10.7. Perfiles del modelo final	47
10.7.1. Tamaños y variables firma	48
10.7.2. Descripción individual de cada perfil	48
10.7.3. Distribución de severidad por perfil	49
10.8. Reutilización del modelo	50
10.9. Arquitectura del módulo <code>src/clustering/</code>	50
10.9.1. Estructura de archivos	50
10.9.2. Patrones de diseño	50
10.9.3. Responsabilidades por clase	51
10.10 Conclusiones del agrupamiento	52

1 Introducción

Los accidentes de tránsito en zonas urbanas y suburbanas de México representan un problema relevante de movilidad, seguridad pública y bienestar social. Además de los daños materiales, estos eventos pueden ocasionar lesiones y fallecimientos, por lo que resulta importante estudiar qué condiciones se asocian con accidentes de mayor severidad. El problema central de este proyecto consiste en analizar los factores geográficos, temporales, vehiculares y humanos que intervienen en la gravedad de los accidentes registrados durante 2024.

El objetivo del proyecto es identificar patrones y relaciones dentro de los datos de **Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas (ATUS)**, publicados por el Instituto Nacional de Estadística y Geografía (INEGI)[1]. Para ello se utiliza el archivo `atus_anual_2024.csv`, que contiene 390,627 registros y 45 variables. A partir de esta información se busca distinguir entre accidentes con sólo daños materiales, accidentes no fatales y accidentes fatales, así como caracterizar las condiciones bajo las cuales ocurren.

La justificación del análisis se basa en la magnitud del fenómeno y en la utilidad de trabajar con una fuente oficial, pública y verificable. La estadística ATUS se construye a partir de registros administrativos proporcionados por dependencias de seguridad pública y vialidad estatales y municipales, agencias del Ministerio Público y juzgados cívicos. Esto permite contar con información amplia sobre ubicación, fecha, hora, tipo de percance, vehículos involucrados, causa presunta, características del conductor y consecuencias humanas del accidente.

El valor del proyecto radica en transformar estos registros administrativos en conocimiento útil para la toma de decisiones y para la comprensión del fenómeno. Mediante técnicas de análisis exploratorio, limpieza de datos, modelado supervisado y agrupamiento, el proyecto permite reconocer perfiles de riesgo, evaluar variables asociadas con la severidad y proponer una lectura basada en datos sobre los accidentes de tránsito en México.

2 Tema, problema y justificación

Área temática: Transporte y movilidad.

Los accidentes de tránsito en zonas urbanas y suburbanas de México constituyen un fenómeno complejo en el que intervienen factores geográficos, temporales, vehiculares y humanos. En este proyecto, el análisis se centra en la severidad de los accidentes ocurridos durante 2024, distinguiendo entre eventos con daños materiales, accidentes no fatales y accidentes fatales.

El problema de interés consiste en identificar qué características y condiciones de los accidentes se asocian con mayores niveles de gravedad, con el fin de comprender mejor las circunstancias bajo las cuales ocurren los eventos más severos.

2.1 ¿Por qué es relevante?

La relevancia de este problema es tanto social como económica. Desde una perspectiva social, los accidentes de tránsito afectan directamente la integridad física de conductores, pasajeros, peatones y ciclistas. Desde una perspectiva económica, generan daños materiales, interrupciones en la movilidad y costos para las personas involucradas, las aseguradoras y las instituciones públicas.

La **magnitud** del fenómeno se refleja en los registros analizados para 2024. Tras excluir los registros administrativos sin percance, se identificaron 374,949 accidentes, de los cuales 63,920 ocasionaron personas lesionadas y 4,188 correspondieron a accidentes fatales. En conjunto, estos eventos dejaron un saldo de, **980 personas heridas y 4,656 personas fallecidas** en tan solo **un año**.

Estas cifras evidencian la importancia de comprender los factores asociados a la severidad de los accidentes y justifican la necesidad de analizarlos desde una perspectiva basada en datos.

2.2 ¿Qué se busca lograr?

El objetivo de este proyecto es analizar el conjunto de datos más reciente disponible de ATUS (2024) para identificar los factores asociados a la severidad de los accidentes de tránsito. A partir de variables geográficas, temporales, vehiculares y humanas, y mediante la aplicación de técnicas de minería de datos y aprendizaje automático, se buscará identificar patrones recurrentes y caracterizar las circunstancias bajo las cuales ocurren accidentes de mayor gravedad, especialmente aquellos que involucran personas lesionadas o fallecidas.

2.3 ¿Por qué este dataset?

Este conjunto de datos fue seleccionado por combinar tres características importantes para el desarrollo del proyecto: una fuente oficial y confiable, una problemática de alta relevancia social y una amplia cantidad de variables descriptivas que permiten caracterizar los accidentes desde múltiples perspectivas.

Dado que el objetivo es analizar la situación más reciente de los accidentes de tránsito, se seleccionó el archivo correspondiente al año más actual disponible dentro del conjunto de datos de ATUS (`atus_anual_2024.csv`). Además, centrar el estudio en un único año permite mantener un alcance adecuado para los objetivos del proyecto.

La elección en particular de este conjunto de datos se debe, en gran medida, a la riqueza de sus variables descriptivas.

Consideramos que la información disponible permitirá caracterizar los accidentes desde múltiples perspectivas, incluyendo aspectos geográficos, temporales, vehiculares y humanos. Esta diversidad de atributos proporciona una base sólida para identificar patrones y explorar posibles relaciones entre los distintos factores asociados a los accidentes de tránsito.

3 Arquitectura y Estructura del Proyecto

Esta sección documenta la organización técnica del proyecto: la estructura del repositorio, el orden de ejecución de los notebooks y las decisiones de diseño de software que guiaron la implementación del código fuente.

```
ProyectoFinal/
|-- data/
|   |-- atus_anual_2024.csv          <- Dataset original (INEGI)
|   |-- atus_anual_2024_limpio.csv   <- Dataset limpio generado por limpieza.ipynb
|   |-- AGEEML.csv                  <- Catálogo oficial de municipios (INEGI)
|   |-- diccionario_de_datos...csv   <- Diccionario de referencia dataset ATUS
|-- notebooks/
|   |-- analisis_exploratorio.ipynb  <- EDA sin modificar datos
|   |-- limpieza.ipynb               <- Creación de dataset limpio
|   |-- analisis_descriptivo_
|       estadistico.ipynb            <- Análisis estadístico y visualizaciones
|   |-- modelado.ipynb               <- Clasificación supervisada (XGBoost)
|   |-- agrupamiento.ipynb           <- Agrupamiento no supervisado (K-Means)
|   |-- demo.ipynb                  <- Demostración de reutilización del modelo
|-- src/
|   |-- supervised/                  <- Módulo de clasificación supervisada
|   |   |-- config/                  <- Parámetros configurables para clases de modelado
|   |   |   |-- multiples_archivos .yaml
|   |   |   |-- data_repository.py
|   |   |   |-- preprocessor.py
|   |   |   |-- model_factory.py
|   |   |   |-- trainer.py
|   |   |-- evaluator.py
|   |-- clustering/                  <- Módulo de agrupamiento no supervisado
|   |   |-- __init__.py
|   |   |-- preprocessor.py
|   |   |-- strategies.py
|   |   |-- analyzer.py
|   |-- model.py
|-- models/                          <- Serialización de modelos entrenados
|   |-- dummy.joblib
|   |-- random_forest.joblib
|   |-- xgboost.joblib
|   |-- clustering_kmeans.joblib
|-- reports/
|   |-- model_evaluation/
|   |-- figures/                    <- Visualizaciones del análisis descriptivo
|-- diagrams/                        <- Diagramas UML de arquitectura
|-- docs/                           <- Sitio Quarto (GitHub Pages)
|-- README.md
-- requirements.txt
```

3.1 Orden de ejecución de los notebooks

Los notebooks están diseñados para ejecutarse de forma secuencial. Cada uno toma como entrada el archivo generado por el anterior y produce el insumo para el siguiente.

- **1.Analisis_exploratorio:** Revisión inicial del dataset original: calidad de datos, diccionario de variables y análisis individual de cada columna. No modifica los datos.
- **2.Limpieza:** Aplicación de todas las decisiones de limpieza: eliminación de duplicados, registros administrativos y columnas constantes, tratamiento de códigos especiales, incorporación de nombres oficiales de entidad y municipio. Exporta `atus\_anual\_2024\_limpio.csv`.
- **3.Analisis_descriptivo_estadistico:** Análisis estadístico descriptivo del dataset limpio: localización, variabilidad, heterogeneidad, concentración y correlaciones entre variables.
- **4.Modelado:** Implementación del pipeline de clasificación supervisada: preprocesamiento, entrenamiento de modelos (línea base, Random Forest y XGBoost), evaluación con métricas completas y ajuste de umbral de clasificación para la clase `Fatal`.
- **5.Demo_persistencia:** Demostración de reutilización del modelo final: carga independiente del entrenamiento y predicción sobre registros.
- **6.Agrupamiento:** Agrupamiento no supervisado con K-Means: selección de variables, preprocesamiento, comparación de algoritmos, selección del número de grupos y descripción de perfiles.

3.2 Diagramas UML

Los siguientes diagramas documentan la arquitectura de clases de los módulos supervised y clustering, incluyendo atributos, métodos públicos, relaciones entre clases y patrones de diseño implementados.




Figura 1: Diagrama UML del módulo `src/supervised/`. Muestra las cinco clases principales, sus atributos, métodos y relaciones de dependencia con los archivos de configuración YAML.




Figura 2: Diagrama UML del módulo `src/clustering/`. Muestra las cinco clases, sus atributos, métodos públicos y relaciones de composición y herencia.

4 Descripción del Dataset

El dataset seleccionado forma parte del programa *Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas* (ATUS), publicado por el Instituto Nacional de Estadística y Geografía (INEGI) [1]. Los datos fueron obtenidos del portal oficial de datos abiertos del INEGI, en el apartado correspondiente al programa ATUS:

https://www.inegi.org.mx/programas/accidentes/#datos_abiertos.

Dentro de este apartado se encuentra disponible el conjunto *Accidentes de tránsito terrestre en zonas urbanas y suburbanas, 1997–2024*, el cual incluye archivos anuales de datos, catálogos auxiliares, diccionarios de variables y documentación complementaria para su correcta interpretación. La fecha de extracción de los datos fue el 29 de mayo de 2026.

Para este proyecto se utilizó el archivo `atus_anual_2024.csv`, correspondiente al periodo más reciente disponible dentro del conjunto de datos. Esta elección permite analizar la situación actual de los accidentes de tránsito manteniendo un alcance adecuado para los objetivos del estudio.

El dataset contiene 390,627 registros y 45 variables con cobertura a nivel municipal. Las variables disponibles describen aspectos geográficos, temporales, vehiculares y humanos asociados a cada accidente, incluyendo información sobre su ubicación, condiciones de ocurrencia, participantes involucrados y consecuencias del evento.

Requisito	Justificación
Datos reales relacionados con México	Los registros provienen de INEGI y documentan accidentes de tránsito ocurridos en zonas urbanas y suburbanas de México durante 2024.
Volumen mínimo	El archivo <code>atus_anual_2024.csv</code> contiene 390,627 registros y 45 variables, superando ampliamente los requisitos mínimos establecidos para el proyecto.
Variables numéricas y categóricas	Incluye variables numéricas y categóricas que describen aspectos geográficos, temporales, vehiculares y humanos asociados a cada accidente.
Fuente pública, verificable y citable	La información proviene del portal oficial de datos abiertos del INEGI y se encuentra acompañada de diccionarios de variables, catálogos y documentación técnica que respaldan su uso.
Modelado supervisado y agrupamiento	La riqueza de variables descriptivas permite aplicar técnicas de aprendizaje supervisado para estudiar la severidad de los accidentes, así como métodos de agrupamiento para identificar perfiles y patrones entre los registros.

Como limitaciones conocidas, los datos dependen de registros administrativos cuya calidad varía entre entidades y municipios. Varias variables utilizan códigos especiales (**Certificado cero**, edad desconocida, conductor fugado) que no representan valores ordinarios y requieren tratamiento explícito. El conjunto tampoco incluye medidas de exposición como volumen de tránsito o kilómetros recorridos, por lo que las frecuencias describen accidentes registrados, no tasas de riesgo ajustadas.

5 Diccionario oficial de datos

El archivo `diccionario_de_datos_atus_anual_2024.csv`, publicado por el INEGI junto con el conjunto de datos ATUS [2], documenta las 45 variables del dataset original. En esta sección se presenta una versión resumida de dichas descripciones para consulta rápida, manteniendo los nombres y tipos de dato originales.

Asimismo, el diccionario oficial incluye códigos especiales para representar información no disponible o casos particulares, como registros incompletos, valores no especificados y situaciones administrativas como `Certificado cero`. Estos códigos deben considerarse durante el proceso de limpieza y análisis de los datos.

5.1 Identificación, localización y tiempo

Variable	Tipo	Descripción resumida
COBERTURA	varchar	Área geográfica a la que se refieren los indicadores.
ID_ENTIDAD	varchar	Clave INEGI de la entidad federativa.
ID_MUNICIPIO	varchar	Clave INEGI del municipio, debe interpretarse junto con la entidad.
ANIO	int	Año en el que ocurrió el accidente.
MES	varchar	Mes de referencia del accidente.
ID_HORA	int	Hora del accidente, el código 99 indica hora no especificada.
ID_MINUTO	int	Minuto del accidente, el código 99 indica minuto no especificado.
ID_DIA	varchar	Día del mes, el código 32 indica día no especificado.
DIASEMANA	varchar	Día de la semana en que ocurrió el evento.
URBANA	varchar	Tipo de ubicación dentro de una zona urbana.
SUBURBANA	varchar	Tipo de vía o camino dentro de una zona suburbana.

5.2 Características del accidente y del conductor

Variable	Tipo	Descripción resumida
TIPACCID	varchar	Tipo de percance, como colisión, volcadura, salida del camino o incendio.
CAUSAACCI	varchar	Causa presunta registrada para el accidente.
CAPAROD	varchar	Tipo de superficie de rodamiento: pavimentada o no pavimentada.
SEXO	varchar	Sexo registrado del conductor presunto responsable.
ALIENTO	varchar	Registro de aliento alcohólico del conductor.
CINTURON	varchar	Uso registrado de cinturón de seguridad por parte del conductor.
ID_EDAD	varchar	Edad del conductor, 0 indica fuga y 99 edad desconocida.

5.3 Vehículos involucrados

Las siguientes columnas numéricas indican cuántos vehículos de cada categoría participaron en el accidente.

Variable	Tipo	Descripción resumida
AUTOMOVIL	int	Automóviles de hasta siete asientos.
CAMPASAJ	int	Camionetas de pasajeros de 8 a 15 asientos.
MICROBUS	int	Microbuses de 16 a 20 asientos.
PASCAMION	int	Camiones urbanos de pasajeros de 21 a 29 asientos.
OMNIBUS	int	Ómnibus de 30 o más asientos.
TRANVIA	int	Trenes eléctricos o trolebuses.
CAMIONETA	int	Camionetas destinadas al transporte de carga.
CAMION	int	Camiones destinados al transporte de carga.
TRACTOR	int	Tractores con o sin remolque.
FERROCARRI	int	Ferrocarriles involucrados.
MOTOCICLET	int	Motocicletas involucradas.
BICICLETA	int	Bicicletas involucradas.
OTROVEHIC	int	Otros vehículos no incluidos en las categorías anteriores.

5.4 Víctimas, severidad y publicación

Las variables de víctimas contabilizan personas fallecidas o heridas según su forma de participación en el accidente.

Variable	Tipo	Descripción resumida
CONDMUERTO	int	Conductores fallecidos en el lugar del accidente.
CONDHERIDO	int	Conductores heridos.
PASAMUERTO	int	Pasajeros fallecidos en el lugar del accidente.
PASAHERIDO	int	Pasajeros heridos.
PEATMUERTO	int	Peatones fallecidos en el lugar del accidente.
PEATHERIDO	int	Peatones heridos.
CICLMUERTO	int	Ciclistas fallecidos en el lugar del accidente.
CICLHERIDO	int	Ciclistas heridos.
OTROMUERTO	int	Otras personas fallecidas en el lugar del accidente.
OTROHERIDO	int	Otras personas heridas.
NEMUERTO	int	Víctimas fallecidas sin clasificación específica.
NEHERIDO	int	Víctimas heridas sin clasificación específica.
CLASACC	varchar	Severidad del accidente: fatal, no fatal o sólo daños.
ESTATUS	varchar	Estado administrativo de las cifras publicadas por INEGI.

Este diccionario permite distinguir entre atributos descriptivos, cantidades numéricas y variables administrativas. También orienta la preparación posterior: **CLASACC** puede utilizarse como variable objetivo para clasificación, mientras que **ESTATUS**, las columnas constantes y los códigos especiales requieren un tratamiento acorde con su significado.

6 Análisis exploratorio y preparación de los datos

6.1 Alcance del análisis

El notebook `analisis_exploratorio.ipynb` documenta la revisión inicial del archivo original, el análisis descriptivo de sus variables y la preparación de un conjunto limpio para las siguientes etapas del proyecto. El procedimiento se realizó conservando el archivo bruto sin modificaciones, de modo que cada decisión de limpieza pudiera rastrearse y reproducirse.

Elemento	Resultado inicial
Archivo analizado	<code>atus_anual_2024.csv</code>
Registros	390,627 filas
Variables	45 columnas
Tamaño aprox.	102 MB
Cobertura	Nivel municipal, con registros de las 32 entidades federativas en el año 2024.
Documentación	Diccionario oficial de INEGI con las 45 variables

La inspección distinguió variables categóricas, identificadores geográficos, componentes temporales y cantidades numéricas relacionadas con vehículos, personas heridas y personas fallecidas. También se revisó el diccionario oficial para interpretar correctamente los códigos especiales antes de realizar transformaciones.

6.2 Calidad inicial de los datos

La primera revisión se concentró en identificar situaciones que pudieran alterar el análisis estadístico o introducir ruido en los modelos posteriores. En esta etapa se examinó el archivo original sin modificarlo.

Aspecto revisado	Hallazgo
Valores nulos	El archivo original no contiene celdas vacías. Sin embargo, algunos valores completos funcionan como códigos especiales y requieren un tratamiento semántico.
Filas duplicadas	Se identificaron 871 repeticiones exactas, equivalentes aproximadamente al 0.22 % del archivo original.
Columnas sin variación	<code>COBERTURA</code> , <code>ANIO</code> , <code>NEMUERTO</code> y <code>NEHERIDO</code> contienen un solo valor y no permiten diferenciar accidentes.
Registros administrativos	Se localizaron 15,678 filas con <code>TIPACCID=Certificado cero</code> . Estas filas indican que un municipio no reportó accidentes durante un mes determinado no representan percances reales.
Códigos especiales de edad	En <code>ID_EDAD</code> , el valor 0 indica que el conductor se fugó y el valor 99 indica que su edad se desconoce. En el archivo bruto aparecen 50,715 y 61,564 registros respectivamente.

La ausencia de celdas vacías no significa que toda la información esté disponible. Algunos valores completos funcionan como marcadores semánticos. Por ejemplo, **Certificado cero** no es una categoría de accidente, y los códigos 0 y 99 de **ID_EDAD** tampoco son edades reales.

Las filas duplicadas se documentaron antes de eliminarlas porque el archivo no incluye un identificador único para cada percance. Sin embargo, la coincidencia exacta en las 45 columnas es poco probable para eventos independientes y las repeticiones representan una fracción reducida del archivo. Esta observación se retomó durante la limpieza.

6.3 Vista auxiliar de accidentes reales

Para describir el fenómeno se construyó una vista auxiliar que excluye los 15,678 registros con **TIPACCID=Certificado cero**, sin modificar todavía el archivo original ni retirar duplicados. Esta vista contiene 374,949 accidentes y se utilizó para estudiar las distribuciones sobre eventos reales.

Conjunto considerado	Registros
Archivo original	390,627
Registros administrativos separados	15,678
Vista auxiliar de accidentes	374,949

Los registros administrativos se utilizan para indicar que un municipio no reportó accidentes durante un mes determinado. Además del valor **Certificado cero** en varias columnas categóricas, estas filas contienen valores de relleno: día 28, día de la semana lunes, cero vehículos, cero víctimas y clasificación de sólo daños. Conservarlas incrementaría artificialmente algunas frecuencias y podría crear agrupamientos carentes de significado.

6.4 Dimensión geográfica y temporal

El dataset contiene registros de las 32 entidades federativas y 2,349 combinaciones de entidad y municipio. Aunque **ID_MUNICIPIO** presenta sólo 570 valores distintos, una misma clave municipal puede repetirse en entidades diferentes. Por ello, la identificación correcta de cada municipio requiere utilizar **ID_ENTIDAD** e **ID_MUNICIPIO** en conjunto.

Entidad	Municipio	Registros
19	39	33,579
26	30	11,991
8	19	9,742
19	46	8,916
16	53	7,087

La tabla muestra las cinco combinaciones con mayor cantidad de registros como referencia exploratoria. Estas claves son identificadores de catálogo, no cantidades, para asignar nombres geográficos o cruzarlas con otras fuentes se deben relacionar con los catálogos oficiales de INEGI.

Las columnas ANIO, MES, ID_DIA, DIASEMANA, ID_HORA e ID_MINUTO describen el momento del percance. Como era esperable en un archivo anual, todos los registros corresponden a 2024, por ello, ANIO sirve como referencia, pero no permite realizar comparaciones internas. Las demás columnas temporales sí presentan variación.

Aspecto	Observación exploratoria
Mes	El archivo bruto presenta entre 30,062 y 34,665 registros mensuales. El menor conteo corresponde a julio y el mayor a mayo.
Día y día de la semana	Los 15,678 registros administrativos utilizan día 28 y lunes. Por esta razón, dichas frecuencias no deben interpretarse antes de retirar Certificado cero .
Hora	Los mayores conteos del archivo bruto aparecen a las 23:00 con 26,565 registros y a las 14:00 con 24,225.
Minuto	Los minutos terminados en cero son especialmente frecuentes: 00 aparece 58,300 veces, 30 aparece 33,707 y 20 aparece 22,680. Esto puede indicar que una parte de las horas fue capturada de forma aproximada.

Esta primera lectura permite reconocer patrones de captura y preparar análisis temporales posteriores. Las comparaciones definitivas deberán realizarse sobre el dataset limpio, una vez retirados los registros administrativos.

6.5 Zona y características del percance

Las columnas URBANA y SUBURBANA describen la zona del accidente y deben interpretarse conjuntamente. Cuando un evento corresponde a una zona urbana, la columna suburbana contiene **Sin accidente en esta zona**, cuando el evento corresponde a una zona suburbana ocurre lo contrario. Este texto no es un dato faltante.

Ubicación registrada	Accidentes
Zona urbana: intersección	259,153
Zona urbana: no intersección	86,281
Zona suburbana: carretera estatal	20,107
Zona suburbana: otro camino	5,224
Zona suburbana: camino rural	4,184
Total	374,949

En conjunto, 345,434 accidentes corresponden a zonas urbanas y 29,515 a zonas suburbanas. La tabla cruzada elaborada en el notebook confirma que ambas columnas son complementarias.

La variable TIPACCID identifica el tipo de percance. Las categorías no se distribuyen de forma uniforme: la colisión con vehículo automotor reúne 224,720 casos (59.93 %), seguida por la colisión con motocicleta con 61,869 (16.50 %) y la colisión con objeto fijo con 43,119 (11.50 %). Estas tres categorías concentran la mayor parte de los accidentes. En comparación con incendio y colisión con ferrocarril que aparecen con frecuencias considerablemente menores.




Figura 3: Cantidad de accidentes según el tipo de percance.

La causa presunta y la superficie de rodamiento aportan información adicional sobre el contexto del evento.

Variable y categoría	Accidentes	Porcentaje	Lectura
CAUSAACCI: conductor	360,051	96.03 %	Categoría ampliamente dominante.
CAUSAACCI: condición del camino	5,991	1.60 %	Segunda causa presunta más frecuente.
CAUSAACCI: falla del vehículo	3,978	1.06 %	Frecuencia reducida respecto al conductor.
CAPAROD: pavimentada	368,913	98.39 %	Superficie registrada en la mayoría de los eventos.
CAPAROD: no pavimentada	6,036	1.61 %	Superficie minoritaria en el archivo.

CAUSAACCI representa una clasificación presunta registrada en el dataset, no una demostración independiente de causalidad. De manera similar, la cantidad de accidentes en superficies pavimentadas no demuestra que éstas sean más peligrosas, pues el archivo no contiene medidas de exposición como longitud de vialidades o número de desplazamientos.

6.6 Vehículos involucrados

Las trece columnas vehiculares indican cuántas unidades de cada categoría participaron en un percance. No son variables excluyentes: un mismo accidente puede involucrar automóviles, motocicletas u otros vehículos simultáneamente. En la vista auxiliar se contabilizaron 710,403 vehículos, con un promedio de 1.89 por accidente.

Categoría	Vehículos	Porcentaje	Accidentes donde aparece
Automóvil	436,681	61.47 %	302,962
Motocicleta	86,124	12.12 %	80,101
Camioneta de pasajeros	79,558	11.20 %	69,664
Camioneta de carga	51,106	7.19 %	47,432




Figura 4: Cantidad total de vehículos involucrados por categoría.

Cantidad de vehículos por accidente	Accidentes
1	61,910
2	294,083
3	16,313
4	2,083
5 o más	560

La mayoría de los accidentes, aproximadamente el 78.43 %, involucra exactamente dos vehículos.

6.7 Información del conductor

La exploración revisó las características disponibles del conductor presunto responsable. En cuanto al sexo registrado, 278,004 accidentes corresponden a hombres (74.14 %), 61,908 a mujeres (16.51 %) y 35,037 a casos en los que el conductor se fugó (9.34 %).

Antes de calcular estadísticas de edad fue necesario separar los códigos especiales. Dentro de la vista auxiliar de accidentes, el valor 0 aparece en 35,037 registros y corresponde a conductores fugados, el valor 99 aparece en 61,564 registros y representa edad desconocida. Después de excluir ambos códigos quedan 278,348 edades válidas entre 12 y 98 años. La media es de 37.85 años y la mediana de 35 años, la mayor concentración se observa entre los 18 y 49 años.




Figura 5: Distribución de edades válidas según el sexo registrado.

Las variables **ALIENTO** y **CINTURON** contienen una cantidad relevante de casos desconocidos. Por ello conviene distinguir el porcentaje sobre todos los accidentes del porcentaje calculado únicamente entre casos conocidos.

Variable	Valor	Accidentes	Porcentaje	Entre casos conocidos
Aliento alcohólico	Sí	15,915	4.24 %	6.24 %
Aliento alcohólico	No	239,170	63.79 %	93.76 %
Aliento alcohólico	Se ignora	119,864	31.97 %	No aplica
Cinturón	Sí	42,451	11.32 %	49.51 %
Cinturón	No	43,285	11.54 %	50.49 %
Cinturón	Se ignora	289,213	77.13 %	No aplica

En el caso de **ALIENTO**, la columna registra la presencia de aliento alcohólico, pero no permite

determinar el grado de consumo ni afirmar que el alcohol causó el percance. Para CINTURON, la proporción de información desconocida es particularmente alta y la variable sólo describe al conductor presunto responsable, no al resto de ocupantes.

6.8 Víctimas, severidad y estatus

Las variables de víctimas contabilizan personas heridas y fallecidas según su tipo de participación. Es importante distinguir estas cantidades del número de accidentes, pues un mismo percance puede afectar a más de una persona.

Tipo de persona	Fallecidas	Heridas
Conductores	2,614	45,442
Pasajeros	972	26,828
Peatones	901	11,509
Ciclistas	142	2,097
Otras personas	27	104
Total	4,656	85,980

Los conductores concentran el mayor número de víctimas, seguidos por pasajeros y peatones. En total, 4,188 accidentes registraron al menos una persona fallecida y 64,845 incluyeron al menos una persona herida. Las columnas de víctimas no especificadas tienen valor cero en todos los registros.




Figura 6: Personas heridas y fallecidas según su tipo de participación.

La variable CLASACC resume la severidad del accidente y será central para el aprendizaje supervisado.

Clasificación	Accidentes	Porcentaje
Sólo daños	306,841	81.84 %
No fatal	63,920	17.05 %
Fatal	4,188	1.12 %

La cantidad de accidentes fatales coincide con los 4,188 eventos que registran al menos una persona fallecida, de manera consistente con el diccionario oficial. La distribución evidencia un desbalance considerable, especialmente para la clase **Fatal**.




Figura 7: Cantidad de accidentes según su clasificación de severidad.

Para el agrupamiento, **CLASACC** deberá excluirse de las variables de entrada con el fin de formar grupos sin proporcionar previamente la severidad. Por otra parte, **ESTATUS** indica el estado administrativo de las cifras: 356,109 accidentes corresponden a cifras definitivas (94.98 %) y 18,840 a cifras corregidas (5.02 %). Como esta variable no describe el percance, se conserva únicamente como referencia durante la exploración.

6.9 Limpieza y generación del dataset final

A partir de los hallazgos anteriores se generó un nuevo archivo sin alterar el CSV original. Las transformaciones se aplicaron de manera secuencial:

Transformación	Justificación y resultado
Eliminar duplicados exactos	Se retiraron 871 filas repetidas. El conjunto pasó de 390,627 a 389,756 registros y no quedaron duplicados exactos.
Eliminar columnas constantes	Se retiraron COBERTURA, ANIO, NEMUERTO y NEHERIDO, ya que no aportan variación para comparar registros ni entrenar modelos.
Retirar Certificado cero	Se eliminaron 15,678 filas administrativas. Después de esta operación permanecen 374,078 accidentes.
Separar códigos de edad	Se crearon CONDUCTOR_FUGADO y EDAD_DESCONOCIDA. Los códigos 0 y 99 se reemplazaron por valores nulos en ID_EDAD para evitar tratarlos como edades reales.
Eliminar ESTATUS	Se retiró esta variable porque describe la publicación de las cifras, no las características del percance.

El resultado se exportó como `atus_anual_2024_limpio.csv`. Este archivo contiene 374,078 filas y 42 columnas, conserva únicamente accidentes reales y no presenta duplicados exactos.

La diferencia entre los 374,949 accidentes de la vista auxiliar y los 374,078 registros del archivo final se debe a que la primera todavía conservaba filas duplicadas. Al aplicar la limpieza, los únicos valores nulos restantes se encuentran en ID_EDAD: 34,920 registros corresponden a conductores fugados y 61,302 a edades desconocidas, para un total de 96,222 valores faltantes intencionales. Es decir, permanecen 277,856 edades válidas.

El dataset limpio constituye el punto de partida para el análisis estadístico, la clasificación supervisada y el agrupamiento.

7 Análisis Descriptivo y Estadístico con Interpretaciones

7.1 ATUS Anual 2024

Esta sección expone el estudio analítico de los registros de accidentes del dataset `atus_anual_2024_limpio.csv`. A continuación, se detalla un análisis exhaustivo del conjunto de datos debidamente depurado, con el objetivo de extraer patrones subyacentes, identificar métricas críticas y formular conclusiones fundamentadas sobre la siniestralidad vial en el territorio nacional.

7.1.1 Localización y Caracterización General

Con el propósito de orientar el análisis hacia las dimensiones más significativas del fenómeno, resulta imperativo construir un panorama general que evidencie las tendencias y factores determinantes de los siniestros viales. Esta aproximación inicial se fundamenta en la identificación de las categorías predominantes dentro del conjunto de datos.

Como parte del proceso de preparación de los datos, se implementó una estructura de homologación para mapear los identificadores numéricos (`ID_ENTIDAD`) con los nombres oficiales de las entidades federativas, garantizando así la correcta interpretación y legibilidad de las representaciones gráficas.

A partir de la evaluación de las medidas de posición (modas cuantitativas y frecuencias categóricas absolutas), se determinaron los siguientes perfiles de máxima recurrencia:

- **Edad del conductor:** La moda estadística se sitúa en los **30 años**.
- **Género del operador:** El sexo masculino registra la mayor tasa de reincidencia en los siniestros.
- **Distribución geográfica:** La entidad federativa con la mayor frecuencia absoluta de accidentes es **Nuevo León**.
- **Vector de transporte:** El tipo de vehículo motorizado con mayor afectación en los incidentes es el **Automóvil**.
- **Temporalidad horaria:** El pico crítico de ocurrencia de siniestros se concentra a las **14:00 horas**.

De los indicadores anteriores, es posible inferir que el perfil demográfico con mayor exposición al riesgo corresponde a conductores masculinos en etapas de plena actividad laboral y económica (en torno a la tercera década de vida), asociándose el fenómeno predominantemente al uso de vehículos particulares de tipología compacta.

Como se demostrará en los apartados subsecuentes mediante el contraste analítico de estas modas frente a la distribución global del dataset, cada una de estas variables críticas exhibe una probabilidad de ocurrencia significativamente superior respecto a sus categorías complementarias.

7.2 Evidencia Gráfica de Distribuciones

Las siguientes ilustraciones presentan el contraste empírico entre las categorías de máxima frecuencia y el resto del espacio muestral analizado.




Figura 8: Contraste de reincidencia según el sexo del conductor.




Figura 9: Frecuencia acumulada de siniestros por Entidad Federativa.

Proporción de Accidentes por Tipo de Vehículo




Figura 10: Siniestralidad según la tipología del vehículo involucrado.

Proporción de Accidentes según la Presencia de Aliento Alcohólico




Figura 11: Casos que presentaron un conductor con aliento alcohólico.

Nota: Los gráficos anteriores representan las distribuciones empíricas tras la remoción de valores atípicos y códigos de error.

7.3 Análisis de Variables Temporales y Demográficas Continuas

Existen dos dimensiones métricas adicionales dentro del conjunto de datos cuyo comportamiento aporta información crítica para un análisis exhaustivo de la siniestralidad: la edad de los conductores y la distribución horaria de los eventos. Con el objetivo de caracterizar el comportamiento central de estas variables y mitigar el efecto de los sesgos distribucionales, se determinaron los promedios aritméticos (μ) junto con sus respectivos puntos medios estadísticos, formalmente conocidos como medianas ($\tilde{x}$). El cálculo simultáneo de ambas medidas de tendencia central permite evaluar el grado de asimetría de las distribuciones. En contextos de seguridad vial, la discrepancia entre la media y la mediana evidencia si el fenómeno se encuentra concentrado en subgrupos específicos (como conductores jóvenes) o si responde a patrones estacionales de movilidad urbana a lo largo del día.




Figura 12: Distribución de densidad y dispersión de edades en los siniestros viales.




Figura 13: Fluctuación y densidad probabilística de los accidentes a lo largo del ciclo diario (0-23 hrs).

7.3.1 Análisis de Variabilidad y Dispersión Data-Driven

Las distribuciones continuas analizadas previamente permiten formular hipótesis sobre el comportamiento demográfico y temporal del fenómeno. No obstante, para garantizar la rigurosidad científica de las conclusiones referentes a los rangos predominantes, es indispensable respaldar el análisis mediante estimadores formales de dispersión. En este apartado se emplean el rango intercuartílico (IQR), la varianza (σ^2) y la desviación estándar (σ) para determinar con precisión la variabilidad en la edad de los implicados y definir las ventanas horarias de mayor criticidad vial.

Las métricas estadísticas calculadas a partir del conjunto de datos se consolidan en la Tabla 1.

Tabla 1: Métricas de Dispersión para las Variables Demográficas y Temporales

Variable Analizada	Rango Absoluto	Rango Intercuartílico (<i>IQR</i>)	Varianza (σ^2)	Desviación Estándar (σ)
Edad del Conductor	12.00 – 98.00 (86.0)	21.00 (Q_1 : 26.0 Q_3 : 47.0)	213.42	14.61
Hora del Siniestro	00:00 – 23:00 (23.0)	9.00 (Q_1 : 09:00 Q_3 : 18:00)	34.31	5.86

El análisis del rango absoluto en la dimensión demográfica revela umbrales biológicos extremos: el registro mínimo identifica a un conductor involucrado de apenas 12 años de edad, mientras que el límite superior corresponde a un individuo de 98 años. Por su parte, el rango en la dimensión temporal abarca la totalidad del ciclo de 24 horas, lo que denota preliminarmente la continuidad del riesgo de siniestralidad.

A pesar de la amplitud de los rangos absolutos, el Análisis Intercuartílico (*IQR*) y la desviación estándar permiten discriminar el comportamiento sistémico de los eventos aislados o atípicos. Esta concentración de la masa de datos se evalúa visualmente mediante diagramas de caja (*BoxPlots*), los cuales delimitan las fronteras de los valores esperados a través de los umbrales de los percentiles y los brazos adjuntos (*whiskers*).




Figura 14: Diagrama de caja para la detección de valores atípicos en la edad.




Figura 15: Diagrama de caja de la distribución del tiempo horario.

A partir de la evidencia gráfica proporcionada por los diagramas de caja, se derivan dos conclusiones sustantivas:

1. En la distribución por edades, se observa que la presencia de conductores menores de edad no constituye un evento estadísticamente aislado, sino una realidad recurrente dentro de los márgenes inferiores de la distribución. Por el contrario, los registros que superan el umbral de los 79 años se sitúan más allá de los brazos del diagrama, clasificándose formalmente como valores atípicos de baja significancia analítica.
2. El diagrama de horas corrobora la hipótesis de continuidad: la ausencia de valores atípicos en este vector demuestra que no existen franjas horarias en las que la ocurrencia de accidentes sea un fenómeno ajeno o extraordinario.

Finalmente, la integración de la desviación estándar respecto a la media permite modelar las regiones de máxima concentración probabilística del fenómeno. Las técnicas de estimación de densidad y dispersión

(Figuras 16 y 17) delimitan las zonas donde reside el comportamiento típico de la población.




Figura 16: Intervalo de dispersión típica para la edad del conductor.




Figura 17: Intervalo de dispersión típica para la temporalidad horaria.

En consecuencia, con base en el soporte paramétrico de la desviación estándar y el análisis de densidad visualizado, es matemáticamente válido formular las siguientes aseveraciones ejecutivas:

“La mayor concentración de siniestros viales involucra a conductores en un rango de edad productiva de entre los 22 y los 52 años.”

“La mayor densidad de los accidentes de tránsito terrestre se manifiesta de manera sostenida en el intervalo diurno comprendido entre las 07:00 y las 19:00 horas.”

7.3.2 Análisis de Heterogeneidad, Concentración y Entropía

A pesar de haber identificado las entidades federativas con mayor volumen absoluto de siniestros, resulta metodológicamente indispensable evaluar si los accidentes de tránsito terrestre constituyen un problema estructural generalizado o si responden a una centralización geoespacial y temporal específica. Asimismo, es imperativo determinar si la incidencia varía significativamente según el ciclo de los días de la semana o si manifiesta un comportamiento homogéneo. Para dilucidar estos patrones, se implementaron el Índice de Impureza de Gini (I_G) y la Entropía de Shannon (H).

La entropía mide cuantitativamente el grado de incertidumbre o desorden informacional en la distribución de una variable categórica. Matemáticamente, se define a partir de las frecuencias relativas o probabilidades asociadas p_i como:

$$H = - \sum_{i=1}^K p_i \log_2(p_i) \quad (1)$$



Un valor de entropía normalizada (H_{norm}) cercano a la unidad (1,0) indica una distribución perfectamente uniforme (máxima heterogeneidad y nula predictibilidad por categoría), mientras que un valor tendiente a cero (0,0) denota una concentración absoluta en una única clase. Por su parte, el Índice de Gini evalúa la dispersión de las frecuencias, operando de manera directamente proporcional a la entropía como métricas complementarias del mismo fenómeno subyacente.

Los indicadores numéricos obtenidos para las dimensiones geográfica y temporal se consolidan en la Tabla 2.

Tabla 2: Métricas de Heterogeneidad y Uniformidad para Entidades, Días y Meses

Dimensión de Análisis	Categorías (K)	Entropía de Shannon (H)	Entropía Normalizada	Índice de Gini (I_G)
Entidades Federativas	32	4.4374 (Máx: 5.0000)	0.8875	0.9290
Días de la Semana	7	2.8056 (Máx: 2.8074)	0.9994	0.8568
Meses del Año	12	3.5837 (Máx: 3.5850)	0.9997	0.9165

A partir de los resultados expuestos, se observa en las tres dimensiones un comportamiento con niveles de entropía e impureza marcadamente elevados, aproximándose de manera asintótica a sus máximos teóricos. Esto implica que la probabilidad de que un siniestro elegido al azar pertenezca a un estado, día o mes determinado tiende a la equiprobabilidad. Para evidenciar empíricamente este comportamiento, se contrastaron las frecuencias reales contra los umbrales ideales de uniformidad perfectas ($1/K$).


 Figura 18: Probabilidad empírica por Entidad Federativa vs. Uniformidad Teórica ($1/32$).

 Figura 19: Probabilidad empírica por Día de la Semana vs. Uniformidad Teórica ($1/7$).

Al evaluar la dimensión temporal semanal (Figura 19), las desviaciones respecto a la recta teórica son marginales ($H_{norm} = 0.9994$). Ello permite colegir con rigor estadístico que el día de la semana no constituye un factor determinante o predictivo para la ocurrencia de los siniestros, no obstante, se identifica un incremento sutil en la densidad probabilística durante los días viernes y sábado.

Por otra parte, el análisis geoespacial (Figura 18) fundamenta una conclusión analítica de alto valor: si bien ciertas entidades federativas exhiben ligeras fluctuaciones relativas debido a sus densidades demográficas o escala de infraestructura vial, la masa probabilística se distribuye de manera lo suficientemente homogénea en el territorio nacional como para catalogar a la siniestralidad vial como un problema estructural generalizado que afecta de forma transversal a toda la federación.

Con el propósito de validar si el factor macro-temporal introduce variaciones de carácter estacional, se replicó el modelado sobre la variable de mensualidad (Figura 20).




Figura 20: Probabilidad empírica por Mes del Año vs. Uniformidad Teórica (1/12).

Los resultados del vector mensual ratifican las conclusiones previas: la entropía normalizada de 0,9997 confirma que la distribución se adhiere de forma casi exacta a un escenario perfectamente homogéneo. Por consiguiente, con base en los registros oficiales del INEGI, se concluye que no existe una relación estadísticamente significativa ni patrones de estacionalidad cíclica entre la frecuencia de accidentes de tránsito y el mes del año en que acontecen.

7.3.3 Análisis de Concentración e Inequidad Distribucional

Habiendo constatado los elevados niveles de entropía e idéntica dispersión en las dimensiones macro-temporales y geoespaciales, resulta imperativo reorientar el estudio hacia aquellas variables cuantitativas que previamente exhibieron una variabilidad interna significativa: la edad de los conductores y la temporalidad horaria de los siniestros. El propósito de este apartado es evaluar el grado de concentración del fenómeno dentro de los rangos demográficos y ventanas de tiempo previamente delimitados, determinando la intensidad con la que ciertos subgrupos acumulan la siniestralidad general.

Para cuantificar esta asimetría, se recurre al Coeficiente de Concentración de Gini (G) combinado con el modelado geométrico de las *Curvas de Lorenz*. En este contexto analítico, la Curva de Lorenz contrasta el porcentaje acumulado de categorías (eje de abscisas) frente al porcentaje acumulado de siniestros viales (eje de ordenadas), midiendo de forma explícita el distanciamiento respecto a la recta de equidad perfecta o distribución uniforme. Este enfoque matemático permite validar de forma empírica si factores sistémicos urbanos —como los intervalos de máxima demanda vehicular o *horas pico*— ejercen un efecto de atracción sobre la ocurrencia de los accidentes.

El procesamiento de las estructuras continuas arrojó los siguientes coeficientes de concentración:

- **Coeficiente de Gini para las Horas del Día:** $G_{\text{hora}} = 0,2346$
- **Coeficiente de Gini para las Edades de los Conductores:** $G_{\text{edad}} = 0,5038$

Los valores obtenidos evidencian comportamientos diferenciados y de alto valor interpretativo. En el vector demográfico, el coeficiente de 0,5038 refleja una concentración marcadamente elevada. Este indicador matemático corrobora que un sector estrictamente delimitado de la población (los conductores jóvenes y en etapas tempranas de la adultez) acapara de manera desproporcionada la mayor densidad de los registros de accidentes.

Por otra parte, si bien el indicador asociado a la distribución horaria ($G = 0,2346$) exhibe una magnitud cuantitativamente menor, representa un umbral estadísticamente significativo. Su valor es lo suficientemente robusto como para confirmar que el riesgo vial no es homogéneo a lo largo del ciclo diario, sino que se suspende de forma preferencial sobre franjas de tiempo específicas. La manifestación

visual de estas asimetrías se presenta a través de las Curvas de Lorenz de las siguientes figuras.




Figura 21: Curva de Lorenz para la distribución acumulada de accidentes por hora.




Figura 22: Curva de Lorenz para la distribución acumulada de accidentes por edad.

La evidencia gráfica proporcionada por las Curvas de Lorenz convalida de forma contundente las intuiciones analíticas formuladas en las descripciones de localización iniciales. En la dimensión temporal, se observa geométricamente cómo la curva acelera su pendiente cóncava a partir de las primeras horas de la mañana y la mitad del día, intervalos que coinciden con los flujos de máxima saturación vial. En paralelo, el comportamiento de la curva de edad expone una segregación clara hacia la población joven. La integración de ambos hallazgos paramétricos permite estructurar un modelo explicativo sólido que vincula la siniestralidad con las dinámicas de la actividad cotidiana. Es posible concluir con rigor estadístico que la mayor densidad de los siniestros viales en el territorio nacional ocurre durante los periodos de mayor dinamismo socioeconómico de las ciudades, es decir, en aquellas ventanas horarias donde la población económicamente activa y estudiantil —constituida prevalentemente por varones en edad laboral o de formación profesional— tiene la necesidad imperativa de desplazarse hacia sus respectivos centros de trabajo o instituciones educativas.

8 Análisis de Correlaciones, Severidad y Factores de Riesgo

A lo largo de las etapas previas del presente estudio, se omitió deliberadamente el uso de los vectores de información que cuantifican las consecuencias directas de los siniestros: el volumen de lesionados y las pérdidas humanas. El conjunto de datos documenta de forma desagregada estas afectaciones a través de las variables CONDMUERTO, CONDHHERIDO, PASAMUERTO, PASAHERIDO, PEATMUERTO, PEATHERIDO, CICLMUERTO, CICLHERIDO, OTROMUERTO y OTROHERIDO, permitiendo mapear el daño físico sufrido por conductores, pasajeros, peatones, ciclistas y otros actores viales, complementándose con la bandera binaria de evasión legal CONDUCTOR_FUGADO.

El propósito de reservar estas métricas para la fase de correlación radica en la posibilidad de cruzar las variables contextuales y demográficas previamente consolidadas con la severidad del impacto. Cabe destacar que el proceso de depuración del dataset garantiza la robustez de este análisis mediante el uso estratégico de la variable categórica CLASACC, la cual clasifica de forma unívoca el desenlace del siniestro en categorías excluyentes (“Fatal”, “No fatal” y “Sólo daños”), mitigando así el ruido estadístico inducido por registros indeterminados.

8.1 Evaluación Lineal de la Siniestralidad Global

Al tratarse de variables cuantitativas y banderas binarias, se procedió al cálculo de los coeficientes de correlación de Pearson y a su posterior representación en un mapa de calor (*HeatMap*) global,

visualizado en la Figura 23.




Figura 23: Matriz de correlación de Pearson para variables temporales, demográficas y de afectación física.

El mapa de calor evidencia, en primera instancia, interacciones lineales predecibles y de correspondencia directa, tales como la colinealidad positiva entre el volumen de conductores afectados y los pasajeros lesionados o fallecidos, lo cual responde a la naturaleza geométrica y de ocupación del espacio vehicular durante un impacto. No obstante, más allá de estas relaciones mecánicas evidentes, el análisis revela patrones conductuales de profunda relevancia criminológica y de seguridad vial.

8.1.1 Modelado de Evasión Conductual según la Severidad del Siniestro

En la matriz de correlación lineal, el coeficiente asociado a la toma de decisiones del operador frente a la gravedad del incidente puede verse atenuado por la asimetría de las frecuencias. Sin embargo, al realizar un análisis de tablas de contingencia normalizadas por fila a un nivel micro, se descubre que la severidad del siniestro ejerce una influencia drástica sobre la probabilidad de que el conductor abandone de forma ilícita la escena (*pánico de fuga*).




Figura 24: Análisis porcentual del comportamiento de fuga del conductor según la clasificación de severidad del accidente.

Como se ilustra en la Figura 24, mientras que el operador muestra una tendencia estadística persistente a permanecer en el sitio del percance cuando este se limita a “Sólo daños” o lesiones no letales (“No fatal”), la probabilidad empírica de registrar la fuga del conductor se incrementa significativamente —mostrando un repunte cercano al 20 %— en escenarios donde el desenlace es catalogado como “Fatal”. Este comportamiento describe una correlación conductual de evasión condicionada por la magnitud de las implicaciones legales y penales punitivas asociadas al homicidio culposo en el tránsito.

8.2 Factores de Riesgo Condicionados y Tipología Vehicular

Con el objetivo de profundizar en la interacción del fenómeno y superar las limitaciones del análisis bivariado simple, se incorporaron al modelo dos dimensiones adicionales: la cuantificación por tipología de vector de transporte involucrado (AUTOMOVIL, MOTOCICLET, etc.) y dos variables dicotómicas de conducta de riesgo: ALIENTO_SI (presencia de aliento alcohólico) y CINTURON_NO (desuso de los sistemas de retención pasiva). El resultado de esta matriz avanzada de factores concurrentes se expone en la Figura 25.

Matriz de Correlación Avanzada: Factores de Riesgo, Tipos de Vehículo y Víctimas




Figura 25: Matriz de correlación avanzada: Interacción entre vectores de transporte, factores de riesgo conductual y severidad de las víctimas.

La evaluación de los coeficientes de esta matriz avanzada revela fenómenos de alto valor para el diseño de políticas públicas de prevención vial:

1. **Vulnerabilidad y Vector de Transporte:** El cruce entre la variable MOTOCICLET y los vectores de afectación física directa exhibe la correlación positiva más robusta del sistema respecto a daños corporales. La presencia de motocicletas en el siniestro correlaciona de manera intensa y directa con la variable CONDHHERIDO, registrando asimismo una asociación positiva con la letalidad (CONDMUERTO). Ello fundamenta de forma paramétrica la vulnerabilidad intrínseca de este modo de transporte en el entorno urbano en comparación con los vehículos de tipología compacta o de carga, cuyas estructuras disipan la energía cinemática del impacto.
2. **La Paradoja del Aliento Alcohólico y la Gravedad:** Contrario a las asunciones teóricas tradicionales, la correlación lineal directa entre el estado de ebriedad aparente y los índices de mortandad inmediata en el sitio del siniestro resulta estadísticamente inconclusa dentro de la matriz general, sugiriendo que el alcohol actúa de forma indirecta como un catalizador de velocidad o pérdida de control antes que como un factor lineal de letalidad aislada.
3. **Dinámicas de Evasión y Factores de Riesgo:** El mapa de calor avanzado desvela dos anomalías conductuales altamente consistentes:

- Se observa una correlación negativa sutil entre la presencia de aliento alcohólico y la fuga inmediata, indicando una menor tasa de abandono de la escena por parte de conductores intoxicados, fenómeno atribuible a la disminución de reflejos, letargo cognitivo o incapacidad motriz para operar el vehículo tras la colisión.
- Por el contrario, la variable `CINTURON_NO` (desuso del cinturón de seguridad) muestra una correlación positiva con la bandera de fuga. Este comportamiento perfila de forma nítida la existencia de un subgrupo de conductores con un patrón sistemático de desapego a las normas jurídicas y de seguridad vial (*conducta infractora integral*), donde la omisión de las medidas de seguridad básicas coexiste con la propensión a la evasión de la justicia.

Gracias al riguroso proceso de limpieza de datos aplicado a las banderas de control y a la representatividad muestral por el volumen de incidencia del INEGI, se descarta que estas tendencias correspondan a artefactos estadísticos o ruido aleatorio, consolidándose como patrones empíricos altamente recurrentes del ecosistema vial nacional.

9 Modelo Supervisado de Clasificación

El pipeline de clasificación supervisada se implementó en el módulo `src/supervised/` siguiendo una estrategia de complejidad creciente: se parte de una línea base trivial y se avanza hacia modelos más sofisticados, evaluando en cada etapa si la complejidad adicional se justifica con una mejora medible en las métricas.

A continuación se describen los modelos utilizados:

- **Línea base trivial** (`DummyClassifier`): clasifica siempre la clase mayoritaria (**Solo danos**). Establece el piso mínimo que cualquier modelo real debe superar.
- **Regresión Logística** (`LogisticRegression`): modelo lineal interpretable como segunda referencia. No logró converger con el volumen y dimensionalidad del dataset, lo que sugiere que la relación entre las variables predictoras y la severidad no es linealmente separable.
- **Random Forest** (`RandomForestClassifier`): ensamble de árboles de decisión robusto frente al desbalance de clases. Produce importancia de características de forma nativa, insumo directo para la etapa de agrupamiento no supervisado.
- **XGBoost** (`XGBClassifier`): modelo de gradiente potenciado con aceleración GPU. Generalmente supera a Random Forest en datasets tabulares con desbalance severo y fue seleccionado como modelo final tras el ajuste de umbral de clasificación.

La métrica principal de comparación es el **F1-score macro**, que pondera por igual las tres clases independientemente de su frecuencia. El accuracy no es una métrica confiable para este problema: un clasificador que ignore completamente **Fatal** y **No fatal** alcanza 82 % de accuracy sin ningún valor predictivo real.

9.1 Planteamiento y variable objetivo

El modelo supervisado tiene como objetivo predecir la severidad de un accidente de tránsito a partir de las condiciones en que ocurrió, sin utilizar información sobre sus consecuencias. La variable objetivo es **CLASACC**, que distingue tres niveles de severidad:

Clase	Registros	Porcentaje
Sólo daños	306,088	81.82 %
No fatal	63,809	17.06 %
Fatal	4,181	1.12 %

El desbalance severo entre clases, especialmente la clase **Fatal** con apenas el 1.12 % de los registros, es el principal desafío técnico del modelo y guía todas las decisiones de preprocesamiento y evaluación posteriores.

9.2 Selección de variables de entrada

Las variables de entrada se seleccionaron con base en el EDA y el dominio del problema. El criterio fue incluir únicamente variables que describen el *contexto* del accidente, excluyendo explícitamente las que

describen sus consecuencias.

9.2.1 Variables excluidas

Variable(s)	Razón
CONDMUERTO, CONDHERIDO, PASAMUERTO, PASAHERIDO, PEATMUERTO, PEATHERIDO, CICLMUERTO, CICLHERIDO, OTROMUERTO, OTROHERIDO	<i>Data leakage</i> : son consecuencias directas del accidente y determinan la variable objetivo. En producción no estarían disponibles al momento de clasificar.
TOTAL_MUERTOS	Variable derivada de las anteriores. Mismo problema de leakage.
NOM_MUN	Cardinalidad de 1,435 categorías. El one-hot encoding generaría más de 1,400 columnas con escasa señal por columna.
ID_MINUTO, ID_DIA	Granularidad excesiva sin relación causal con la severidad.
TRANVIA, FERROCARRI, OTROVEHIC	Prácticamente sin variación (2 valores únicos).

9.2.2 Transformaciones aplicadas

Las 26 variables seleccionadas se transformaron mediante el **Preprocessor** descrito en la sección de arquitectura, produciendo 81 features numéricas listas para el modelado.

Grupo	Variables	Transformación
Numéricas	ID_EDAD, conteos de vehículos	SimpleImputer (mediana) → StandardScaler . La imputación se ajusta exclusivamente sobre el conjunto de entrenamiento para evitar <i>data leakage</i> .
Binarias	CONDUCTOR_FUGADO, EDAD_DESCONOCIDA	Passthrough: No requirieron transformación.
Categorías	TIPACCID, CAUSAACCI, SEXO, ALIENTO, CINTURON, DIASEMANA, URBANA, SUBURBANA, CAPAROD, NOM_ENT	OneHotEncoder(drop='first') para evitar multicolinealidad perfecta.
Temporales cíclicas	MES, ID_HORA	Encoding seno/coseno mediante CyclicEncoder personalizado. Preserva la continuidad circular: la hora 23 está cerca de la hora 0, y diciembre cerca de enero.

9.3 División de los datos

Los datos se dividieron en 80 % entrenamiento (299,262 registros) y 20 % prueba (74,816 registros) con **random_state=42** y **stratify=y**, garantizando que la distribución de **CLASACC** se preserve en ambos conjuntos. La división se realizó **antes** de ajustar el preprocesador, y este se ajustó exclusivamente sobre el conjunto de entrenamiento.

9.4 Modelos entrenados

Se entrenaron tres modelos en orden creciente de complejidad. En todos los casos el desbalance de clases se compensó con `class_weight='balanced'`, que ajusta el peso de cada clase inversamente proporcional a su frecuencia.

9.4.1 Línea base trivial

Un `DummyClassifier` que siempre predice `Solo dañños` establece el piso mínimo de comparación. Obtiene aproximadamente 82 % de accuracy con 0 % de recall en `Fatal` y `No fatal`, evidenciando que el accuracy no es una métrica confiable para este problema.

9.4.2 Random Forest

Se entrenó un `RandomForestClassifier` con validación cruzada de 3 folds y búsqueda de hiperparámetros mediante `GridSearchCV`.

Elemento	Valor
CV F1-macro (3 folds)	0.5239 ± 0.0040
Mejor F1-macro (GridSearch)	0.5482
Mejores hiperparámetros	<code>max_depth=None, min_samples_leaf=2, n_estimators=100</code>
Tiempo total de entrenamiento	≈ 8 minutos (CPU)

9.4.3 Importancia de características: Random Forest




Figura 26: Top 25 variables más importantes — Random Forest.

Random Forest distribuye la importancia de forma mas uniforme que XGBoost, destacando variables temporales y demograficas que el segundo modelo no considera relevantes.

`TIPACCID_Colision con vehiculo automotor` encabeza el ranking con 8 %, seguida por `ID_EDAD` (7.3 %) confirmando la relacion entre edad y severidad identificada en el analisis descriptivo. Las componentes ciclicas de la hora (`ID_HORA_COS` e `ID_HORA_SEN`, ≈ 6 % cada una) representan en conjunto ≈ 12 % de la importancia total, validando la decision de aplicar encoding ciclico para capturar patrones como la mayor gravedad de accidentes nocturnos. `MES_SEN` y `MES_COS` (≈ 5 % cada uno) sugieren estacionalidad en la severidad que el encoding ciclico logra preservar correctamente.

`MOTOCICLET` y `AUTOMOVIL` (≈ 4.5 % cada uno) confirman la relevancia del tipo de vehiculo. `TIPACCID_Colision con peaton` (3.5 %) y `NOM_ENT_Nuevo Leon` (2.7 %) refuerzan hallazgos ya identificados en el analisis descriptivo. Finalmente, `ALIENTO_Se ignora` (2 %) y `CINTURON_Se ignora` (1.4 %) tienen poder predictivo propio a pesar de ser categorias de informacion no disponible, confirmando que la decision de conservarlas con sus tres categorias originales fue correcta.

9.4.4 XGBoost

Se entrenó un `XGBClassifier` con aceleración GPU (`device='cuda'`) sobre una NVIDIA GeForce RTX 3080 con 16 GB de VRAM y CUDA 12.4.

Elemento	Valor
CV F1-macro (3 folds)	0.5005 $\pm$ 0.0016
Mejor F1-macro (GridSearch)	0.5253
Mejores hiperparámetros	<code>colsample_bytree=0.8, learning_rate=0.2, max_depth=6, n_estimators=300, subsample=0.8</code>
Tiempo total de entrenamiento	$\approx$ 25 minutos (GPU)

9.4.5 Importancia de características: Xgboost




Figura 27: Top 25 variables más importantes — XGBoost (modelo final).

El ranking de XGBoost presenta diferencias relevantes respecto al de Random Forest, sugiriendo que ambos modelos capturan aspectos distintos del problema.

`TIPACCID_Colision con peaton` domina con ≈ 27 % de importancia, posicionándose como el predictor

más determinante de severidad, en Random Forest ocupaba la cuarta posición. Le siguen la colisión con vehículo automotor (10 %) y MOTOCICLET (7 %), consolidando el tipo de accidente y el vehículo involucrado como los factores de mayor peso predictivo.

En contraste, ID_EDAD, ID_HORA y MES — variables críticas en Random Forest, no aparecen entre las 25 más importantes de XGBoost. En su lugar, múltiples entidades federativas (Nuevo León, Sinaloa, Yucatán, Quintana Roo, Coahuila, Puebla, Ciudad de México) ocupan posiciones relevantes, indicando que XGBoost asigna mayor peso a los patrones geográficos.

Destacan también BICICLETA, PASCAMION y CONDUCTOR_FUGADO, ausentes en Random Forest. Los dos primeros son consistentes con la vulnerabilidad física de ciclistas y pasajeros de camión, el tercero confirma que la fuga del conductor se asocia con accidentes de mayor gravedad, hallazgo coherente con el análisis de correlaciones de la sección anterior.

9.5 Evaluación con umbral por defecto

Las métricas se calcularon sobre el conjunto de prueba (74,816 registros) con el umbral de clasificación por defecto (0.5).

Modelo	Accuracy	Precision macro	Recall macro	F1 macro
Línea base	0.8182	0.2727	0.3333	0.2985
Random Forest	0.8193	0.5259	0.5794	0.5453
XGBoost	0.8727	0.6473	0.4946	0.5265

Con umbral por defecto, **Random Forest** obtiene el mejor F1-macro (0.5453). Sin embargo, ambos modelos presentan recall muy bajo en la clase **Fatal**: 17.94 % en Random Forest y apenas 4.67 % en XGBoost. Las curvas ROC revelan que esta limitación no se debe a falta de capacidad discriminativa, ambos modelos obtienen $AUC \approx 0.88$ para **Fatal**, sino a que el umbral por defecto está mal calibrado para una clase tan minoritaria.




Figura 28: Matriz de confusión — Random Forest (umbral por defecto).




Figura 29: Matriz de confusión — XGBoost (umbral por defecto).

9.5.1 Interpretación de matrices y curvas ROC

Las matrices de confusión permiten observar el comportamiento operativo del clasificador bajo un umbral específico: muestran cuántos casos quedan asignados a cada clase y, por tanto, exponen directamente los errores de clasificación que afectan a **Fatal**. En cambio, las curvas ROC evalúan la capacidad de ordenamiento probabilístico del modelo sin fijar todavía un umbral de decisión. Por esta razón ambas visualizaciones son complementarias: una matriz puede verse débil para la clase minoritaria aunque la curva ROC indique que el modelo sí asigna probabilidades más altas a muchos casos fatales que a los no fatales.




Figura 30: Curvas ROC por clase — Random Forest.




Figura 31: Curvas ROC por clase — XGBoost.

La lectura principal de las Figuras 30 y 31 es que ambos modelos superan con claridad al clasificador aleatorio en las tres clases. La clase **Fatal** alcanza AUC cercano a 0.86–0.88, lo cual indica una capacidad razonable para ordenar los accidentes según probabilidad de fatalidad. Sin embargo, esa capacidad no se traduce automáticamente en buen recall cuando se usa el umbral estándar de 0.5, porque la distribución de probabilidades queda dominada por las clases mayoritarias. Esta diferencia justifica el análisis de umbral posterior.

9.6 Ajuste de umbral de clasificación

El AUC elevado de ambos modelos indica que pueden tener mejor capacidad para ordenar los casos por probabilidad de fatalidad, pero el umbral por defecto (0.5) no aprovecha esta capacidad para la clase minoritaria. Se realizó una búsqueda sistemática del umbral óptimo para **Fatal** evaluando valores entre 0.01 y 0.50 en incrementos de 0.01, seleccionando el que maximiza el F1-macro sobre el conjunto de prueba.

Modelo	Umbral óptimo	F1 macro default	F1 macro ajustado	Mejora
Random Forest	0.44	0.5453	0.5497	+0.0044
XGBoost	0.15	0.5265	0.5636	+0.0371

Random Forest encuentra su umbral óptimo en 0.44, cercano al valor por defecto, lo que indica que ya estaba bien calibrado. XGBoost, en cambio, requiere un umbral de 0.15 para aprovechar su capacidad discriminativa, evidenciando que con el umbral por defecto estaba fuertemente sesgado hacia las clases mayoritarias.

Con umbral ajustado, XGBoost (0.5636) supera a Random Forest (0.5497), lo que determina la selección del modelo final.

9.6.1 Comportamiento del F1-macro al modificar el umbral

El barrido de umbrales permite identificar si la mejora proviene de un cambio local y estable o de una fluctuación aislada. En Random Forest, la curva muestra un máximo cercano al umbral por defecto, por lo que el modelo no requiere una corrección fuerte para equilibrar las clases. En XGBoost, la curva evidencia un cambio más pronunciado: al reducir el umbral de `Fatal` a 0.15, el modelo aprovecha mejor la separación probabilística observada en la curva ROC.




Figura 32: Búsqueda de umbral para la clase `Fatal` — Random Forest.




Figura 33: Búsqueda de umbral para la clase `Fatal` — XGBoost.

La comparación entre las Figuras 32 y 33 refuerza la selección final: Random Forest mejora de forma

marginal al ajustar el umbral, mientras que XGBoost obtiene una ganancia mayor en F1-macro. Esto sugiere que XGBoost no estaba limitado por ausencia de señal, sino por una regla de decisión demasiado conservadora para la clase minoritaria.

9.7 Modelo final — XGBoost con umbral ajustado

9.7.1 Métricas finales

Clase	Precision	Recall	F1-score	Support
Fatal	0.21	0.22	0.21	836
No fatal	0.73	0.44	0.55	12,762
Sólo daños	0.89	0.97	0.93	61,218
Macro avg	0.61	0.54	0.5636	74,816
Weighted avg	0.86	0.87	0.86	74,816

El ajuste de umbral incrementó el recall de **Fatal** de 4.67 % a 21.53 %, pasando de identificar correctamente 39 a 180 accidentes fatales de los 836 del conjunto de prueba. Las clases **No fatal** y **Solo danos** prácticamente no se ven afectadas.




Figura 34: Matriz de confusión — XGBoost con umbral ajustado para **Fatal**.

La matriz final de la Figura 34 permite interpretar el costo de la decisión. El modelo gana sensibilidad sobre la clase **Fatal**, pero lo hace aceptando más confusiones entre accidentes fatales y no fatales. Desde una perspectiva de prevención, este intercambio es defendible porque el objetivo del ajuste no es maximizar el número total de aciertos, sino reducir la probabilidad de pasar por alto eventos de mayor severidad. Aun así, el resultado debe leerse con cuidado: el modelo mejora la detección relativa de accidentes fatales, pero no alcanza un recall suficientemente alto como para ser usado como sistema de decisión automática.

9.8 Persistencia y reutilización

El modelo final se serializó en `models/xgboost.joblib` mediante `joblib`. El notebook `demo.ipynb` demuestra que puede cargarse y utilizarse para predicciones nuevas sin acceder al dataset original ni reentrenar, cumpliendo con el requisito de persistencia del proyecto.

```

from src.supervised.trainer import Trainer
from src.supervised.preprocessor import Preprocessor
from src.supervised.evaluator import Evaluator

model      = Trainer.load_model('xgboost', output_dir='models')
prep       = Preprocessor()
evaluator  = Evaluator(prepare.target_classes)

X_new_transformed = prep.transform(X_new)
y_probs          = model.predict_proba(X_new_transformed)
y_pred           = evaluator.predict_with_threshold(y_probs, threshold=0.15)
y_labels         = prep.inverse_transform_target(y_pred)

```

9.9 Limitaciones

- **Recall limitado en Fatal.** A pesar del ajuste de umbral, el modelo sigue fallando en el 78 % de los accidentes fatales. Esto no es una falla del umbral sino una consecuencia estructural del desbalance extremo (1.12 %). Como trabajo futuro se podría explorar técnicas de oversampling (*SMOTE*) sobre la clase **Fatal** antes del entrenamiento.
- **Ausencia de medidas de exposición.** El dataset no contiene volumen de tránsito ni kilómetros recorridos, por lo que las predicciones describen accidentes registrados pero no tasas de riesgo ajustadas.
- **Variables con alta proporción de datos desconocidos.** **CINTURON** (77 % “Se ignora”) y **ALIENTO** (32 % “Se ignora”) limitan el poder predictivo de estas variables, que de otro modo serían potencialmente relevantes para la severidad.

10 Agrupamiento no supervisado

10.1 Planteamiento y motivación

¿Existen grupos naturales de accidentes que compartan condiciones similares, independientemente de su gravedad?

Para responder a esta pregunta se aplicó agrupamiento no supervisado mediante *K-Means* sobre el conjunto limpio `atus_anual_2024_limpio.csv` (374,078 registros, 42 columnas). El análisis completo se implementa en el módulo `src/clustering/` y se documenta en el notebook `agrupamiento.ipynb`.

El modelo supervisado recibe la etiqueta de severidad (**CLASACC**) como variable objetivo, el agrupamiento, en cambio, no la recibe en ningún momento. Los grupos se forman exclusivamente a partir de variables que describen el *contexto* del accidente. La relación de cada grupo con **CLASACC** se evalúa únicamente como validación posterior, lo que permite confirmar que los grupos capturan estructura real y no artefactos del algoritmo.

10.2 Selección y exclusión de variables

La decisión metodológica más importante del análisis fue determinar qué variables entran al espacio de agrupamiento. El criterio fue el siguiente: se incluyen las variables que describen el *contexto* del accidente, se excluyen las variables que describen sus *consecuencias*.

10.2.1 Variables de entrada

Se emplearon 27 variables agrupadas en cinco categorías:

Grupo	Tipo	Variables
Temporales	Numéricas y categórica	MES, ID_HORA (numéricas); DIASEMANA (categórica con codificación <i>one-hot</i>).
Zona del accidente	Categóricas	URBANA, SUBURBANA.
Tipo y causa	Categóricas	TIPACCID, CAUSAACCI, CAPAROD.
Vehículos involucrados	Numéricas	AUTOMOVIL, CAMPASAJ, MICROBUS, PASCAMION, OMNIBUS, TRANVIA, CAMIONETA, CAMION, TRACTOR, FERROCARRI, MOTOCICLET, BICICLETA, OTROVEHIC.
Conductor	Categóricas y numéricas	SEXO, ALIENTO, CINTURON (categóricas); ID_EDAD, CONDUCTOR_FUGADO, EDAD_DESCONOCIDA (numéricas).

10.2.2 Variables excluidas y justificación

Variable(s) excluida(s)	Razón
CLASACC	Variable objetivo del modelo supervisado. Si se incluyera, el agrupamiento simplemente reconstruiría la severidad ya conocida en lugar de descubrir perfiles independientes.
CONDMUERTO, CONDHERIDO, PASAMUERTO, PASAHERIDO, PEATMUERTO, PEATHERIDO, CICLMUERTO, CICLHERIDO, OTROMUERTO, OTROHERIDO	Son las consecuencias directas del accidente. Incluir las equivale a incluir CLASACC de forma encubierta, pues determinan directamente la severidad del evento.
NOM_ENT, NOM_MUN	Alta cardinalidad (32 y 1,435 categorías respectivamente). La codificación <i>one-hot</i> generaría más de 1,400 columnas adicionales con escasa señal por columna.
ID_MINUTO, ID_DIA	Granularidad excesiva para describir un perfil de accidente. El minuto exacto o el día del mes no discriminan contextos operativamente distintos.

10.3 Preprocesamiento

Las 27 variables de entrada se transformaron mediante un `ColumnTransformer` de *scikit-learn*, implementadas en `AccidentClusteringPreprocessor` de `clustering/preprocessor.py`.

Rama	Transformaciones
Numérica (18 variables)	(1) Imputación por mediana mediante <code>SimpleImputer</code> . Esta operación cubre los 96,222 valores faltantes de <code>ID_EDAD</code> , preservando la información de fuga mediante las banderas binarias <code>CONDUCTOR_FUGADO</code> y <code>EDAD_DESCONOCIDA</code> . (2) Estandarización con <code>StandardScaler</code> : media cero y desviación estándar unitaria. Paso obligatorio para <i>K-Means</i> , ya que el algoritmo calcula distancias euclidianas y es sensible a la escala de las variables.
Categorica (9 variables)	(1) Imputación por moda mediante <code>SimpleImputer</code> . (2) Codificación <i>one-hot</i> con <code>OneHotEncoder</code> (<code>handle_unknown='ignore'</code> , <code>sparse_output=False</code>). El parámetro <code>handle_unknown='ignore'</code> garantiza que categorías no vistas durante el entrenamiento generen vectores de ceros en lugar de lanzar una excepción, lo que permite reutilizar el modelo con registros nuevos.

El resultado de la transformación es una matriz densa de **374,078 filas** $\times$ **60 columnas**, que constituye el espacio de entrada para el algoritmo de agrupamiento.

Los cálculos exploratorios (curva del codo, coeficiente de silueta, PCA, t-SNE) se realizaron sobre una muestra de 40,000 registros (`random_state=42`). Esta decisión tiene una justificación: el cómputo del coeficiente de silueta sobre los 374,078 registros requeriría una matriz de distancias de ~ 140 millones de entradas. El modelo final se entrena sobre el conjunto completo.

10.4 Selección del número de grupos

Para determinar el número de grupos k se emplearon dos criterios complementarios sobre la muestra de 40,000 registros.

10.4.1 Método del codo

La inercia mide la suma de las distancias cuadráticas de cada punto a su centroide más cercano, valores más bajos indican grupos más compactos. Se calculó para $k \in \{2, \dots, 10\}$:

k	Inercia	Silueta
2	806,656	0.1921
3	765,158	0.0800
4	721,335	0.1037
5	687,205	0.1204
6	649,590	0.1456
7	612,342	0.1492
8	565,118	0.1381
9	536,051	0.1602
10	498,718	0.1821

La inercia descende de forma monótona y casi lineal: una reducción acumulada del 38 % entre $k = 2$ y $k = 10$, sin ningún quiebre marcado. Este comportamiento gradual es el esperado en espacios de alta dimensionalidad y dispersos (60 columnas tras la codificación *one-hot*): la distancia euclidiana se diluye entre muchos ejes y la inercia pierde poder discriminante.




Figura 35: Método del codo: inercia de K-Means para $k \in \{2, \dots, 10\}$.




Figura 36: Coeficiente de silueta para $k \in \{2, \dots, 10\}$.

10.4.2 Coeficiente de silueta

El coeficiente de silueta mide qué tan bien separado está cada punto de su propio cluster respecto al vecino más cercano, varía en $[-1, 1]$, con valores más altos indicando mejor separación. El máximo se alcanza en $k = 2$ (0.1921), pero corresponde a una partición trivial: accidentes con motocicleta frente a todo lo demás. Esta separación maximiza la distancia geométrica pero no aporta valor analítico, pues el comportamiento diferencial de las motocicletas era ya conocido del análisis descriptivo.

10.4.3 Elección de $k = 4$

Ninguno de los dos criterios señala un óptimo único. La silueta en $k = 4$ es 0.1037, valor modesto en escala absoluta pero razonable para datos reales de alta dimensionalidad. Se priorizó la interpretabilidad: $k = 4$ es el menor número de grupos que produce cuatro perfiles operativamente distintos (conductores fugados, colisiones con camioneta, accidentes con motocicleta y colisiones multi-automóvil) manteniendo una silueta aceptable.

10.5 Comparación de algoritmos

Para justificar la elección de *K-Means* se compararon tres algoritmos sobre la misma muestra de 40,000 registros. Esta comparación se realizó mediante el patrón de diseño *Strategy*, descrito en la sección de arquitectura.

Algoritmo	Grupos	Ruido	Silueta	Observación
<i>K-Means</i> ($k = 4$)	4	0	0.104	Balanceado, interpretable y escalable a 374k registros.
Aglomerativo (Ward, $k = 4$)	4	0	0.228	Mejor silueta, pero complejidad $\mathcal{O}(n^2)$: inviable a escala real. No produce método predict .
DBSCAN ($\varepsilon = 2,0$, $min_samples=15$)	44	7,636	0.186	Fragmenta en 44 microgrupos, $\sim 19\%$ de la muestra como ruido. No ofrece predict .

Por qué se descartó el aglomerativo. Su coeficiente de silueta (0.228) es el doble que el de *K-Means*, pero el algoritmo tiene complejidad $\mathcal{O}(n^2)$ en memoria. Para los 374,078 registros completos requeriría almacenar una matriz de ~ 140 mil millones de entradas, inviable en hardware convencional. Adicionalmente, no expone un método **predict**, lo que impide asignar el perfil de accidentes nuevos sin reentrenar desde cero.

Por qué se descartó DBSCAN. Con los parámetros evaluados, clasifica 7,636 puntos ($\sim 19\%$ de la muestra) como ruido y forma 44 microgrupos en lugar de estructuras compactas. Esto no es un fallo de los parámetros sino una señal estructural: tras la codificación *one-hot*, los datos forman una nube continua sin valles de densidad bien definidos. Tampoco ofrece **predict** directo.

Por qué se seleccionó *K-Means*. Su silueta intermedia (0.104) es el precio de tres ventajas decisivas: escala de forma lineal a los 374,078 registros, produce centroides interpretables directamente sobre las variables originales y expone el método **predict**, que permite asignar el perfil de accidentes nuevos sin reentrenar.

10.6 Reducción de dimensionalidad

Con 60 dimensiones la matriz no puede visualizarse directamente. Se aplicó Análisis de Componentes Principales (PCA) para dos propósitos:

1. **Caracterizar la estructura del espacio.** Las primeras 10 componentes explican únicamente el 54.40 % de la varianza acumulada. Esta dispersión de la varianza entre muchos ejes es la firma de un espacio multidimensional sin una dirección dominante, lo que explica tanto la silueta moderada como la ausencia de un codo pronunciado en la curva de inercia.

2. **Visualizar la separación de grupos.** La proyección a dos dimensiones muestra que los grupos ocupan regiones preferentes con zonas de transición difusas, consistente con la nube continua que detectó DBSCAN. La proyección *t-SNE* (submuestra de 5,000 puntos, perplejidad 30) separa los conglomerados de forma más marcada al preservar la vecindad local, aunque sus distancias no son métricamente interpretables.




Figura 37: Proyección PCA de la muestra de 40,000 registros coloreada por grupo.




Figura 38: Proyección t-SNE (submuestra 5,000 puntos) coloreada por grupo.

Las proyecciones PCA y *t-SNE* son exclusivamente herramientas de visualización. El agrupamiento se realiza en el espacio completo de 60 dimensiones, las gráficas 2D comprimen el 85.88 % de la varianza restante y necesariamente solapan estructura real. Deben leerse como apoyo cualitativo, no como prueba de separación.

10.7 Perfiles del modelo final

El modelo final se entrenó con *K-Means* ($k = 4$, `random_state=42`) sobre el conjunto completo de 374,078 registros. Los tamaños, promedios de variables firma y distribución de severidad se reportan todos sobre este modelo.

Nota sobre la correspondencia de identificadores. *K-Means* no garantiza IDs de cluster estables entre dos ajustes distintos. Los IDs numéricos de la exploración en muestra (40,000 registros) pueden diferir de los del modelo final (374,078 registros). La correspondencia entre ambos conjuntos se establece por el perfil semántico de cada grupo, no por el número asignado.

10.7.1 Tamaños y variables firma

Clúster	Nombre	Registros	%	COND_FUG	MOTO	AUTO	CAM
0	Conductor fugado	34,944	9.3 %	0.999	0.198	1.068	0.118
1	Colisión con camioneta	116,665	31.2 %	0.000	0.001	0.626	0.348
2	Accidente con motocicleta	76,057	20.3 %	0.000	1.033	0.753	0.066
3	Colisión multi-automóvil	146,412	39.1 %	0.000	0.002	1.830	0.008
Total		374,078	100 %				

COND_FUG: media de CONDUCTOR_FUGADO; MOTO: media de MOTOCICLET; AUTO: media de AUTOMOVIL; CAM: media de CAMIONETA.

10.7.2 Descripción individual de cada perfil

Clúster 0 — Conductor fugado (9.3 %) La variable firma de este grupo no es un tipo de vehículo sino un comportamiento: el 99.88 % de los registros tiene `CONDUCTOR_FUGADO` = 1. Como el conductor abandonó la escena antes de ser registrado, prácticamente toda la información de su identidad es desconocida: el 99.9 % de los casos tiene `SEXO` = Desconocido y sólo 36 de 34,944 registros contienen una edad válida.

El tipo de accidente es heterogéneo: colisión con vehículo automotor (44.4 %), colisión con objeto fijo (23.1 %) y colisión con motocicleta (14.6 %). Esta mezcla refleja que la ausencia del conductor impide identificar un patrón vehicular dominante.

Un hallazgo relevante es la concentración dominical: el 21.2 % de los accidentes de este grupo ocurre en domingo, frente a valores entre 11 % y 13 % en el resto de los días. Esta concentración apunta a una dinámica de fin de semana donde la evasión de la escena es más probable.

Clúster 1 — Colisión con camioneta (31.2 %) La variable firma es `CAMIONETA` = 0.348, entre 5 y 43 veces mayor que en los demás clusters (0.008 en multi-automóvil, 0.066 en motocicleta). El 81.1 % de los accidentes corresponde a colisión con vehículo automotor, lo que refleja que la camioneta de carga participa colisionando contra automóviles.

Este grupo presenta la edad media más alta de los cuatro (39.6 años, calculada sobre 94,214 registros con edad válida) y la proporción más alta de aliento negativo (76.0 %). La distribución semanal es casi uniforme de lunes a sábado con una caída notable el domingo (10.6 %), patrón consistente con un perfil de conducción laboral.

Clúster 2 — Accidente con motocicleta (20.3 %) La variable firma es `MOTOCICLET` = 1.033: prácticamente cada accidente del grupo involucra exactamente una motocicleta. El 74.5 % de los tipos se clasifica como colisión con motocicleta. Es el grupo con la edad media más baja (34.4 años) y el más masculino (86.0 % hombres).

La hora media de ocurrencia (14.08 h) es la más tardía de los cuatro grupos (12.55, 13.39 y 12.96 h en los demás), lo que apunta a una concentración en el horario vespertino asociado a desplazamientos de reparto y movilidad cotidiana.


Este perfil es el hallazgo central del agrupamiento. El modelo no recibió ninguna columna de víctimas durante el entrenamiento, sin embargo, el 43.25 % de los accidentes de este grupo resultaron en personas lesionadas, entre 2.8 y 5.0 veces más que cualquier otro perfil. El mecanismo físico subyacente es la ausencia de carrocería protectora: ante un impacto, el cuerpo del motociclista recibe la energía directamente.

Clúster 3 — Colisión multi-automóvil (39.1 %) La variable firma es AUTOMOVIL = 1.830: en promedio casi dos automóviles por accidente. El 76.9 % de los tipos corresponde a colisión con vehículo automotor. Es el grupo más grande del conjunto y el menos diferenciado: no presenta desviaciones notables en alcohol, hora, ni distribución semanal. Representa el accidente cotidiano de tráfico urbano.

10.7.3 Distribución de severidad por perfil

La tabla siguiente cruza los clusters con CLASACC como validación externa. Los porcentajes se calculan con `normalize='index'`, es decir, dentro de cada grupo.

Clúster	Nombre	Fatal	No fatal	Sólo daños
0	Conductor fugado	2.23 %	15.73 %	82.05 %
1	Colisión con camioneta	0.74 %	8.55 %	90.70 %
2	Accidente con motocicleta	2.06 %	43.25 %	54.70 %
3	Colisión multi-automóvil	0.66 %	10.55 %	88.79 %
<i>Base global</i>		<i>1.12 %</i>	<i>17.06 %</i>	<i>81.82 %</i>



Si el agrupamiento no capturara estructura real, CLASACC se distribuiría de forma similar a la base global en los cuatro grupos. En cambio, el Clúster 2 (motocicletas) tiene una tasa de heridos 2.5 veces mayor que la base global, mientras que el Clúster 3 (multi-automóvil) tiene una tasa fatal 41 % inferior a la media. Esta ordenación coherente con la física del accidente, obtenida sin haber proporcionado la variable de severidad al modelo, constituye la principal validación del análisis.

10.8 Reutilización del modelo

El modelo final se serializa como un objeto `ClusteringModel` mediante `joblib` en:

```
models/clustering\_kmeans.joblib.
```

- El `ColumnTransformer` **ajustado** sobre los 374,078 registros de entrenamiento, con la mediana de `ID_EDAD`, los parámetros del `StandardScaler` y el vocabulario del `OneHotEncoder`.
- El estimador *K-Means* **entrenado** con sus cuatro centroides en el espacio de 60 dimensiones.
- El diccionario de **etiquetas interpretativas** asignadas a partir de las variables firma.

Esto permite cargar el artefacto en cualquier sesión posterior y asignar el perfil de accidentes nuevos sin acceder al dataset original ni reentrenar:

```
from src.clustering import ClusteringModel
modelo = ClusteringModel.load('models/clustering_kmeans.joblib')
etiquetas = modelo.predict_labels(df_nuevos_accidentes)
# Resultado: ['Accidente con motocicleta', 'Colisión multi-automóvil', ...]
```

10.9 Arquitectura del módulo `src/clustering/`

El código se organizó bajo el paradigma de POO en el paquete `src/clustering/`.

10.9.1 Estructura de archivos

```
src/clustering/
|-- __init__.py      <- Exporta todas las clases públicas
|-- preprocessor.py  <- AccidentClusteringPreprocessor
|-- strategies.py    <- ClusteringStrategy, KMeansStrategy, AgglomerativeStrategy,
|                    DBSCANStrategy
|-- analyzer.py      <- ClusterAnalyzer
'-- model.py         <- ClusteringModel
```

10.9.2 Patrones de diseño

Patrón	Clase(s)	Rol en el módulo
Repository	<code>DataRepository</code> (en <code>src/supervised/</code>)	Abstrae el acceso al CSV en una interfaz. El módulo de clustering no lee el archivo, llama a <code>repo.load()</code> . Si la fuente de datos cambia, solo se modifica este componente.
Strategy	<code>ClusteringStrategy</code> (abstracta), <code>KMeansStrategy</code> , <code>AgglomerativeStrategy</code> , <code>DBSCANStrategy</code>	Cada algoritmo hereda de la interfaz común y sobrescribe <code>build_estimador()</code> . El <code>ClusterAnalyzer</code> llama a <code>strategy.fit_predict(X)</code> sin saber qué algoritmo contiene. Para agregar un nuevo algoritmo basta con crear una nueva subclase.
Composición	<code>ClusterAnalyzer</code> , <code>ClusteringModel</code>	En lugar de heredar de clases base, ambas clases <i>componen</i> un repositorio, un preprocesador y una estrategia como atributos.

10.9.3 Responsabilidades por clase

AccidentClusteringPreprocessor (preprocessor.py) Encapsula la selección de variables, la construcción del `ColumnTransformer` y su ajuste. Define como atributos de clase las listas de variables incluidas y excluidas, lo que hace explícitas las decisiones metodológicas y facilita su revisión. Una vez ajustado, el transformador puede serializar y reutilizarse para datos nuevos mediante el método `transform()`.

ClusteringStrategy y subclasses (strategies.py) La clase abstracta define la interfaz `fit_predict(X) -> ndarray`. Las tres subclasses envuelven los estimadores de *scikit-learn* (`KMeans`, `AgglomerativeClustering` y `DBSCAN`) y exponen el mismo contrato independientemente del algoritmo subyacente.

ClusterAnalyzer (analyzer.py) Orquesta el flujo exploratorio: carga el dataset vía `DataRepository`, prepara la muestra de 40,000 registros, calcula la curva del codo, el coeficiente de silueta, la varianza explicada por PCA, las proyecciones t-SNE y los perfiles descriptivos de cada grupo. Cada operación es un método independiente que permite reproducir cualquier parte del análisis de forma aislada.

ClusteringModel (model.py) Empaqueta el preprocesador ajustado y la estrategia K-Means entrenada. Expone los métodos `predict()` y `predict\_labels()` para clasificar nuevos registros, y los métodos estáticos `train()`, `save()` y `load()` para gestionar el ciclo de vida del artefacto.




Figura 39: Diagrama de clases UML del módulo `src/clustering/`. Muestra las cinco clases, sus atributos, métodos públicos y relaciones de composición y herencia.

10.10 Conclusiones del agrupamiento

El agrupamiento respondió la pregunta de partida: los accidentes de tránsito en México no son homogéneos en cuanto al perfil de sus condiciones contextuales, aunque su distribución temporal y geográfica sea relativamente uniforme a nivel agregado.

Los cuatro perfiles obtenidos son internamente coherentes y externamente validables:

1. **Conductor fugado** (9.3 %): su firma es la ausencia de información. La fuga del conductor es más frecuente en domingo y concentra la tasa fatal más alta (2.23 %).
2. **Colisión con camioneta** (31.2 %): perfil laboral con edad media más alta (39.6 años), mayor sobriedad registrada (76.0 % sin aliento) y distribución semanal plana de lunes a sábado.
3. **Accidente con motocicleta** (20.3 %): conductor más joven (34.4 años), horario vespertino más tardío y la tasa de heridos más alta (43.25 %). Este perfil, identificado sin información de víctimas, confirma que el tipo de vehículo involucrado concentra el riesgo de lesión más allá de cualquier variable temporal o geográfica individual.
4. **Colisión multi-automóvil** (39.1 %): el grupo más numeroso y el menos diferenciado. Representa el accidente cotidiano de tráfico urbano con la tasa fatal más baja (0.66 %) y la mayor proporción de sólo daños materiales (88.79 %).

El hallazgo metodológico más relevante es la coherencia entre los perfiles descriptivos y la distribución de CLASACC, variable que **nunca entró al modelo**. Si el agrupamiento no capturara estructura real, la severidad se distribuiría de forma homogénea en los cuatro grupos. En cambio, la tasa de heridos varía entre 8.55 % (camioneta) y 43.25 % (motocicleta), una diferencia de factor cinco. Este resultado es consistente con el análisis de correlaciones reportado en la sección anterior, donde MOTOCICLET presentó la correlación lineal más alta con CONDHHERIDO ($r = 0,39$), y valida tanto el agrupamiento como el análisis descriptivo de forma mutua e independiente.

Referencias

- [1] Instituto Nacional de Estadística y Geografía (INEGI). Accidentes de tránsito terrestre en zonas urbanas y suburbanas (atus): Microdatos 1997–2024. https://www.inegi.org.mx/programas/accidentes/?ps=Microdatos#datos_abiertos, 2025. Consultado el 29 de mayo de 2026.
- [2] Instituto Nacional de Estadística y Geografía (INEGI). Diccionario de datos: Accidentes de tránsito terrestre en zonas urbanas y suburbanas (atus) 2024. https://www.inegi.org.mx/rnm/index.php/catalog/1115/data-dictionary/F1?file_name=ATUS, 2024. Diccionario de variables del conjunto ATUS, consultado el 29 de mayo de 2026.