Universidad Nacional Autónoma de México
Facultad de Ciencias

Almacenes y Minería de datos (2026-II)

Tarea 1: Data Warehouse

Alumnos:	**Número de cuenta:**
Salgado González Edgar	321277086
Romero Godoy Jesús Antonio	321144292
Kevin Steve Quezada Ordoñez	318331241
Gramer Muñoz Omar Fernando	419003698

---

1 Conceptos

1.1 Da un ejemplo de Almacén de Datos y explica cómo se cumple la definición en tu ejemplo.

Consideremos un Almacén de datos para una planta de producción de biogás, concebido como un repositorio central orientado al análisis y a la toma de decisiones. Este almacén está diseñado para concentrar y preservar información histórica relacionada con la operación de la planta, incluyendo la cantidad de biogás producido diariamente por cada biodigestor, la composición del gas (porcentajes de metano, CO_2 y H_2S), el tipo y proporción de sustrato empleado, las condiciones operativas (temperatura, pH y presión) y los registros de mantenimiento.

La información proviene de múltiples fuentes, como sensores industriales (IoT), sistemas SCADA y registros administrativos, y es sometida a procesos de extracción, transformación y carga para garantizar su consistencia y calidad. Una vez integrada en un modelo dimensional, esta base histórica permite analizar el rendimiento de los biodigestores, identificar patrones de comportamiento, comparar periodos de producción y apoyar decisiones estratégicas orientadas a optimizar la eficiencia y mejorar la calidad del biogás generado.

Incluye:

1. **Orientación a temas**

   El almacén está organizado en torno al tema central del negocio: la producción y calidad del biogás. No se enfoca en procesos operativos en tiempo real, sino en el análisis del rendimiento, eficiencia y comportamiento histórico de los biodigestores

2. **Integración de datos**

   Para este ejemplo se considera que los datos provienen de múltiples fuentes heterogéneas: sensores físicos, sistemas de control industrial y registros manuales. Durante el proceso de ETL estaríamos limpiando, unificando formatos (por ejemplo, unidades de medida como m^3), limpiando así mismo estaríamos estandarizando nombres de sustratos (nomenclaturas) y corrigiendo posibles inconsistencias.

3. **Variabilidad en el tiempo**

   Conservamos datos históricos asociados a una dimensión temporal (día, mes, año), lo que permite analizar tendencias, estacionalidades y comparaciones entre distintos periodos. Se agregan nuevos datos periódicamente cada día y el resto no se modifica.

4. **No volatilidad**

   El almacén es una entidad física separada de los sistemas operacionales del negocio (Sistemas SCADA, etc). En él los datos no se modifican ni eliminan, sino que se realizan principalmente operaciones de carga y consulta sobre los registros históricos de producción.

1.2 Explica con tus propias palabras la diferencia entre un Almacén de Datos y:

1. **Una base de datos transaccional (OLTP)**

   Una base de datos transaccional (OLTP) está orientada a registrar y gestionar las operaciones cotidianas de una organización, priorizando la rapidez, la integridad y la consistencia de cada transacción individual (inserciones, actualizaciones y eliminaciones frecuentes). Y su estructura suele estar normalizada para reducir redundancias y garantizar eficiencia en las operaciones operativas.

   En cambio, un Data Warehouse (DW) está diseñado para el análisis y la toma de decisiones. Sus datos son históricos, estables y se cargan de manera periódica, no transaccional. Su estructura está diseñada ante necesidades analíticas, optimizando consultas complejas y agregaciones de gran volumen, lo que implica un modelo estructural diferente al de una base de datos OLTP.

2. **Un esquema estrella**

   Un esquema estrella es una forma estructural de modelar los datos de un almacén de datos de tal manera que existe una tabla de hechos central conectada a tablas de dimensiones para facilitar consultas analíticas eficientes.

   Dicho esto, la diferencia entre un DW y un esquema estrella es que el esquema estrella es un modelo de diseño lógico utilizado dentro del Data Warehouse para organizar los datos que define cómo se estructuran las tablas.

3. **Un cubo OLAP (Online Analytical Processing)**

   Un cubo OLAP es una estructura de datos provenientes de un almacén de datos que se construye al reorganizar dichos datos en una estructura multidimensional que permita analizarlos de forma eficiente en tiempo real a través de dimensiones y medidas, en lugar de depender únicamente de consultas relacionales tradicionales.

   Dicho esto, la diferencia entre un DW y un cubo OLAP es que el cubo es una estructura optimizada que se puede construir a partir del DW.

4. **Un Data Lake**

   Un Data Lake es un repositorio que almacena grandes volúmenes de datos en su forma original, sin transformarlos previamente ni imponerles un esquema rígido al momento de guardarlos.

   A diferencia de un DW, cuyos datos están optimizados estructuralmente para toma de decisiones y análisis mediante consultas a gran escala, un Data Lake funciona como un repositorio masivo y flexible de datos puros que está orientado a la exploración y al análisis experimental, como el machine learning, donde el procesamiento de los datos pueden requerir distintos enfoques y transformaciones dependiendo del objetivo del análisis.

---

2 Escenario

El Instituto de Matemáticas de la Universidad Nacional Autónoma de México desarrolla y analiza modelos matemáticos mediante simulaciones numéricas, orientadas al estudio de ecuaciones diferenciales, sistemas dinámicos, procesos estocásticos y métodos numéricos.
Cada ejecución de simulación genera información distribuida que se encuentra en registros del clúster, bitácoras de ejecución, archivos de resultados y reportes de uso de recursos computacionales.
Actualmente, esta información no está integrada, lo que dificulta el análisis histórico y la toma de decisiones estratégicas.
Por lo anterior, el Instituto te contrata para diseñar un Almacén de Datos que permita analizar el uso de recursos, el comportamiento de las simulaciones y su evolución a lo largo del tiempo

3 Ejercicios

3.1 Menciona qué beneficios tendrá utilizar un Almacén de Datos en un entorno de cómputo científico. Justifica.

Usar Almacén de Datos en este contexto permitiría en primer lugar integrar información que normalmente está dispersa en diferentes lugares, como bitácoras, archivos de resultados y registros del clúster en lugar de tener los datos separados por proyecto o sistema, todo estaría organizado bajo un mismo modelo, lo que facilita mucho su consulta y análisis.

Además, ayudaría a realizar análisis históricos. No solo serviría para ver lo que está pasando en tiempo real, sino también para entender cómo ha cambiado la demanda de recursos con el tiempo, si los modelos se han vuelto más complejos o si los tiempos de ejecución han aumentado. Esto permite tener una visión más completa del comportamiento del entorno de cómputo.

También apoya la toma de decisiones estratégicas, ya que con datos consolidados y confiables es más fácil justificar inversiones en infraestructura, solicitar financiamiento o ajustar las políticas de uso del clúster.

Y finalmente, algo que considero muy importante es que favorecía la reproducibilidad científica, porque permite consultar configuraciones pasadas, parámetros y resultados de simulaciones anteriores lo cual es crucial para reconstruir experimentos, validar resultados y mantener la calidad académica.

3.2 Indica qué usuarios utilizarían este Almacén de Datos y con qué propósito. Justifica.

Los **investigadores** acceden al DW para identificar qué modelos fallan o consumen mayor cantidad de recursos, apoyándose en el histórico de ejecuciones. Su interés está centrado en las tasas de éxito, tiempos de ejecución y volumen de datos.

Los **administradores de TI** utilizan el sistema para detectar saturación en la infraestructura. Analizan métricas de consumo de RAM, CPU y tiempos de espera.

Los **directivos** lo emplean como respaldo a la toma de decisiones, con esto pueden justificar la adquisición de equipos más potentes, evaluar la pertinencia de ciertos tipos de simulación y asignar presupuesto de manera fundamentada.

El Almacen de Datos permite responder preguntas que ningún sistema operacional podría responder por sí mismo.

3.3 Escribe al menos cinco preguntas que el Instituto desearía responder en términos de análisis.

1. La pregunta inicial y probablemente la mayor motivación para construir un almacén de datos es:
   ¿Qué se espera analizar/observar de los resultados obtenidos de cada una de las simulaciones a recopilar?

   Esta pregunta define el propósito general del DW y ayuda a empezar a modelar los requisitos.

2. De forma más específica:
   ¿Qué costo computacional tiene cada una de las simulaciones?

   Al recopilar registros post-ejecución (uso de recursos computacionales), obtenemos información útil para la toma de decisiones estratégicas, como reemplazar simulaciones por otras más eficientes, aumentar recursos o descartar algunas pruebas.

3. Basándonos en el input y el proceso de cada simulación:
   ¿Cuáles simulaciones son las que más fallan o tienen mayor porcentaje de éxito?

   Las bitácoras de ejecución permiten llevar un conteo confiable de simulaciones exitosas; incluso la ausencia de registros completos aporta información para calcular porcentajes de éxito y falla, siendo resultados clave en la toma de decisiones.

4. En términos históricos:
   ¿Cómo se refleja la mejora de los sistemas computacionales en la ejecución de las simulaciones?

   Al ser un DW variante en el tiempo, permite observar el impacto de actualizaciones en los sistemas mediante el análisis de bitácoras y reportes de uso de recursos, apoyando decisiones sobre futuras mejoras.

5. Finalmente:
   ¿Hay alguna forma de hacer nuestro sistema más eficiente?

   Por ejemplo: ¿el sistema presenta tiempos de espera al ejecutar simulaciones?, ¿de cuánto tiempo? Con registros de clusters y datos de ejecución es posible detectar patrones de saturación y determinar si se requieren actualizaciones o nuevas políticas, con el objetivo de lograr mayor eficiencia.

3.4 Describe qué datos históricos almacenaría el Data Warehouse del Instituto de Matemáticas y qué decisiones estratégicas apoyaría.

Datos

Al Instituto de Matemáticas le interesa conocer información acerca de las simulaciones que desarrolla y ejecuta. Por lo tanto, el objetivo principal es recabar información relacionada con aquello que conforma las simulaciones por computadora. Los datos históricos de interés pueden organizarse mediante un modelo estrella, estructurado en hechos y dimensiones.

Hechos

Nos interesa medir distintos aspectos de cada ejecución completa de simulación que permitan responder preguntas relacionadas con desempeño, consumo de recursos, eficiencia y confiabilidad.

El hecho, que sería una **Ejecución Completa de Simulación** puede almacenar distintas métricas, las cuales agruparemos en tres grandes categorías: consumo de recursos, desempeño computacional y calidad/resultado de la ejecución.

Consumo de Recursos

- `tiempo_ejecucion_total` (segundos)
- `cpu_horas_consumidas` (CPU-horas)
- `memoria_promedio_utilizada` (GB)
- `memoria_maxima_utilizada` (GB)
- `nodos_utilizados`
- `energia_consumida` (kWh)

Métricas de Desempeño

- `tiempo_espera_cola` (segundos)
- `numero_iteraciones`
- `tasa_error(%)`
- `throughput_estimado` (iteraciones/segundo)
- `tasa`$_e ficiencia_paralela(\%)$

Resultado y Calidad

- `tamano_resultado` (GB)
- `estado_ejecucion` (1=exitosa, 0=fallida)
- `codigo_error`
- `costo_estimado`($)

Dimensiones

Los hechos por sí mismos no proporcionan suficiente información; necesitan un contexto para poder ser analizados. Las dimensiones que aportarían dicho contexto podrían ser:

- **Dimensión Tiempo**: día, mes, año, periodo académico.
  Permite: analizar evolución anual, detectar estacionalidad y comparar periodos.
- **Dimensión Simulación**: id_simulación, nombre_simulación, objetivo_científico, descripción, proyecto_asociado, estado_simulación, fecha_creación.
  Permite: identificar y clasificar cada simulación como experimento científico independiente.
- **Dimensión Investigador**: id_investigador, nombre, área de investigación, nivel académico, antiguedad, instituto.
  Permite: analizar uso de recursos por investigador y comparar grupos académicos.
- **Dimensión Modelo Matemático**: nombre_modelo, tipo_modelo, método_numérico, versión_modelo, complejidad_teórica.
  Permite: evaluar consumo de recursos por tipo de modelo y comparar métodos numéricos.
- **Dimensión Infraestructura**: id_infraestructura, nombre_clúster, nodo, arquitectura, número_núcleos, memoria_RAM, tipo_procesador, modelo_GPU, sistema_operativo, etc.
  Permite: analizar rendimiento por tipo de hardware, identificar cuellos de botella, comparar eficiencia entre nodos y asíjustificar actualizaciones tecnológicas.
- **Dimensión Configuración**: id_configuración, algoritmo, tolerancia, parametros, criterio_de_convergencia, número_máximo_iteraciones, semilla_aleatoria, versión_software, librerías_utilizadas.
  Permite: analizar el impacto de los parámetros en el tiempo de ejecución y evaluar diferencias de desempeño entre configuraciones.

Decisiones estratégicas

Con la información organizada y disponible para análisis histórico, el Instituto podría tomar decisiones estratégicas como:

- **Mejor planificación para la compra de equipos.** Al medir y analizar el consumo de recursos, si se detecta la necesidad de mejorar tiempos de ejecución o se estima que en el futuro se realizarán simulaciones más demandantes, se podría planificar de forma más adecuada la inversión en equipos más potentes.
- **Control de la demanda de usuarios.** Si en ciertos periodos existe saturación de usuarios intentando ejecutar simulaciones, se podrían analizar esos periodos de alta demanda y establecer límites de tiempo por usuario o por simulación, o incluso implementar un sistema de reservación.
- **Mejor gestión de recursos según el tipo de simulación.** Identificar qué tipos de simulaciones (ecuaciones diferenciales, sistemas dinámicos, procesos estocásticos o métodos numéricos) son más costosas computacionalmente o tienden más a fallar permitiría optimizar la asignación y gestión de recursos.

3.5 Define el hecho principal del modelo multidimensional.

En este modelo, definimos el nivel de granularidad como **una fila por ejecución completa de la simulación**. Es decir, cada fila representa una corrida individual desde su inicio hasta su finalización, incluyendo todas las iteraciones internas y los resultados obtenidos.

A partir de esto, el hecho central del modelo multidimensional en este escenario se puede definir como:

Los resultados de una ejecución completa de un modelo numérico específico, realizada en una fecha determinada, por un investigador concreto, con una configuración particular de parámetros y utilizando una infraestructura de cómputo definida.

Este hecho permite analizar el desempeño de cada ejecución, comparar resultados entre corridas y evaluar el uso de recursos de manera histórica y detallada, manteniendo un equilibrio entre nivel de detalle y manejabilidad del Almacén de Datos.

3.6 Explica qué representa una fila en la tabla de hechos y da cinco ejemplos.

Una fila en la tabla de hechos representa **una ejecución completa de simulación**. Cada fila recoge las métricas asociadas a ese evento, vinculándolas con sus dimensiones.

Fila	Descripción
1	El 15 de enero de 2025 se ejecutó un modelo de ecuaciones diferenciales a cargo del investigador García. El proceso consumió 4.2 horas de CPU y 12 GB de RAM, y finalizó correctamente, generando 3.8 GB de datos.
2	El 3 de marzo de 2025 se llevó a cabo un análisis de sistemas dinámicos que duró 0.5 horas y utilizó 2 GB de RAM. La ejecución terminó con un fallo antes de completarse y no produjo archivos de salida.
3	El 22 de agosto de 2024 se realizó una corrida de métodos numéricos en el nodo 4 del clúster. La ejecución tomó 8.1 horas, tuvo indicador de éxito igual a 1 y generó 10.2 GB de resultados.
4	El 7 de noviembre de 2024 se intentó procesar un modelo de procesos estocásticos. El trabajo permaneció 45 minutos en cola antes de iniciar, pero fue interrumpido por tiempo de espera y no logró completarse.
5	El 1 de febrero de 2026 se ejecutó nuevamente un proceso de métodos numéricos. Requirió 6.7 horas de CPU, alcanzó un pico de 20 GB de RAM y finalizó con éxito, siendo el de mayor costo computacional del semestre.

3.7 Se consideran los siguientes niveles de granularidad para el hecho Ejecución de Simulación

- Una fila por simulación científica
- Una fila por ejecución completa de simulación
- Una fila por paso iterativo interno

Selecciona la granularidad adecuada y justifica por qué es preferible a las demás.

Consideramos que la granularidad más adecuada para el caso de uso es:

Una fila por ejecución completa de simulación.

Ya que una ejecución completa es una unidad clara y medible: tiene un inicio, un fin, parámetros definidos y métricas asociadas (tiempo total, consumo de CPU, memoria, energía, convergencia, etc.). Esto permite analizar desempeño, uso de recursos y evolución histórica sin generar un volumen innecesario de datos.

Además, muchas decisiones estratégicas como planificación de infraestructura o evaluación de eficiencia se toman a nivel de ejecución, no a nivel de cada iteración interna.

Por otra parte, hacer una fila por simulación científica sería demasiado general ya que como ya mencionamos una simulación científica puede ejecutarse múltiples veces con diferentes configuraciones, parámetros o versiones del modelo. Si solo se almacena una fila por simulación, se perdería la variabilidad entre ejecuciones y no sería posible analizar diferencias de rendimiento o cambios en el tiempo.

3.8 Explica cuándo sería adecuada una granularidad alta y cuándo una baja, incluyendo sus ventajas y desventajas.

- **Granularidad Alta**: Almacenar una fila por cada paso iterativo interno de una simulación.

  Esta sería adecuada si el objetivo principal fuera analizar el comportamiento numérico interno de los algoritmos, estudiar convergencia paso a paso y detectar inestabilidades en métodos específicos.

  - **Ventajas:** Permitiría un análisis científico muy detallado ya que conserva toda la información posible del proceso computacional.
  - **Desventajas**: El volumen de datos sería enorme (millones de iteraciones por simulación) aumentando el costo de almacenamiento, y haciendo las consultas mucho más lentas. No es necesario para análisis estratégicos de uso de recursos.

- **Granularidad Baja**: Almacenar una fila por simulación científica (a nivel de modelo o proyecto).

  Sería adecuada principalmente para el análisis estratégicos de alto nivel como evaluar el desempeño global por tipo de modelo y comparar proyectos desde una perspectiva ejecutiva o institucional. En lugar de registrar cada ejecución individual, cada fila representaría un resumen histórico del comportamiento del modelo, incluyendo métricas agregadas como el total de ejecuciones por proyecto, el tiempo promedio de ejecución, el consumo promedio de CPU y otros recursos utilizados.

  - **Ventajas:** Permitiría un modelo simple con poco volumen de datos para consultas rápidas ideales para análisis estratégicos de alto nivel que podría servir a rectoría, al consejo científico o entidades financiadoras.
  - **Desventajas**: Se perdería el detalle por ejecución, asi que no podríamos analizar variabilidad entre corridas ni estudiar la evolución fina en el tiempo. La mayoría de las medidas estarían ya agregadas por proyecto y por ende serían en su mayoría no aditivas, dificultando el análisis científico.

3.9 Dibuja el esquema estrella correspondiente al escenario.

Considera que:

- Debe haber al menos cuatro medidas numéricas.
- Deben definirse al menos cinco dimensiones, incluidas Tiempo y Simulación.
- Deben indicarse los atributos relevantes de cada dimensión.

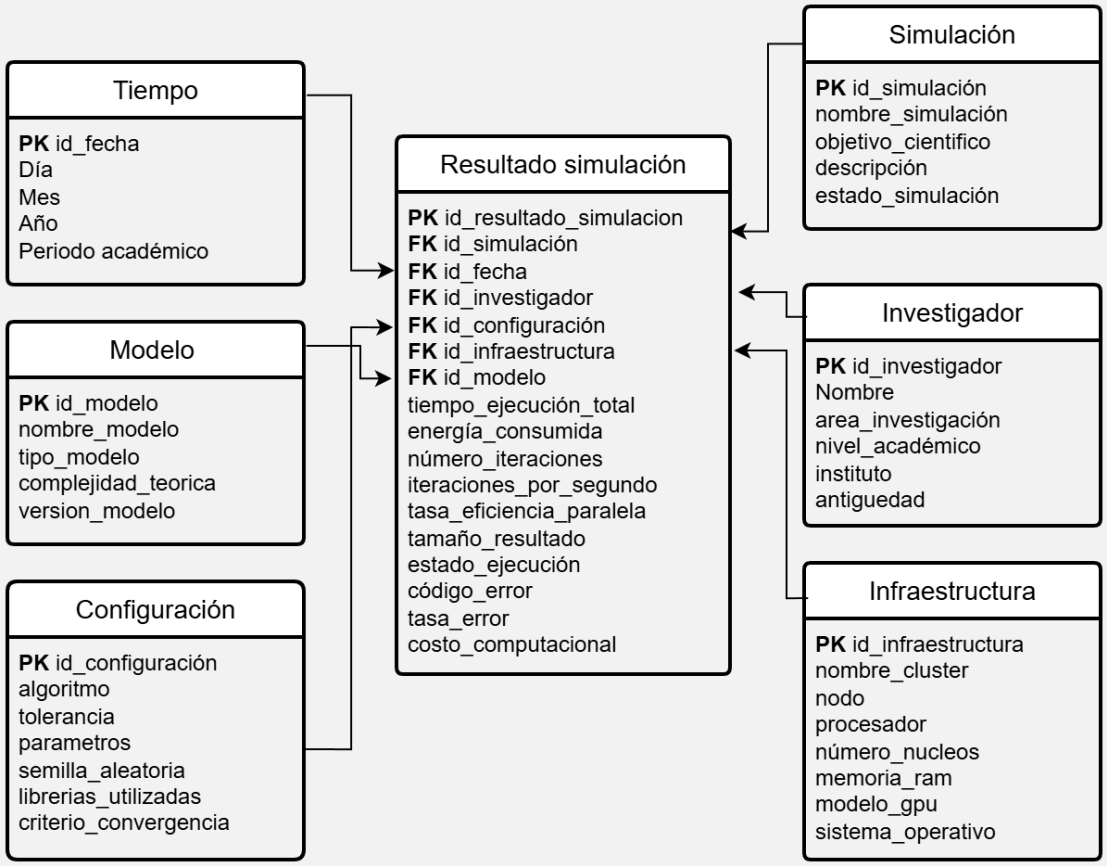

3.10 Describe las capas de la arquitectura de un Almacén de Datos.

Data Source. Corresponde a las fuentes de datos originales. Incluye sistemas operacionales, bases de datos transaccionales, archivos externos o servicios web. En esta capa los datos suelen ser heterogéneos, estar en distintos formatos y no necesariamente preparados para análisis.

Data Staging / ETL (Extracción, Transformación y Carga). Actúa como capa intermedia entre las fuentes y el almacén. Aquí se extraen los datos, se depuran, integran y transforman para asegurar consistencia, calidad y homogeneidad. Finalmente, se cargan en el almacén de datos.

Data Storage. Es la capa donde se almacena el Almacén de Datos. Los datos ya transformados se organizan siguiendo modelos dimensionales, como esquemas estrella o copo de nieve. En esta estructura se definen tablas de hechos y dimensiones que permiten el análisis eficiente de la información.

Data Presentation. Es la capa orientada al usuario final. Proporciona herramientas de consulta, reportes y análisis (por ejemplo, sistemas OLAP o dashboards). Permite acceder a la información según perfiles y necesidades, facilitando la toma de decisiones.

3.11 Explica el rol de cada capa en el contexto del cómputo científico.

En este escenario, la capa de **Data Source** está formada por todas las fuentes originales de información generadas por el entorno de simulación: registros del clúster, bitácoras de ejecución, archivos de resultados y reportes de uso de recursos. Estos datos son heterogéneos y se encuentran dispersos en distintos formatos y sistemas.

La capa de **Data Staging** se encarga de extraer y preparar esta información sin afectar la operación del clúster. Aquí se limpian, transforman y estandarizan los datos, por ejemplo, normalizando unidades de medida o corrigiendo inconsistencias, para que puedan integrarse de manera coherente.

En la capa de **Data Storage** se implementa el Almacén de Datos propiamente dicho. Los datos ya transformados se organizan bajo un modelo multidimensional, vinculando cada ejecución de simulación con dimensiones como fecha, investigador, modelo, parámetros y recursos utilizados. Esto permite realizar análisis históricos y comparativos.

Finalmente, la capa de **Data Presentation** pone la información a disposición de los distintos usuarios mediante reportes y herramientas analíticas. Investigadores, administradores del clúster y directivos pueden así analizar desempeño, uso de recursos y tendencias, facilitando la toma de decisiones estratégicas.

3.12 Indica dónde se implementa el modelo estrella.

Basándonos en las presentaciones vistas en clase el modelo estrella vive dentro del área de **Data Storage**, ya que en esta etapa es donde se implementa directamente este modelo dimensional en las tablas para organizar la información. Esto ocurre en las primeras fases de esta etapa, ya que necesitamos tener lista la estructura implementada físicamente (en un SMBD) para poder realizar la carga de los datos después de que hayan pasado por el proceso de extracción y transformación (ETL).

4 Detección de Errores

4.1 Plantea y describe dos errores de diseño posibles en un Almacén de Datos para este escenario.

Los errores no deben impedir la ejecución de consultas, pero sí producir resultados incorrectos o engañosos. Para cada error, indica:

1. **Un ejemplo de consulta donde el problema sea evidente.**
2. **Cómo corregirías el error (ETL o modelo)**
3. **Escribe detalladamente los pasos a seguir, así como tu solución.**

Error 1: Doble contabilización de recursos por mala definición de granularidad

Descripción del error:
Un error común sería almacenar en la misma tabla de hechos métricas agregadas por ejecución completa y métricas parciales por paso iterativo interno. Aunque las consultas se ejecuten correctamente, las agregaciones producirían resultados inflados debido a la doble contabilización de recursos.

1. **Ejemplo de consulta donde el problema es evidente:**

   Total de horas consumidas por proyecto durante el semestre.

   Si existen filas por iteración y también una fila resumen por ejecución completa, al sumar `cpu_horas_consumidas` se estaría contando varias veces el mismo consumo.

2. **Cómo corregirlo (Modelo y ETL):**

   Definir explícitamente la granularidad como *una fila por ejecución completa* y separar cualquier posible análisis de pasos internos en una segunda tabla de hechos o dimensión distinta.

3. **Pasos para corregirlo:**

   - Revisar la definición formal de granularidad del hecho principal.
   - Crear, si es necesario, una tabla de hechos independiente para pasos iterativos.
   - Ajustar el proceso ETL para que:
     - Cargue métricas acumuladas únicamente en la tabla de ejecución completa (tabla de hechos actual).
     - Cargue métricas parciales exclusivamente en la tabla de iteraciones.
   - Validar que no existan métricas redundantes entre ambas tablas.
   - Recalcular agregaciones históricas si es necesario.

Error 2: No manejar correctamente cambios en dimensiones (Dimensiones lentamente cambiantes)

Descripción del error:
Si los atributos de dimensiones como la Infraestructura del cluster cambian con el tiempo (por ejemplo, actualización de hardware) y el modelo sobrescribe los valores antiguos en lugar de mantener historial, los análisis históricos producirán resultados engañosos.

1. **Ejemplo de consulta donde el problema es evidente:**

   Comparación del rendimiento promedio del clúster antes y después de una actualización de hardware.

   Si la dimensión Infraestructura fue sobrescrita, parecería que el hardware actual existía también en años anteriores, distorsionando el análisis.

2. **Cómo corregirlo (Modelo y ETL):**

   Implementar dimensiones lentamente cambiantes para conservar el historial de cambios.

3. **Pasos para corregirlo:**

   - Modificar la dimensión para incluir:
     - Fecha_inicio_vigencia
     - Fecha_fin_vigencia
     - Indicador_registro_actual
   - Ajustar el ETL para que:
     - Detecte cambios en atributos relevantes.
     - Inserte un nuevo registro en la dimensión en lugar de sobrescribir el anterior.
     - Actualice la fecha de fin del registro previo.
   - Verificar que las claves foráneas se utilicen correctamente en la tabla de hechos.