Universidad Nacional Autónoma de México
Facultad de Ciencias

Almacenes y Minería de Datos (2026-II)

Tarea 2: EDA - Personas desaparecidas en México

Alumnos:	**Número de cuenta:**
Gramer Muñoz Omar Fernando	419003698
Quezada Ordoñez Kevin Steve	318331241
Romero Godoy Jesús Antonio	321144292
Salgado González Edgar	321277086

I. Empresa y metodología de Minería de Datos

Integrante 1 [Omar Fernando Gramer Muñoz]

Empresa elegida: Bio Engine (Bioengine.mx)

Metodología identificada: Analítica de datos orientada a procesos (*Process-Driven Data Analytics*) con sensores virtuales y detección predictiva de anomalías

Síntesis con cita(s):
Bio Engine es una empresa mexicana con sede en Toluca y Mérida dedicada a convertir biogás en energía eléctrica mediante motogeneradores diseñados para operar con gas contaminado. Su proceso incluye la limpieza del biogás usando un sistema de absorción con amina que elimina CO_2 y H_2S, permitiendo obtener un gas rico en metano reutilizable.
Para optimizar este proceso, la empresa quiere aplicar analítica de datos orientada al procesos utilizando sensores para monitorear variables operativas y modelos de machine learning que detecten anomalías de forma temprana, anticipando fallos como la saturación de la amina o problemas en equipos.
Además, como próximos pasos se desea implementar sensores virtuales que estimen variables difíciles de medir directamente, reduciendo costos sin perder precisión. Con el tiempo, estos modelos evolucionan hacia sistemas de optimización que recomiendan ajustes operativos, siguiendo una metodología similar a CRISP-DM pero aplicada a procesos industriales.
En conjunto, Bio Engine integra ingeniería química con próximas aplicaciones de aprendizaje de máquina para mejorar la eficiencia, reducir riesgos y fortalecer el desarrollo de tecnología energética sustentable en México.[7]

Integrante 2 [Kevin Steve Quezada Ordoñez]

Empresa elegida: Amazon Web Services (AWS)
Metodología identificada: Ciclo de vida de Machine Learning (MLOps) mediante Amazon SageMaker
Síntesis con cita(s):

En lugar de tratar el análisis de información como un proceso estático y aislado, los proyectos de minería de datos se abordan mediante un flujo de trabajo automatizado de extremo a extremo. Este enfoque convierte el descubrimiento de patrones en un proceso continuo, capaz de manejar grandes volúmenes de información sin perder consistencia ni reproducibilidad.
La metodología se organiza en fases iterativas. Comienza con la extracción y preparación de datos desde lagos de datos (como Amazon S3), utilizando herramientas de *data wrangling* para limpiar, transformar y preparar las variables. Luego, el proceso continúa con la construcción y el entrenamiento de modelos, donde el sistema ajusta automáticamente los parámetros para optimizar métricas como la *precisión* o el *F1 score*.
Finalmente, los modelos se despliegan para generar inferencias en contextos reales, como sistemas de recomendación o detección de fraudes. Todo el proceso se mantiene bajo un esquema de monitoreo continuo que detecta posibles cambios en los datos en producción y permite activar reentrenamientos automáticos, asegurando que los modelos se mantengan actualizados y precisos a lo largo del tiempo [8].

Integrante 3 [Jesús Antonio Romero Godoy]

Empresa elegida: Uber
Metodología identificada: Plataforma Michelangelo
Síntesis con cita(s):
Uber desarrolla sus proyectos de minería de datos y machine learning con su plataforma interna propia llamada Michelangelo. En lugar de que cada equipo arme su proceso por separado, Uber centraliza el trabajo, es decir, primero reúne y prepara los datos, luego entrena y evalúa modelos y después los despliega en producción y finalmente monitorea su desempeño para ver si siguen funcionando bien.
De forma simple, Uber lo hace como un proceso de extremo a extremo: ingestión de datos al lago de datos, transformación y generación de variables, entrenamiento del modelo, validación de resultados, despliegue para predicciones en sistemas reales y monitoreo continuo. Además, esta infraestructura les permite usar los modelos tanto para predicciones por lotes como en tiempo real dentro de la app [6]

Integrante 4 [Edgar Salgado González]

Empresa elegida: Microsoft
Metodología identificada: Proceso de Minería de Datos de Microsoft (MS-DM)
Síntesis con cita(s):
Microsoft emplea un enfoque estructurado y cíclico que guarda una estrecha similitud con el método *Cross-Industry Standard Process for Data Mining* (CRISP-DM), adaptado específicamente a sus herramientas de análisis. Esta metodología se puede sintetizar en las siguientes fases interconectadas:

1. **Definición del problema:** Fase híbrida entre el entendimiento del negocio y la comprensión de las fuentes. La propia Microsoft define esta fase como: "El análisis de los requisitos empresariales, la definición del ámbito

del problema, la definición de las métricas por las que se evaluará el modelo y la definición de objetivos específicos para el proyecto de minería de datos". [3].

2. **Preparación de datos:** Con base en las necesidades detectadas, se realiza un proceso de limpieza para filtrar la información útil y asegurar la calidad del insumo para el análisis.

3. **Exploración de datos:** Se analizan diversas capas de los datos limpios para generar diseños preliminares de los modelos, evaluando su viabilidad antes de la construcción formal.

4. **Construcción de modelos:** Se ejecutan los algoritmos sobre la vista de origen de datos para generar el modelo matemático. Según la documentación oficial: *"Después de crear una estructura y un modelo, puede procesar cada modelo mediante la ejecución de los datos [...] proceso que también se conoce como entrenamiento del modelo"* [4].

5. **Validación de modelos:** Se utilizan herramientas de comparación para seleccionar el modelo más preciso. *"SQL Server Analysis Services proporciona varios gráficos que puede usar para [...] elegir el modelo de minería de datos más preciso o útil"* [4].

6. **Implementación y actualización:** Equivalente a la fase de despliegue, donde los modelos aprobados se integran al entorno productivo para guiar la toma de decisiones.

II. Dataset a limpiar: personas desaparecidas en México

Este conjunto de datos reúne reportes de personas desaparecidas o no localizadas en México, con información proveniente de instancias estatales y federales. El corte más reciente corresponde al 1 de agosto de 2025. Los registros abarcan casos desde 1961 hasta la actualidad.

Estructura del dataset
La unidad de análisis es el reporte de desaparición. Esto significa que una misma persona puede aparecer en más de un registro si su caso fue documentado por distintas instituciones. La base de datos incluye variables de identificación, origen del reporte, información demográfica, aspectos temporales del evento y ubicación geográfica.

- **Dataset asignado:** data_secretariado.csv
- **Número de filas:** 133,887
- **Número de columnas:** 11
- **Periodo de fechas cubierto:** del 07/05/1961 al 30/09/2025
- **Unidad de análisis:** cada fila representa un registro individual de víctima/persona reportada, identificado de forma única por `ID_VICTIMA`
- **Fuente institucional:** Registro Nacional de Personas Desaparecidas y No Localizadas (RNPDNO).

III. Medidas descriptivas y análisis exploratorio de datos (EDA)

1. Diccionario de datos

Columna	Descripción	Tipo de dato	Tipo estadístico
ID_VICTIMA	Identificador único del registro de víctima/persona reportada.	string	Categórica nominal (identificador)
ORIGEN_REPORTE	Institución o fuente que genera el reporte.	string	Categórica nominal
FECHA_NACIMIENTO	Fecha de nacimiento de la persona (cuando no es nula o `CONFIDENCIAL`).	fecha/hora	Categórica ordinal
SEXO	Sexo reportado de la víctima (incluye categoría `CONFIDENCIAL`).	string	Categórica nominal
FECHA_DESAPARICION	Fecha y hora de desaparición (cuando no es nula o `CONFIDENCIAL`).	fecha/hora	Categórica ordinal
FECHA_REGISTRO	Fecha y hora de registro del caso (cuando no es nula o `CONFIDENCIAL`).	fecha/hora	Categórica ordinal
ESTATUS_VICTIMA	Estatus administrativo del registro de la víctima.	string	Categórica nominal
CVE_ENT	Clave de entidad federativa (catálogo de códigos).	string	Categórica nominal
ENTIDAD	Nombre de la entidad federativa asociada al registro.	string	Categórica nominal
CVE_MUN	Clave de municipio (catálogo de códigos).	string	Categórica nominal
MUNICIPIO	Nombre del municipio asociado al registro.	string	Categórica nominal

2. Aplicación de CRISP-DM al dataset asignado

1. Business Understanding

El objetivo principal de este análisis es que podamos comprender el fenómeno de desaparición de personas en México a partir de los registros oficiales del dataset asignado `data_secretariado.csv`, con el fin de identificar posibles patrones geográficos, temporales y demográficos que pudieran ser relevantes en la toma de decisiones en materia de política pública y búsqueda de personas.

Preguntas de interés:

- ¿En qué entidades federativas y municipios se concentra el mayor número de personas desaparecidas?
- ¿Existe alguna tendencia temporal en las desapariciones (por año, mes o época del año)?
- ¿Hay diferencias en los patrones de desaparición según el sexo o la edad de las víctimas?
- ¿Qué instituciones reportan más casos y cómo varía eso por estado?
- ¿Qué proporción de registros tiene información confidencial y cómo afecta esto al análisis?

Criterios de éxito:
Consideraremos que el análisis será exitoso si logramos identificar al menos un patrón geográfico, demográfico o temporal significativo, y si el dataset limpio resultante es consistente, reproducible y libre de duplicados e inconsistencias detectables.

2. Data Understanding

Una exploración inicial a grandes rasgos del dataset revela lo siguiente:

- Cada fila representa un registro de una persona desaparecida, identificada por un id único (`ID_VICTIMA`).
- Las columnas cubren información sobre el origen del reporte (fiscalías o comisiones locales de búsqueda), datos demográficos de la víctima (sexo, fecha de nacimiento y con ello edad), fechas clave de desaparición y registro, y ubicación geográfica de la desaparición (entidad y municipio).
- Se observa que un porcentaje considerable de registros tiene los campos de fecha de nacimiento, sexo, fecha de desaparición, fecha de registro y estatus marcados como `CONFIDENCIAL`, lo que constituye el principal problema de calidad del dataset.
- Los registros con `CVE_MUN = 999` y municipio confidencial nos indican que la ubicación municipal también está protegida en muchos casos, limitando el análisis geográfico al nivel estatal.
- El campo de estatus de la víctima aparece únicamente como `DESAPARECIDA` en los registros no confidenciales visibles, lo que podría indicar que el dataset está filtrado por este estatus o que hay poca variación en esta variable.
- La brecha entre fecha de desaparición y fecha de registro podría ser un indicador indirecto del tiempo de respuesta institucional.

3. Data Preparation

Data Preparation

El proceso de preparación de datos se llevó a cabo en varias etapas, dando como resultado dos versiones limpias del dataset que responden a objetivos analíticos distintos.

- **Eliminación de registros completamente inutilizables:**
  Se identificó un subconjunto de 29 registros que presentaban simultáneamente `CONFIDENCIAL` en todas las variables sensibles y `SE DESCONOCE` tanto en `ENTIDAD` como en `ORIGEN_REPORTE`, por lo que no aportaban ningún tipo de información aprovechable. Estos fueron eliminados, dejando 133,858 registros válidos como base de trabajo.

- **Tratamiento del bloque confidencial:**
  Se identificó un bloque estructurado de 49,149 registros marcados como `CONFIDENCIAL` de forma simultánea en las columnas `FECHA_NACIMIENTO`, `SEXO`, `FECHA_DESAPARICION`, `FECHA_REGISTRO`, `ESTATUS_VICTIMA` y `MUNICIPIO`. Este bloque no fue eliminado en su totalidad, ya que parte de esos registros conservaban información geográfica e institucional útil (entidad y origen del reporte). Los valores `CONFIDENCIAL` en columnas sensibles se conservaron como tales, sin sustituirlos por `NaN`, para preservar la distinción entre dato reservado y dato ausente.

- **Conversión de tipos de dato:**
  Las columnas `CVE_ENT` y `CVE_MUN` fueron convertidas a tipo numérico entero (`Int64`). Las demás columnas identificadoras y categóricas se establecieron explícitamente como `string`. Para las variables temporales se crearon columnas auxiliares `FECHA_NACIMIENTO_DT`, `FECHA_DESAPARICION_DT` y `FECHA_REGISTRO_DT` de modo que los valores `CONFIDENCIAL` y los formatos inválidos se transformaran en `NaT`, conservando el valor original crudo en la columna base.

- **Generación de variables derivadas:**
  A partir de las columnas temporales limpias se calcularon:
  - `EDAD`: diferencia en años entre `FECHA_DESAPARICION_DT` y `FECHA_NACIMIENTO_DT`, disponible únicamente cuando ambas fechas son válidas.
  - `DIAS_RETRASO`: diferencia en días entre `FECHA_REGISTRO_DT` y `FECHA_DESAPARICION_DT`, utilizada para analizar el tiempo de respuesta institucional.

- **Normalización de categorías:**
  Se aplicó normalización preventiva sobre `ORIGEN_REPORTE`, `SEXO`, `ESTATUS_VICTIMA`, `ENTIDAD` y `MUNICIPIO`, consistente en eliminar espacios al inicio y al final, reducir espacios múltiples internos y homologar etiquetas a mayúsculas. En la práctica no se detectaron cambios sustantivos en la cardinalidad de las categorías, lo que indica un grado aceptable de consistencia previo.

- **Detección de duplicados:**
  La búsqueda se realizó bajo dos criterios: duplicados exactos por fila completa y unicidad del campo `ID_VICTIMA`. No se detectaron duplicados bajo ninguno de los dos criterios.

- **Validaciones de consistencia temporal:**
  Se incorporaron reglas para detectar anomalías en las fechas, como fecha de nacimiento posterior a la fecha de

desaparición, o fecha de registro anterior a la fecha de desaparición. Se identificaron 1,121 casos (1.52% del dataset temporal) con esta última anomalía, concentrados principalmente en la Fiscalía General de Veracruz y la Procuraduría General de Justicia de Michoacán. Estos registros no fueron eliminados, sino marcados para su revisión.

- **Construcción de dos versiones del dataset limpio:**
  El proceso dio lugar a dos archivos finales con propósitos complementarios:
  - `data_secretariado_limpio_general.csv`: conserva los registros confidenciales cuando aún aportan información geográfica o institucional. Sirve como base para análisis descriptivos generales, distribución por entidad y estudio de la confidencialidad.
  - `data_secretariado_limpio_temporal.csv`: excluye el bloque confidencial para trabajar únicamente con registros cuyas fechas pueden interpretarse de forma consistente. Sirve como base para análisis de edad, retraso de registro y cronología de casos.

4. Modeling

Aunque en esta tarea no se entrenan modelos de manera formal, el EDA que hicimos permite identificar con claridad qué técnicas de minería de datos serían más adecuadas para continuar con el análisis.

En primer lugar, dado que las desapariciones muestran una distribución geográfica heterogénea pero generalizada en el país (índice de Gini y entropía de Shannon cercanos a 1, con picos claros en Jalisco, Estado de México y Tamaulipas), la técnica más pertinente sería el **clustering geoespacial**. Algoritmos como **K-Means** aplicados sobre las agrupaciones por entidad o municipio permitirían identificar zonas con patrones similares de incidencia y de respuesta institucional, superando el análisis descriptivo por frecuencia.

En segundo lugar, la variable `DIAS_RETRASO` mostró una concentración extrema (índice $R = 0.9955$), donde una fracción mínima de los registros acumula la mayoría del tiempo de retraso. Esto sugiere que un **modelo de detección de anomalías** (como Isolation Forest o LOF) podría ser útil para identificar sistemáticamente los registros con comportamiento atípico en el tiempo de registro, separándolos de los casos con captura inmediata.

Finalmente, dado que el análisis de correlación reveló una relación débil pero consistente entre el sexo y la edad al momento de la desaparición (hombres de mayor edad, mujeres más jóvenes), un **modelo de clasificación** supervisado como un árbol de decisión podría explorar si variables como entidad, sexo y origen del reporte son predictoras del perfil demográfico de las víctimas, con las limitaciones que impone el bloque confidencial.

5. Evaluation

La validación de los hallazgos encontrados en esta tarea deben contrastarse con patrones identificados con fuentes externas confiables. En particular, las distribuciones por entidad y las tendencias temporales podrían compararse con los datos del dashboard público del Registro Nacional de Personas Desaparecidas y No Localizadas (RNPDNO) y con los reportes del Observatorio sobre Desaparición e Impunidad.

Hallazgos que requieren validación crítica:

- La concentración de desapariciones en Jalisco, Estado de México y Tamaulipas debería contrastarse con

cifras oficiales del RNPDNO para determinar si refleja mayor incidencia real o simplemente mayor capacidad institucional de reporte.

- El índice de concentración $R = 0.9955$ en los días de retraso indica que unos pocos registros acumulan la mayor parte del tiempo de espera total; este valor debe interpretarse con cautela ya que podría deberse a errores de captura y no a demoras institucionales reales.
- Los 1,121 casos con fecha de registro anterior a la fecha de desaparición (1.52% del dataset temporal) se concentran principalmente en tres fuentes (Portal, Fiscalía General de Veracruz y Procuraduría/Fiscalía de Michoacán), lo que apunta a un problema sistemático de captura en esas instituciones.

3. Cálculo de medidas con visualizaciones e interpretación

Medidas de localización:
Para las medidas de localización, extraeremos los datos directamente de la tabla `df_export_general`, ya que cuenta con una mayor cantidad de información.
Al realizar el proceso de extracción de los resultados más repetidos en cada una de las columnas, encontramos la moda de cada una de las entradas. Podemos notar que el sexo masculino es el más registrado en los reportes de desaparición; Jalisco es el estado en el que más reportes se generan, junto con su procuraduría. Esto se debe a la alta presencia de grupos delictivos en la zona y los conflictos que son generados gracias a estos.
En las siguientes gráficas podemos observar las medidas más contundentes, ya que el porcentaje de hombres desaparecidos respecto al de mujeres es notable; además de la no tan remarcable diferencia entre las entidades federativas con más reportes, ya que las primeras tres presentan la misma problemática de altas tasas de delincuencia.

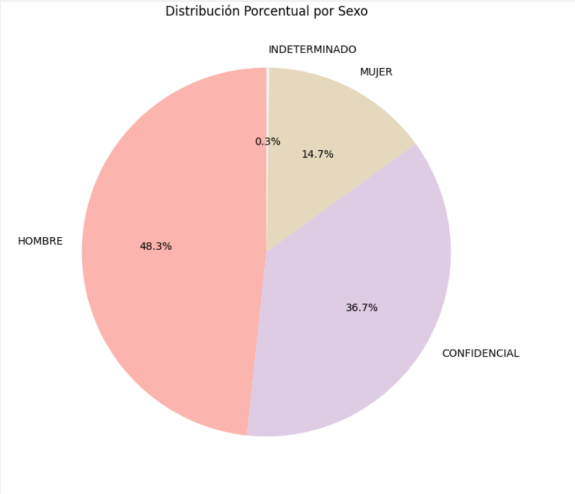

Gráfica de pastel de Sexo

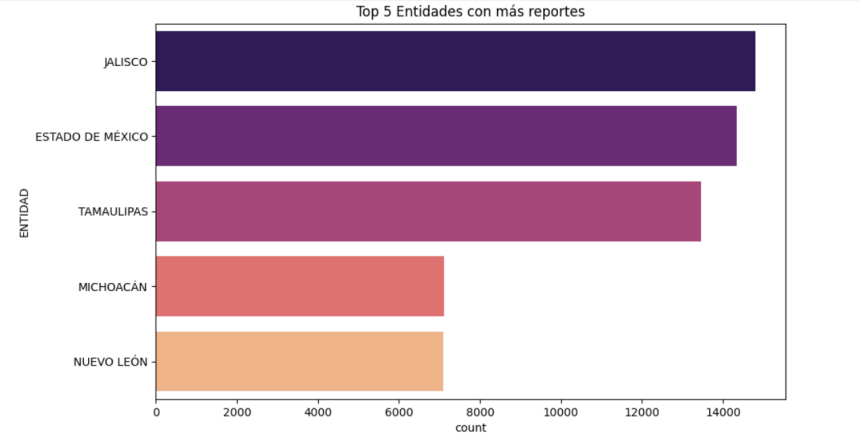

Gráfica de barras de Entidades Federativas

Media y Mediana:
Al contar con registros fuertemente relacionados al tiempo y necesitar el menor sesgo posible que pueda afectar a nuestros resultados, cambiamos a la tabla `df_export_temporal`. De esta, podemos extraer información relevante de las fechas de nacimiento, como las edades de las personas al momento de su desaparición o el tiempo que transcurrió entre la fecha de la desaparición y la fecha de creación del reporte.
La edad al momento de la desaparición es la resta entre la fecha de desaparición y la fecha de nacimiento. Realizamos un pequeño filtrado con únicamente las entradas de fechas válidas, permitiendo eliminar el sesgo de los registros generales sin perder la consistencia. No encontramos mucha diferencia entre el promedio de edad entre las personas y su mediana, ya que indican que la edad media de las personas desaparecidas es de un poco más de 30 años.
Sin embargo, el resultado más interesante es el que podemos observar entre el promedio y la mediana del tiempo entre la desaparición y el registro: una gran cantidad de datos (la mitad inferior, por definición de la mediana) indica que el registro se hizo el mismo día que la desaparición; pero la media indica que, en algunos casos, la espera fue bastante considerable, siendo estos valores atípicos los que afectaron nuestros resultados.

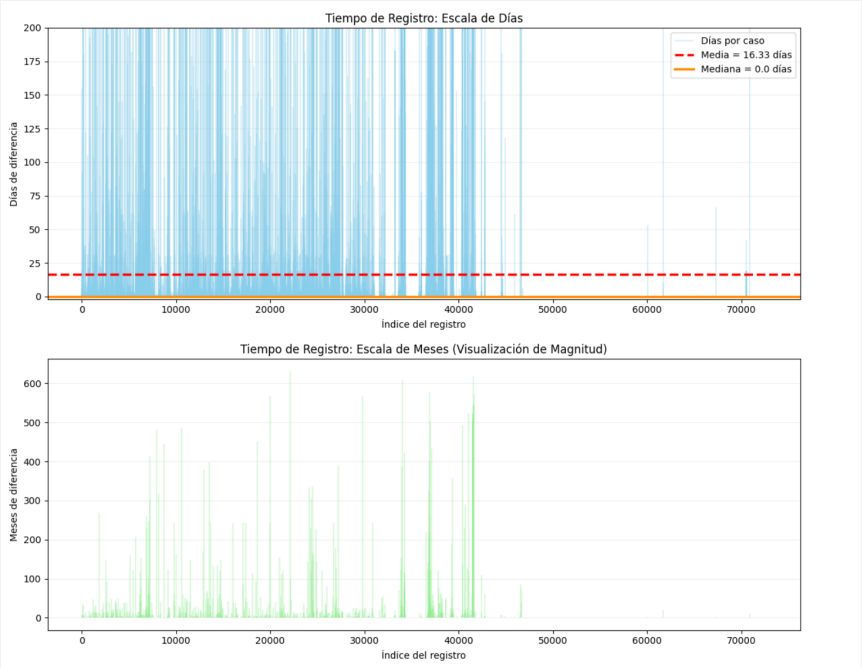

Gráfica de días y meses de Registro

La anterior gráfica muestra el número de días entre el registro y la desaparición. Es claro que hay una mayor cantidad de personas que fueron registradas en el mismo día por los vacíos entre las barras, pero hay algunos registros con tiempos de espera superiores a varios años. Se incluyó un gráfico con el número de meses para poder apreciar mejor el rango entre las fechas.
Medidas de variabilidad:

Medidas de Variabilidad: Rango, IQR, Varianza y Desviación

En estas mediciones continuaremos lo propuesto en la sección anterior sobre la edad de las personas desaparecidas; en este caso se salteará el análisis de los días de diferencia en registro, ya que la diferencia es lo suficientemente alta como para hacer su análisis completamente impreciso.
El rango es la diferencia entre el valor mínimo y el valor máximo. Como observamos en las operaciones anteriores, encontramos una gran cantidad de valores atípicos que alteran el comportamiento de diversas medidas, incluyendo el rango. El IQR (Rango Intercuartílico), en cambio, nos dará información más relevante respecto a la concentración de información: los valores centrales de los registros de edad.

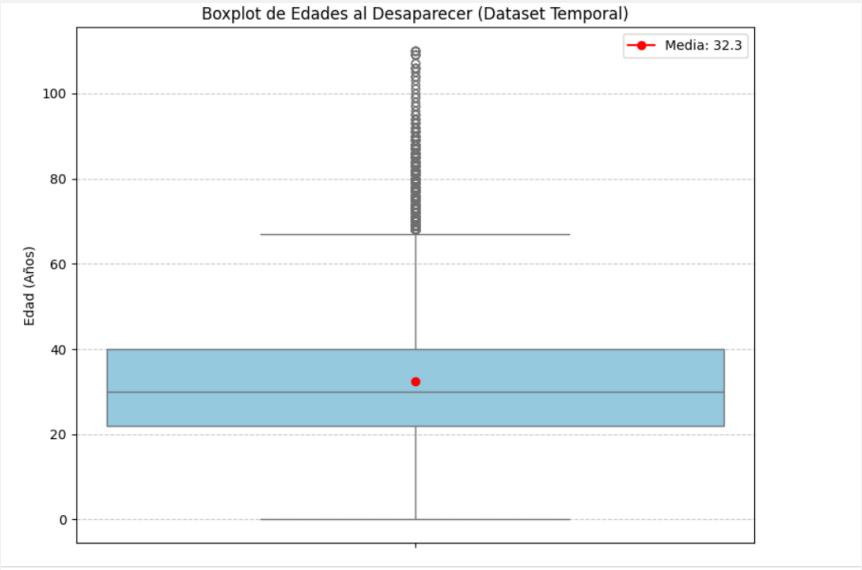

Boxplot de Edades

Lo anterior es un boxplot; sabiendo el valor de IQR podemos dar un espacio en el cual se puede apreciar la concentración de nuestros registros, además de la detección de valores atípicos con los conocidos *"whiskers"* inferiores y superiores que son calculados mediante el IQR. Podemos observar la tendencia de edad en personas desaparecidas: rangos de edad entre 20 y 40 años, lo cual nos guía hacia un grupo de personas en su mayoría del género masculino —por lo visto en las mediciones anteriores— que en su mayoría son adultos. Pero antes de poder sacar conclusiones, es necesario revisar otras mediciones importantes como la varianza y la desviación estándar, las cuales presentan la consistencia de información extraída en las edades.
De una manera un tanto coloquial, la desviación estándar nos indicará en qué rango caen la mayoría de edades de gente desaparecida; mientras más grande sea la desviación, más grupos de edades se ven afectados por las desapariciones.

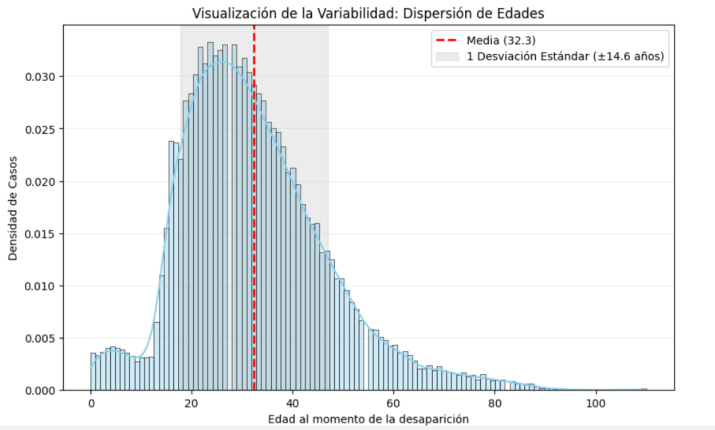

Dispersión de Edades

Después de calcular la varianza y la desviación, presentamos esta gráfica que arroja conclusiones mucho más

sólidas al respecto del grupo de edades. Es claro ahora que en su mayoría las personas desaparecidas son mayores de edad, pero también esta gráfica nos permite "agrandar" un poco este grupo y llegar a una conclusión mucho más contundente: las desapariciones afectan fuertemente a los adultos jóvenes y a los adolescentes.
Volviendo a las observaciones hechas en anteriores mediciones como los estados y sexo con más desapariciones, es muy probable que esto se deba a la delincuencia organizada; personas en rango de ser fuerza laboral se ven forzadas a unirse a estos grupos delictivos y sufrir las consecuencias que esto conlleva. Esta es una conclusión bastante aventurada, ya que sería necesaria una investigación más a fondo de la situación económica en estos lugares.

Un pequeño agregado: Verificación de Limpieza

Este es un apartado adicional, ya que se consideró insuficiente solo el análisis de edad en el rubro anterior, así que aquí presentamos algo bastante interesante para nuestro trabajo: hemos hecho correctamente nuestro proceso de limpieza.
Si recordamos, la tabla con los registros generales contiene mucha más información que la temporal, pero en numerosas ocasiones se expresó la preocupación de tener información sesgada al no poseer consistencia en las fechas; mientras que en la tabla de registros temporal tenemos muchos menos registros, pero garantizamos un mejor proceso de limpieza con las edades. ¿Cómo podríamos representar el cambio entre ambas tablas?
A continuación tenemos la respuesta. Recordemos que el IQR y los Boxplots, además de la desviación estándar, ofrecen una manera de medir la consistencia de los registros. Claramente podemos ver la diferencia entre la tabla general y temporal al tener muchos más valores atípicos en la primera, además de valores de varianza y desviación estándar mucho más disparados que apuntan a sectores de edad mucho más grandes de forma inconsistente. Por el contrario, la tabla temporal presenta unos *whiskers* ligeramente más centralizados que tienen mayor capacidad de detectar valores atípicos (un ejemplo lo tenemos con la nula presencia de valores negativos) y una desviación más pequeña que focaliza mejor la información. La diferencia puede observarse en los Boxplots generados.

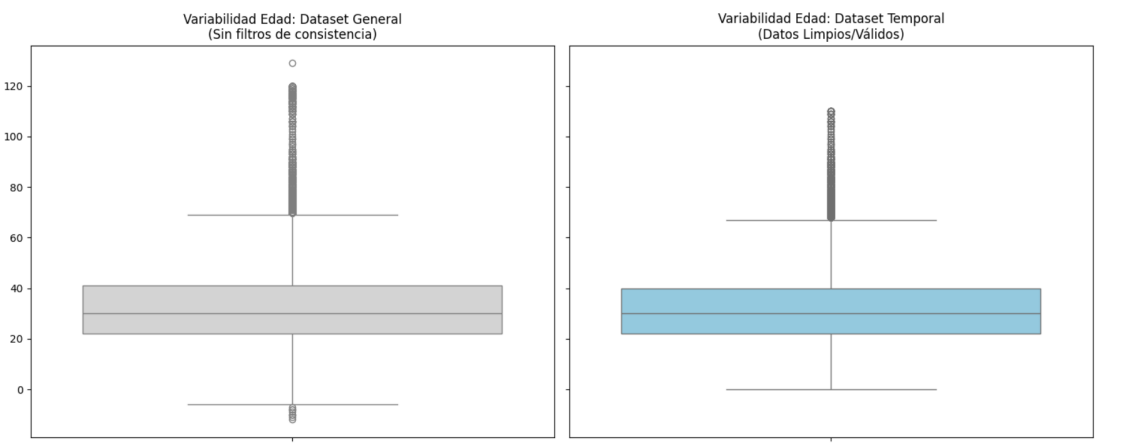

Comparativa de Boxplots (General vs Temporal)

Medidas de Heterogeneidad: Índices de Impureza de Gini y Entropía de Shannon

Ahora se analizará con más detalle la proporción de reportes de desaparición por cada uno de los estados de la república para llegar a conclusiones importantes respecto a la proporción de los casos; ya sea que es una

problemática generalizada en toda la república mexicana o solo es una preocupación que afecta a un solo grupo de estados.
Se puede dar el caso de aplicar estas medidas a los grupos de género y edad al momento de desaparecer, pero ambas proporciones fueron extensamente evaluadas en las mediciones anteriores. Además, las gráficas de proporción de género presentadas en las primeras secciones nos dan una idea concreta respecto a la distribución por edades, siendo ahora necesario ahondar en una sección no tan explorada con anterioridad.
Pasaremos a la tabla `df_export_general` para hacer nuestras evaluaciones, ya que en esta ocasión requerimos de un panorama más general de la información. Las siguientes medidas calculan la misma proporción pero de diferentes formas. Ambas emplean la misma escala para indicar la información de interés: valores cercanos a 0 indican una alta concentración de los datos, mientras que valores cercanos a 1 indican una distribución uniforme de cada uno de los registros. Al aplicar esto a los estados de la república, podremos observar si la cantidad de registros de desapariciones es una problemática generalizada en todo el país o solo un caso grave para unos cuantos estados.
La diferencia entre ambas mediciones radica en la definición y metodología: mientras que el índice de Gini mide diversidad, el índice de entropía mide incertidumbre; en este caso, el nivel de incertidumbre que se tiene al extraer un registro cualquiera y que este pertenezca a una categoría u otra. Para comparar directamente tanto Gini como Shannon debemos normalizar la entropía. Recordemos que la entropía máxima de N distribuciones es el logaritmo base 2 de N. Por lo que, para transformar la entropía en una escala de 0 a 1, debemos dividir la entropía resultante por la máxima; esto es una medida adicional conocida como la **equidad de Pielou**.
Aquí observamos información reveladora para esta investigación. Tanto el índice de Gini como el de entropía son muy altos y cercanos al valor de 1 (que indica diversidad máxima). Esto nos indica que es un problema generalizado en todo el país al tener una distribución un tanto uniforme de los reportes.
Esto se visualiza mejor al revisar la entropía por cada uno de los estados. En el siguiente gráfico podemos apreciar la probabilidad de que un registro cualquiera pertenezca a cada una de las entidades. Aplicamos una línea llamada **Distribución Uniforme Teórica** que señaliza la ubicación de las barras si tuvieramos una escala de entropía máxima.

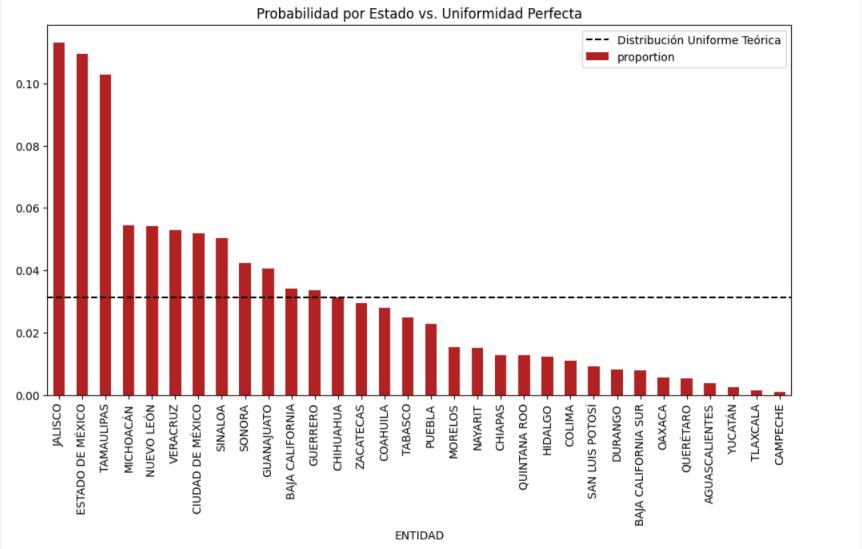

Gráfica de Entropía por Estado

Con esto podemos llegar a una conclusión mucho más acertada de este fenómeno: las desapariciones son una problemática que asola de manera generalizada a todos los estados de la república, pero es una problemática aún más grave para un grupo específico de entidades. Esto sirve como base y complemento contundente para las conclusiones hechas en secciones anteriores. **Medidas de concentración:**

Medidas de Concentración: Índice de Concentración (R) y Curva de Lorenz

En esta sección volveremos a analizar el número de días de diferencia entre la desaparición y el registro de dicha desaparición, que ahora denominaremos como **retraso**. Esto tiene el objetivo de conocer si la presencia de valores atípicos realmente está afectando las posibles conclusiones extraídas de estos días de retraso.
La siguiente medición es una herramienta poderosa, ya que su principal función es indicar si unos pocos individuos (en este caso, los registros de desaparición) concentran la mayor cantidad de resultados (número de días de retraso). Esto sirve para determinar si existe un sesgo en nuestra información, ya que es posible que, aunque generalmente las desapariciones sean registradas de manera inmediata, existan unos pocos casos los cuales se registran mucho después, logrando cambiar la percepción de eficiencia en los procesos de registro.
Para usar el índice de concentración debemos definir el índice de acumulación de registros y el índice de acumulación de resultados, que tienen asignadas las nomenclaturas F_i y Q_i respectivamente, las cuales representan el porcentaje de la información acumulada hasta el momento.
El índice de concentración R resulta de la suma de las diferencias de cada uno de los porcentajes por cada registro realizado, dando un resultado en la escala entre 0 y 1 que indica el nivel de concentración (0 siendo una concentración mínima con resultados equilibrados, mientras que 1 representa una concentración máxima donde unos pocos individuos acumulan la totalidad de los resultados).
Del cálculo anterior podemos observar un índice $R = 0.9955$; una concentración extremadamente alta que indica que unos pocos casos conservan el mayor número de resultados acumulados. Aplicado a nuestro *dataset*, esto indica que una fracción mínima de los registros concentra la mayor parte del tiempo de retraso. Mientras que la gran mayoría de los reportes son realizados el mismo día, los reportes con mayor tiempo de espera sesgan la información global y, por tanto, pueden llevar a conclusiones incorrectas si se analizan únicamente de forma lineal. Esto se observa con mayor claridad en la siguiente **Curva de Lorenz**. La distancia entre la línea de equidad perfecta y la proporción de días de retraso acumulados (demarcada por la curva rosa) demuestra el enorme sesgo que existe entre estos registros. En términos prácticos, un porcentaje muy pequeño de los reportes acumula la gran mayoría de los días de retraso totales.

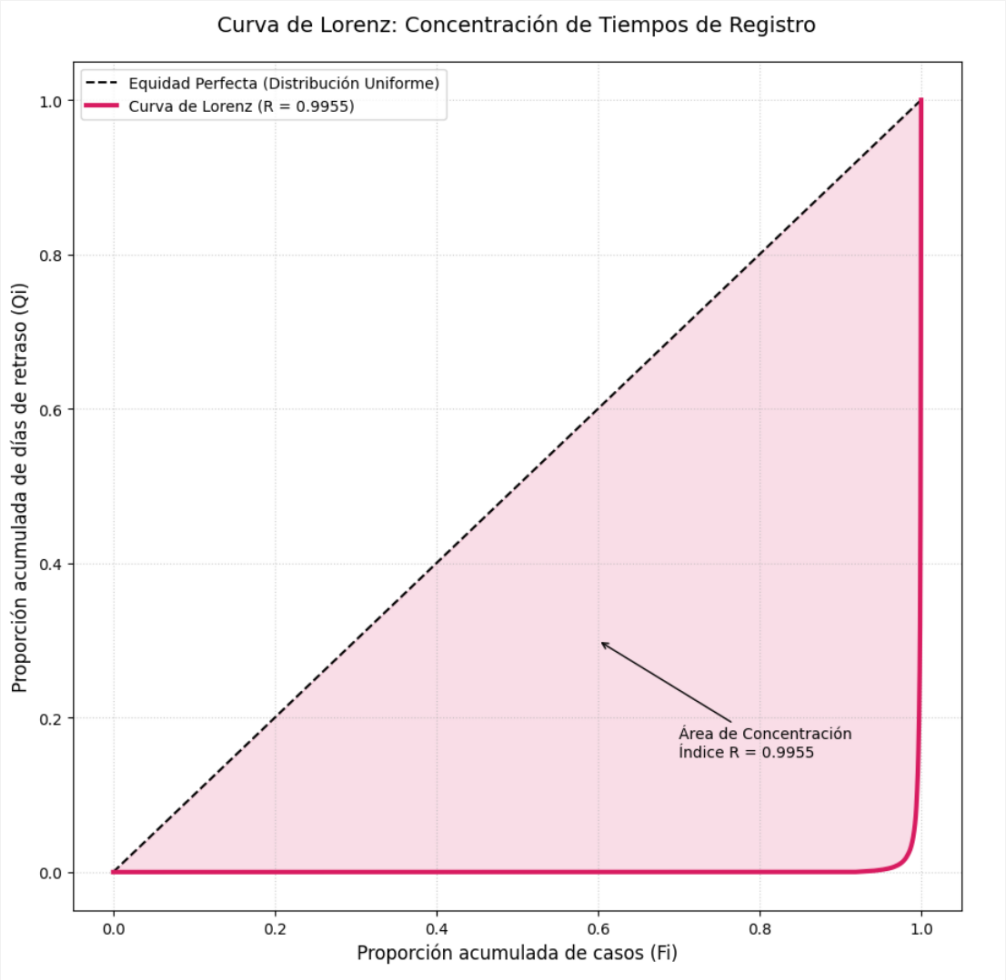

Curva de Lorenz para Días de Retraso

IV. Correlación de Variables

En esta sección determinaremos si existe alguna relación entre los resultados de cada uno de nuestros registros, tomando en cuenta el análisis expuesto en el apartado de cálculo de medidas. Determinaremos la existencia de dichas relaciones a través de la matriz de Pearson (matriz de correlación) entre la edad de la desaparición, el sexo de la persona y el tiempo de retraso acumulado para registrar el reporte. Se ofrece una breve explicación de cada uno de los índices, además de clasificarlos como fuertes o débiles dependiendo del resultado obtenido.

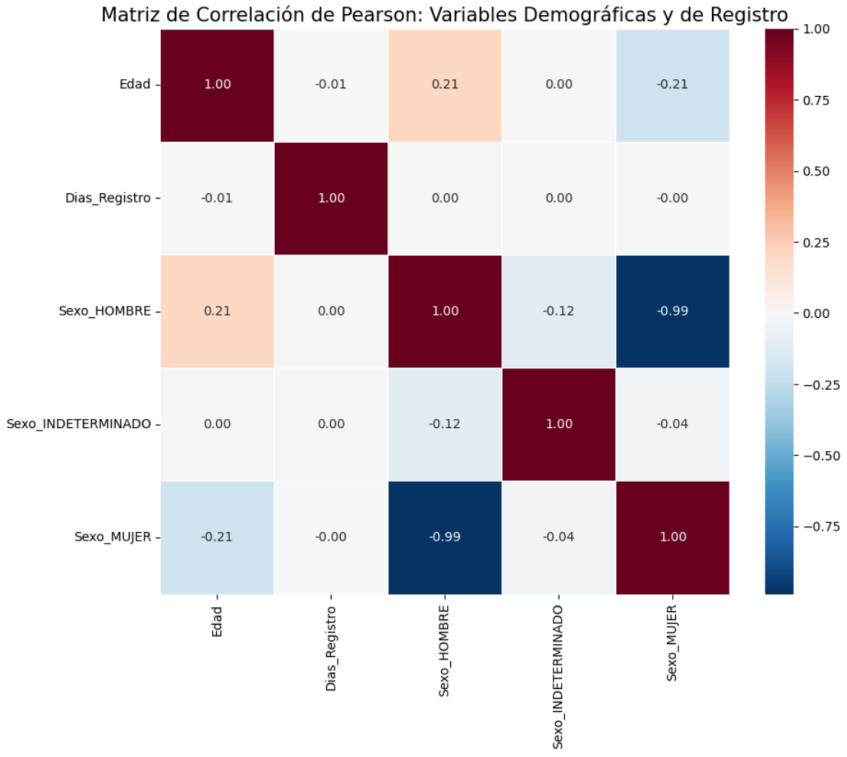

Heatmap de Correlación: Edad, Sexo y Retraso

Podemos observar que los días de retraso no tienen una relevancia real o una asociación lineal con cualquiera de los otros factores demográficos; aunque esto puede ser causado por el enorme sesgo de la variable, como se analizó en la sección de concentración.

En este análisis no se presentan relaciones necesariamente fuertes, salvo la correlación entre géneros. El índice de $r \approx -0.99$ entre `Sexo_Hombre` y `Sexo_Mujer` indica que el alza de uno representa la disminución del otro; esto es una consecuencia lógica de la exclusión mutua de las categorías (pertenecer a una clasificación impide pertenecer a la otra). Lo mismo ocurre con la clasificación de `Sexo_Indeterminado`, aunque debido a los procesos de limpieza en la tabla temporal, los valores pueden diferir ligeramente manteniendo siempre el índice negativo.

Los únicos índices rescatables son la relación entre el género y la edad, mostrando una relación débil positiva y negativa para `Sexo_Masculino` y `Sexo_Femenino` respectivamente. Esto indica una tendencia estadística donde las personas desaparecidas del género masculino suelen tener mayor edad, mientras que las del género femenino tienden a ser más jóvenes.

Análisis de Confidencialidad y Origen

Otra relación que consideramos crucial es la que existe entre el origen de los reportes y la probabilidad de que estos contengan información confidencial. Al evaluar específicamente esta interacción, generamos una matriz de correlación centrada en un solo fenómeno: la confidencialidad unificada.
Las relaciones más débiles se encuentran en el centro de nuestro *heatmap*, donde no existe una conexión clara entre ambos factores. Sin embargo, en los extremos observamos relaciones más marcadas tanto positivas como negativas. Las relaciones negativas representan una probabilidad mucho menor de que los datos sean confidenciales según su origen (liderando la Fiscalía de Chihuahua), mientras que un índice positivo representa una mayor probabilidad de que la información sea clasificada viniendo de dicha fuente.

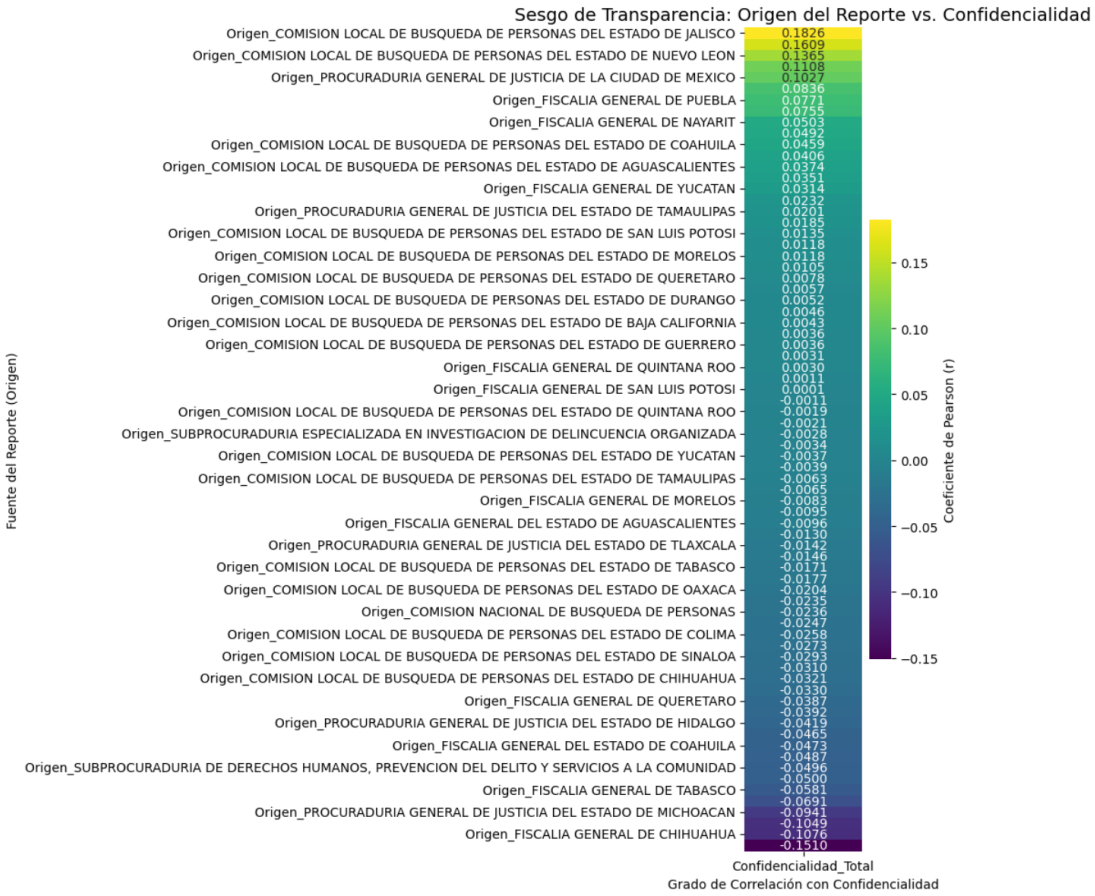

Heatmap de Origen del Reporte vs. Confidencialidad

Destacan en este apartado los orígenes de la Ciudad de México, Nuevo León y Jalisco. Mientras que para las primeras dos entidades es probable que esto involucre protocolos de seguridad específicos o tiempos de espera institucionales, es imperativo destacar que el estado líder en desapariciones (Jalisco) también presenta una alta correlación con la clasificación confidencial de la información.

Resumen de Correlaciones

A continuación, se listan los valores más significativos detectados en el análisis:

- **Correlaciones más Fuertes:**
  - `Sexo_Hombre` vs. `Sexo_Mujer`: $r \approx -0.988$ (Relación técnica excluyente).
  - Origen Comisión Local Jalisco vs. Confidencialidad: $r \approx 0.1826$.
  - Origen Fiscalía Chihuahua vs. Confidencialidad: $r \approx -0.1510$ (Tendencia a la transparencia).
- **Correlaciones más Débiles:**
  - Edad vs. Días de Registro: $r \approx -0.0052$ (Independencia total).
  - Sexo vs. Días de Registro: $r \approx 0.0031$ (Independencia total).
  - Entidades Federativas vs. Días de Registro: $|r| < 0.05$ en la mayoría de los casos.

V. Limpieza del dataset y generación del CSV limpio

Valores faltantes

Durante la etapa de limpieza se distinguieron dos tipos de ausencia de datos o reserva de información: por un lado, los valores faltantes reales (`NaN`) y, por otro, los valores etiquetados como `CONFIDENCIAL`. Esta distinción fue importante porque los valores `CONFIDENCIAL` no representan un dato perdido, sino información explícitamente reservada, por lo que no debían tratarse de la misma manera que un dato faltante normal.
Como parte del analsis exploratorio inicial se identificó un bloque solido de 49,149 registros marcados como `CONFIDENCIAL`. Este bloque no aparecía de manera aislada en una sola variable, sino de forma simultánea en varias columnas sensibles del dataset, especificamente en `FECHA_NACIMIENTO`, `SEXO`, `FECHA_DESAPARICION`, `FECHA_REGISTRO`, `ESTATUS_VICTIMA` y `MUNICIPIO`. La coincidencia exacta de estos registros mostró que se trataba de un subconjunto completo de información reservada y no de datos `CONFIDENCIALES` dispersos por errores de captura.
Sin embargo, decidimos no eliminar todo este bloque, ya que una parte importante de esos registros todavía conservaba información útil para ciertos análisis, por ejemplo la entidad o el origen del reporte. Por esta razón los registros confidenciales se conservaron en el dataset general cuando aún aportaban contexto geográfico o administrativo.
Pero dentro de ese bloque detectamos un subconjunto mucho más pequeño de 29 registros cuyo contenido era prácticamente inutilizable para el análisis. Estos casos presentaban `CONFIDENCIAL` en las variables sensibles ya mencionadas y, además, tenían simultáneamente `ENTIDAD = SE DESCONOCE` y `ORIGEN_REPORTE = SE DESCONOCE`. En otras palabras, no aportaban información demográfica, temporal, geográfica ni institucional aprovechable. Debido a ello estos 29 registros ($\approx 0.02\%$ del total original) sí fueron eliminados del dataset principal antes de continuar con la limpieza.
Una vez realizada esta depuración mínima, el dataset principal de trabajo quedó conformado por 133,858 registros. Sobre esta base, se identificó que la columna `FECHA_NACIMIENTO` contenía 28,887 valores faltantes (21.58%), la columna `FECHA_DESAPARICION` contenía 8,160 (6.10%) y la columna `FECHA_REGISTRO` contenía 6,097 (4.55%). En todos estos casos se decidió conservar los faltantes como nulos, sin aplicar imputación, ya que sustituirlos habría implicado introducir supuestos difíciles de justificar, especialmente en variables temporales.

Duplicados

La búsqueda de duplicados se realizó con base en dos criterios. El pirmero, se reviso si existian duplicados exactos por fila completa, con el fin de detectar registros repetidos en todas sus columnas. En segundo lugar, se revisó la unicidad de la variable `ID_VICTIMA`, ya que esta funciona como identificador del registro.
Bajo ambos criterios no se detectaron duplicados. Por lo tanto, no fue necesario eliminar registros por repetición, lo cual nos permitió conservar todos los registros válidos tras la eliminacion inicial.

Tipos de datos correctos

La corrección de tipos de datos se realizó de forma diferenciada según la naturaleza de cada variable. Las columnas `CVE_ENT` y `CVE_MUN`, al corresponder a claves geográficas, fueron convertidas a tipo numérico entero (`Int64`) con el fin de preservar consistencia y permitir validaciones posteriores entre claves y etiquetas textuales.
Por su parte, las columnas `ID_VICTIMA`, `ORIGEN_REPORTE`, `FECHA_NACIMIENTO`, `SEXO`, `FECHA_DESAPARICION`, `FECHA_REGISTRO`, `ESTATUS_VICTIMA`, `ENTIDAD` y `MUNICIPIO` fueron convertidas explícitamente a tipo `string`, ya que almacenan identificadores, categorías, nombres institucionales o etiquetas geográficas y no deben interpretarse como valores numéricos.
Finalmente, las variables temporales se transformaron en columnas auxiliares de tipo fecha y hora, respetando el formato original de la información: `FECHA_NACIMIENTO_DT`, `FECHA_DESAPARICION_DT` y `FECHA_REGISTRO_DT`. Para ello se utilizó una conversión controlada con coerción de errores, de modo que los valores nulos, los registros `CONFIDENCIAL` y los formatos no válidos se transformaran en `NaT`. Esta estrategia permitió conservar el valor original crudo y, al mismo tiempo, disponer de una versión temporal limpia para análisis posteriores.
A partir de esta conversión fue posible construir dos versiones finales del dataset. La primera corresponde a un dataset general, que conserva los registros confidenciales cuando todavía aportan información útil para análisis descriptivos, institucionales o geográficos. La segunda corresponde a un dataset de analisis temporal, en el cual se excluyó el bloque confidencial para trabajar únicamente con registros cuyas fechas pudieran interpretarse de manera consistente. Esta separación permitió adaptar el proceso de limpieza a dos objetivos analíticos distintos sin perder información relevante.

Normalización de categorías

Se aplicó una normalización preventiva sobre las principales columnas categóricas de texto: `ORIGEN_REPORTE`, `SEXO`, `ESTATUS_VICTIMA`, `ENTIDAD` y `MUNICIPIO`. Esta normalización consistió en eliminar espacios al inicio y al final de cada cadena, reducir espacios múltiples internos a un solo espacio y homologar todas las etiquetas a mayúsculas.
El propósito de esta etapa fue evitar diferencias artificiales entre categorías equivalentes. En la práctica, la normalización no produjo cambios sustantivos en la cardinalidad de las categorías, lo cual indica que el dataset ya presentaba un grado aceptable de consistencia en sus etiquetas. Sin embargo, mantener este paso dentro del proceso de limpieza fortalece la trazabilidad y asegura robustez frente a futuras actualizaciones del conjunto de datos.

Validaciones

Después de corregir tipos y normalizar categorías, se realizaron validaciones estructurales y temporales. En primer lugar, se verificó la coherencia entre la clave de entidad y su representación textual, comprobando que la clave `99` correspondiera a `SE DESCONOCE` en la columna `ENTIDAD`. Esta validación no presento inconsistencias, por lo que las variables geográficas principales quedaron alineadas entre sí.
En segundo lugar, se validó la conversión de fechas sobre el dataset orientado al análisis temporal, el cual excluye el bloque confidencial. En esta revisión se observó que las fechas de desaparición y registro no presentaban errores adicionales de formato una vez retirados los registros reservados; únicamente la fecha de nacimiento conservó un conjunto muy pequeño de valores no nulos que no pudieron convertirse correctamente.
Finalmente, se incorporaron reglas de consistencia temporal para detectar secuencias temporales poco creibles y poco probables, tales como que la fecha de nacimiento fuera posterior a la de desaparición, o que la fecha de nacimiento fuera posterior al registro y la fecha de registro fuera anterior a la desaparición. Estas banderas no implicaron la eliminación automática de registros, pero sí permitieron identificar registros que podrían requerir revisión adicional por posible error de captura o por inconsistencias cronológicas.
Cabe señalar que el dataset no contiene variables de coordenadas geográficas, por lo que no fue posible aplicar validaciones espaciales de latitud y longitud. En consecuencia las validaciones se concentraron en la coherencia estructural de claves, la conversión de fechas y la consistencia temporal de los registros.

Entregable adicional

Como resultado del proceso de limpieza se generaron dos archivos CSV finales, ya que el tratamiento de las variables temporales hizo necesario separar el conjunto de datos en dos versiones. Esta decisión permitió conservar la mayor cantidad posible de información útil sin forzar un único dataset para propósitos analíticos distintos.
El primero, `data_secretariado_limpio_general.csv`, corresponde al dataset general limpio. En esta versión se conservaron los registros confidenciales que todavía contienen información útil para el análisis, por ejemplo en variables institucionales o geográficas. Su propósito es servir como base para análisis descriptivos generales, distribución por entidad o municipio, origen del reporte, estatus de la víctima y estudio de la presencia de registros reservados.
El segundo, `data_secretariado_limpio_temporal.csv`, corresponde al dataset limpio orientado al análisis temporal. En esta versión se excluyó el bloque confidencial, debido a que sus fechas no pueden interpretarse de manera confiable ni convertirse consistentemente a variables cronológicas. Su propósito es servir como base para análisis relacionados con fechas, secuencias temporales, cronología de registros y revisión de consistencia entre nacimiento, desaparición y registro.
De esta forma, ambos archivos cumplen funciones distintas pero complementarias: el dataset general preserva la mayor cantidad posible de registros útiles, mientras que el dataset temporal ofrece una base más adecuada para trabajar con variables de tiempo.
Ruta del CSV limpio generado: `data_secretariado_limpio_general.csv` y `data_secretariado_limpio_temporal.csv`

VI. Git

- **Repositorio del proyecto:** `https://github.com/SteveQuezworx/Almacenes-y-Mineria-de-Datos` (repositorio público en GitHub).
- **Notebook reproducible:** Libro Quarto compuesto por 7 capítulos `.qmd` en la carpeta `notebooks/`. El capítulo `03_exploracion_limpieza.qmd` ejecuta el pipeline completo de limpieza y genera los CSV limpios; los capítulos `04_medidas_eda.qmd` y `05_correlacion_analisis.qmd` cargan dichos CSV y producen todas las medidas, visualizaciones y análisis de correlación. Al renderizar con `quarto render`, se genera un libro HTML navegable en `_book/index.html` y opcionalmente un PDF.
- **Environment/dependencias:**
  - `environment.yml` — entorno conda con Python 3.11, pandas, numpy, matplotlib, seaborn, scipy y Jupyter.
  - `requirements.txt` — dependencias para instalación con `pip`.
  - Quarto CLI $\geq$ 1.4 (`https://quarto.org/docs/get-started/`).
- **Instrucciones de ejecución:**
  1. Clonar el repositorio: `git clone <URL_del_repo>`.
  2. Colocar `data_secretariado.csv` en `data/raw/`.
  3. Crear el entorno: `conda env create -f environment.yml && conda activate almacenes-mineria` (o bien `pip install -r requirements.txt`).
  4. Renderizar: `quarto render` desde la raíz del proyecto.
  5. Abrir `_book/index.html` en el navegador.

VII. Reporte final: hallazgos y limitaciones

Objetivo y preguntas de análisis

Objetivo general:
Analizar el dataset asignado sobre personas desaparecidas y no localizadas en México para identificar patrones descriptivos, problemas de calidad de datos, comportamientos temporales y diferencias institucionales en los registros, prestando especial atención a la presencia de información confidencial, la consistencia cronológica de las fechas y la utilidad analítica real del conjunto de datos tras su limpieza.
Preguntas de análisis:

- ¿La presencia de valores 'CONFIDENCIAL' aparece de forma aleatoria o sigue un patrón estructurado según entidad u origen institucional?
- ¿Existen anomalías cronológicas relevantes, por ejemplo registros cuya fecha de registro sea anterior a la fecha de desaparición?
- ¿Qué diferencias analíticas aparecen al trabajar con un dataset general frente a uno depurado específicamente para análisis temporal?

- ¿Las desapariciones se concentran en unas pocas entidades o constituyen una problemática ampliamente distribuida en el país?
- ¿Qué relaciones débiles o fuertes pueden detectarse entre variables demográficas, temporales e institucionales?

Descripción del dataset asignado al equipo

El dataset asignado al equipo, `data_secretariado.csv`, tiene registros de personas desaparecidas o no localizadas en México provenientes de distintas instancias estatales y federales. El corte de registros, es decir, la fecha del ultimo registro utilizado en este trabajo corresponde al 1 de agosto de 2025, aunque los registros abarcan casos desde 1961 hasta 2025. La unidad de análisis no es la persona como tal, sino el reporte registrado.
La versión original del dataset contiene 133,887 filas y 11 columnas, con variables de identificación, origen institucional, sexo, fechas relevantes del caso, estatus y ubicación geográfica a nivel de entidad y municipio. A partir del proceso de limpieza se conservaron 133,858 registros válidos, después de eliminar únicamente 29 casos cuyo contenido era prácticamente inutilizable por presentar simultáneamente información confidencial o desconocida en variables clave.

Hallazgos principales (mínimo 8)

1. **Bloque de Datos Confidenciales**

   Los registros con el dato 'CONFIDENCIAL' no estan distribuidos en el dataset al azar, ya que estos aparecen como un bloque completo y consistente, además hay estados en los que los registros confidenciales predominan.
   No es que falten datos aquí y allá, sino que en realidad 49,149 registros aparecen como CONFIDENCIAL exactamente en las mismas 6 columnas sensibles: fecha de nacimiento, sexo, fecha de desaparición, fecha de registro, estatus y municipio.

   Esto nos quiere decir que no son errores ni datos nulos normales, sino un subconjunto censurado por las entidades donde se realizaron esos registros.
   Una de las cosas mas interesantes es que esa censura de datos no es la misma en todo el país. En el dataset con nombre 'limpio general', la proporción nacional de registros donde todos sus campos son confidenciales excepto el de la entidad es de 36.3 %, pero en estados grandes sube muchísimo: Jalisco: 67.5 % Guanajuato: 58.7 % Ciudad de México: 58.4 %

   Esto nos quiere decir algo muy importante, ya que la reserva de información parece depender mucho de cómo reporta cada entidad o institución, no solo del fenómeno en sí.

   Este creemos que es un gran hallazgo, ya que a simple vista uno pensaría simplemente que hay muchos confidenciales, pero en realidad el patrón fuerte es que la confidencialidad es estructurada y territorialmente desigual.

Top 5 entidades con mayor proporción de registros confidenciales:

5 rows · 5 rows × 3 cols · Static Output

ENTIDAD	total_registros	registros_confidenciales	proporcion_confidencial
JALISCO	14811	10000	0.6752
NAYARIT	1969	1300	0.6602
GUANAJUATO	5293	3106	0.5868
CIUDAD DE MÉXICO	6802	3973	0.5841
PUEBLA	3001	1710	0.5698

Ejemplo pequeño de registros confidenciales en las entidades más concentradas:

6 rows · 6 rows × 9 cols · Static Output

	ID_VICTIMA	ORIGEN_REPORTE	ENTIDAD	MUNICIPIO	FECHA_NACIMIENTO	SEXO	FECHA_DESAPARICION	FECHA_REGISTRO
11526	3E3C0A43-0832…	PROCURADURIA GENERAL DE JUSTICIA DEL ES…	GUANAJUATO	CONFIDENCIAL	CONFIDENCIAL	CONFIDENCIAL	CONFIDENCIAL	CONFIDENCIAL
61658	4C0C5519-D2C7…	COMISION LOCAL DE BUSQUEDA DE PERSONAS …	JALISCO	CONFIDENCIAL	CONFIDENCIAL	CONFIDENCIAL	CONFIDENCIAL	CONFIDENCIAL
73657	F36F618B-32EB…	COMISION LOCAL DE BUSQUEDA DE PERSONAS …	JALISCO	CONFIDENCIAL	CONFIDENCIAL	CONFIDENCIAL	CONFIDENCIAL	CONFIDENCIAL
87435	19C4FB30-ED53…	FISCALIA GENERAL DE JALISCO	JALISCO	CONFIDENCIAL	CONFIDENCIAL	CONFIDENCIAL	CONFIDENCIAL	CONFIDENCIAL
89554	C0ABBCA2-5CD0…	FISCALIA GENERAL DE JALISCO	JALISCO	CONFIDENCIAL	CONFIDENCIAL	CONFIDENCIAL	CONFIDENCIAL	CONFIDENCIAL
88619	3CBDE798-C30A…	FISCALIA GENERAL DE JALISCO	JALISCO	CONFIDENCIAL	CONFIDENCIAL	CONFIDENCIAL	CONFIDENCIAL	CONFIDENCIAL

Registos Cofidenciales

2. **Anomalías temporales en las fechas de registro y desaparición**

   De igual forma, si nos fijamos en el dataset temporal, si consideramos únicamente los casos en los que sí fue posible comparar la `FECHA_DESAPARICION` con la `FECHA_REGISTRO`, pudimos identificar 1,121 casos, que son el 1.52%, es decir, estos tienen unas inconsistencia importante: la fecha de registro aparece antes que la fecha de desaparición.

   Lo mas interesante no es solo que estos datos existan asi en el dastaset, sino su fuerte concentración en unicamente algunas fuentes de origen. En especifico, las fuentes Portal, Fiscalía General de Veracruz y Procuraduría/Fiscalía de Michoacán concentran en conjunto el 65.4% de todas las anomalías detectadas, a pesar de que solo representan el 15.2% de los registros válidos para realizar esta comparación.

   Además, al analizar la magnitud del desfase temporal, se observó que aproximadamente el 64% de estos casos presentan diferencias de un día o menos, lo que sugiere posibles problemas de captura o desfases de horarios. Sin embargo, también detectamos 64 registros con desfases mayores a un año, lo cual ya no parece indicar una simple variación técnica y más bien quiere decir que se comentieron errores de integración, captura tardía o inconsistencias administrativas de mayor escala.

   Este hallazgo es interesante porque indica que las anomalías temporales, al igual que los datos 'CONFIDENCIALES', no se distribuyen de forma aleatoria en el dataset. Por el contrario, muestran un patrón localizad, lo que nos quiere decir que el problema podría estar asociado a ciertos procesos específicos de captura o criterios administrativos diferenciados según la fuente de reporte.

Top 10 fuentes donde más se concentran las anomalías de fecha:

10 rows · 10 rows × 4 cols

ORIGEN_REPORTE	casos	porcentaje_del_total	desfase_promedio_dias	desfase_max_dias
PORTAL	371	33.10	486.46	20804.00
FISCALIA GENERAL DE VERACRUZ	202	18.02	289.39	16316.50
PROCURADURIA GENERAL DE JUSTICIA DEL ESTADO DE MICHOACAN	160	14.27	64.56	7304.85
FISCALIA GENERAL DE MORELOS	48	4.28	62.71	1881.00
COMISION NACIONAL DE BUSQUEDA DE PERSONAS	33	2.94	284.13	5841.83
FISCALIA GENERAL DE GUERRERO	31	2.77	16.79	363.96
FISCALIA GENERAL DE DURANGO	23	2.05	147.23	3375.00
COMISION LOCAL DE BUSQUEDA DE PERSONAS DEL ESTADO DE MICH…	19	1.69	81.05	1095.00
COMISION LOCAL DE BUSQUEDA DE PERSONAS DEL ESTADO DE VERA…	19	1.69	1.06	10.00
FISCALIA GENERAL DE SINALOA	18	1.61	147.46	2556.00

Ejemplo pequeño de registros con registro antes que desaparición:

9 rows · 9 rows × 7 cols

	ID_VICTIMA	ORIGEN_REPORTE	ENTIDAD	MUNICIPIO	FECHA_DESAPARICION	FECHA_REGISTRO	dias_desfase
77946	EDB3DD00-01DC-4BB1-BE9F-6F1A3010A316	FISCALIA GENERAL DE VERACRUZ	VERACRUZ	VERACRUZ	2018-02-19 00:00:00	1973-06-18 12:00:00	16316.500000
77918	AFAD669C-5762-4B2D-8E7A-0228CBB4E05D	FISCALIA GENERAL DE VERACRUZ	VERACRUZ	VERACRUZ	2018-08-18 00:00:00	1986-10-23 00:00:00	11622.000000
77935	9DB46B0F-8689-4446-AC32-BE85FB3A7992	FISCALIA GENERAL DE VERACRUZ	VERACRUZ	VERACRUZ	2018-05-24 00:00:00	1986-11-04 00:00:00	11524.000000
77936	CC35C1CF-8121-49AF-B29A-9571D4BD04B6	FISCALIA GENERAL DE VERACRUZ	VERACRUZ	VERACRUZ	2018-05-23 00:00:00	1994-01-02 00:00:00	8907.000000
77939	1AF2BD04-2183-4146-8A31-8AD057EFAED9	FISCALIA GENERAL DE VERACRUZ	VERACRUZ	VERACRUZ	2011-06-12 00:00:00	1994-09-21 00:00:00	6108.000000
78194	63322CDC-B147-4653-9B39-3A00A0757DE7	FISCALIA GENERAL DE VERACRUZ	VERACRUZ	COYUTLA	2018-08-13 13:00:00	2012-08-13 21:00:00	2190.666667
78118	D83A6F31-2DED-4AF2-A799-9B3BECD808B7	FISCALIA GENERAL DE VERACRUZ	VERACRUZ	COSAMALOAPAN DE CARPIO	2016-10-13 13:00:00	2013-10-13 13:00:00	1096.000000
78261	A98D113A-45C2-4F28-93CA-E50AFCC067DD	FISCALIA GENERAL DE VERACRUZ	VERACRUZ	ISLA	2018-10-07 11:00:00	2018-06-07 09:30:00	122.062500
78678	8E84A282-19DB-49E9-810A-681ED0021CA0	FISCALIA GENERAL DE VERACRUZ	VERACRUZ	VERACRUZ	2015-05-21 10:30:00	2015-01-20 00:00:00	121.437500

Desfase Fechas

3. **Predominio masculino en los registros**

   Del total de registros que cuentan con información sobre sexo en el dataset limpio general, el 60.6% corresponde a personas del sexo masculino y el 39.4% al sexo femenino. En el dataset temporal (sin registros confidenciales), esta proporción se mantiene prácticamente igual: 60.2% hombres y 39.8% mujeres.

   Este predominio no implica necesariamente que desaparezcan más hombres que mujeres, sino que los registros con sexo conocido reflejan esa distribución. Es relevante porque permite orientar políticas de búsqueda y atención de forma diferenciada.

4. **Concentración geográfica en pocas entidades**

   Solo tres entidades concentran una proporción desproporcionada de los registros: Jalisco, Estado de México y Tamaulipas encabezan la lista tanto en el dataset general como en el temporal. En contraste, estados como Baja California Sur, Campeche y Yucatán registran cifras muy bajas.

   Esta concentración territorial no es solo un dato descriptivo: también sugiere que la capacidad de registro y la magnitud del fenómeno se superponen, y que la lectura de las cifras brutas debe considerar diferencias operativas entre entidades.

5. **Perfil demográfico: grupo de 20 a 40 años**

   La edad promedio calculada en el dataset temporal es de aproximadamente 33 años, con una mediana de 30. La distribución muestra una concentración clara en el rango de 20 a 40 años. El histograma de edades

revela una curva asimétrica positiva, con una cola derecha que se extiende hasta edades avanzadas pero con muy baja frecuencia.

El desfase entre media y mediana (la media es mayor que la mediana) confirma la asimetría: hay algunos registros de personas mayores que elevan el promedio, pero la mayor parte de los casos corresponde a adultos jóvenes.

6. **Distribución generalizada: índice de Gini cercano a 1**

   Al calcular el índice de Gini para la distribución de registros por entidad, se obtuvo un valor de aproximadamente 0.53, y la entropía de Shannon arroja un valor de 3.73 sobre un máximo de 4.09, lo que da un índice de equitabilidad de Pielou de 0.91.

   Esto indica que, aunque existe concentración en algunos estados (hallazgo 4), la distribución entre entidades no es completamente desigual: muchos estados sí aportan registros significativos. La heterogeneidad es alta, es decir, el fenómeno no está limitado a unas pocas entidades, sino que es de alcance nacional con variaciones regionales.

7. **Concentración extrema en el índice R**

   El coeficiente de concentración R calculado para la distribución de registros por entidad alcanza un valor de 0.9955, muy cercano al máximo teórico de 1. La curva de Lorenz correspondiente muestra que una pequeña fracción de las entidades acumula la gran mayoría de los registros.

   Esto complementa el hallazgo anterior: si bien todas las entidades registran casos (alta entropía), la magnitud varía enormemente. La curva de Lorenz ilustra que aproximadamente el 20% de las entidades concentra más del 60% de los registros, confirmando el patrón de concentración.

8. **Correlación débil entre variables demográficas**

   La matriz de correlación de Pearson calculada sobre las variables numéricas del dataset temporal (edad, sexo codificado, días de desfase entre fechas) muestra correlaciones muy bajas en todos los pares. La correlación más fuerte encontrada es entre la edad aproximada y los indicadores binarios de sexo, pero no supera $|r| = 0.10$.

   Esto indica que las variables demográficas disponibles no presentan dependencias lineales fuertes entre sí, lo cual tiene implicaciones directas para la modelación: un modelo predictivo basado únicamente en estas variables tendría capacidad explicativa limitada. La principal utilidad del dataset reside en su valor descriptivo y geoespacial más que en relaciones inter-variables.

Limitaciones del análisis

Este análisis presenta varias limitaciones que deben considerarse al interpretar los resultados. La primera es que el dataset no representa personas únicas, sino reportes, por lo que no puede asumirse automáticamente que cada fila corresponde a un caso irrepetible en sentido estricto. Esto limita inferencias directas sobre el número real de personas afectadas sin una revisión adicional de datos duplicados entre instituciones.

La segunda limitación importante es la presencia de un bloque amplio y estructurado de registros 'CONFIDENCIAL', el cual restringe el acceso a variables sensibles como sexo, fechas y municipio. Esto reduce la profundidad del análisis temporal y demográfico y, además, introduce un sesgo institucional y territorial.
También existen problemas de calidad de datos en las variables temporales. Aunque se realizó una depuración cuidadosa, persistieron registros con secuencias cronológicas poco probables, como casos donde la fecha de registro aparece antes que la fecha de desaparición. Estas anomalías no invalidan todo el conjunto, pero sí obligan a interpretar con cautela las medidas basadas en tiempo y retraso de registro.
Finalmente, la ausencia de variables contextuales más profundas es otra limitacion. El dataset no incluye información socioeconómica, circunstancias del hecho, causas, vínculos con violencia delictiva, condición laboral, nivel educativo ni coordenadas geográficas exactas. Por ello, el análisis permite describir patrones estadísticos, pero no explicar causalmente el fenómeno ni atribuirlo de forma concluyente a factores sociales específicos.

Conclusión

El análisis sobre el dataset nos permitió identificar dos cosas al mismo tiempo: por un lado, patrones bastante interesantes sobre el fenómeno reportado y, por otro lado, algunos patrones internos del propio sistema de registro. Esto es importante porque el trabajo no solo mostró distribuciones por sexo, edad, entidad o retraso de registro, sino también desigualdades claras en la forma en que las instituciones reportan, reservan y estructuran la información.
Uno de los principales resultados es que la confidencialidad no aparece como una simple ausencia aleatoria de datos, sino como un mecanismo estructurado y territorialmente desigual. De forma similar, las anomalías temporales tampoco se distribuyen al azar, sino que muestran concentración en ciertas fuentes de origen.
Aun con estas limitaciones, el dataset conserva un valor analítico considerable. La construcción de dos versiones limpias permitió aprovechar tanto la riqueza descriptiva del conjunto general como la mayor consistencia cronológica del conjunto temporal. Esto hizo posible desarrollar análisis más sólidos sobre medidas descriptivas, heterogeneidad, concentración, correlaciones y validaciones de limpieza.
En términos generales, los resultados apuntan a que las desapariciones constituyen un problema amplio y distribuido en el país, aunque con mayor intensidad o visibilidad en ciertos estados y bajo ciertas formas de registro. Por ello, una conclusión de este trabajo es que estudiar este tipo de bases no solo requiere técnicas de minería de datos, sino también una lectura crítica de la calidad. En este caso, limpiar el dataset no fue únicamente una etapa técnica, sino una condición necesaria para poder interpretar de manera responsable cualquier hallazgo.

Fuentes sugeridas para CRISP-DM

- ODIM - Jurídicas UNAM: `https://odim.juridicas.unam.mx/`
- A dónde van los desaparecidos: `https://adondevanlosdesaparecidos.org/`
- Contexto General RNPDNO: `https://versionpublicarnpdno.segob.gob.mx/Dashboard/ContextoGeneral`
- Documentos ONU: `https://docs.un.org/en/A/HRC/30/38/Add.4`

References

[1] Codeando México A.C. (01 de octubre de 2025). *Personas desaparecidas y no localizadas en México*. Obtenido de datamx: https://datamx.io/el/dataset/personas-desaparecidas-y-no-localizadas-en-mexico

[2] Comisión Nacional de Búsqueda de Personas. (s.f.). *CONSULTA PÚBLICA DEL REGISTRO NACIONAL DE PERSONAS DESAPARECIDAS Y NO LOCALIZADAS*. Obtenido de Gobierno de México: https://consultapublicarnpdno.segob.gob.mx/consulta

[3] Microsoft Learn. (s.f.). *Conceptos de minería de datos*. Obtenido de Analysis Services: https://learn.microsoft.com/es-es/analysis-services/data-mining/data-mining-concepts

[4] Microsoft Learn. (s.f.). *Proyectos de minería de datos*. Obtenido de Analysis Services: https://learn.microsoft.com/es-es/analysis-services/data-mining/data-mining-projects

[5] Axial SQL. (s.f.). *Usando SQL Server Analysis Services para minería de datos*. Obtenido de Axial SQL: https://axial-sql.com/es/usando-sql-server-analysis-services-para-mineria-de-datos/

[6] Uber Engineering. (2017, 5 de septiembre). *Meet Michelangelo: Uber's Machine Learning Platform*. Obtenido de Uber Blog: https://www.uber.com/blog/michelangelo-machine-learning-platform/

[7] Bio Engine. (2024). *Producción de energía renovable – Bioengine México*. Obtenido de: https://bioengine.mx/

[8] Amazon Web Services. (16 de diciembre de 2020). *Architect and build the full machine learning lifecycle with AWS: An end-to-end Amazon SageMaker demo*. Obtenido de AWS Machine Learning Blog: https://aws.amazon.com/blogs/machine-learning/architect-and-build-the-full-machine-learning-lifecycle-with-amazon-sagemaker/