Universidad Nacional Autonoma de Mexico

Facultad de Ciencias
Almacenes y Minería de Datos

Tarea 03

Reglas de asociación y clasificación

Alumnos:

Omar Fernando Gramer Muñoz
Kevin Steve Quezada Ordoñez
Jesús Antonio Romero Godoy
Edgar Salgado González

Mayo de 2026

1. Propósito y alcance

El objetivo de la tarea fue aplicar minería de datos sobre registros de personas desaparecidas o no localizadas en México, usando dos enfoques principales:

- reglas de asociación, con una implementación propia de Apriori y una comparación contra `mlxtend`;
- clasificación supervisada, usando Random Forest para analizar qué variables se asocian con el estatus de la víctima.

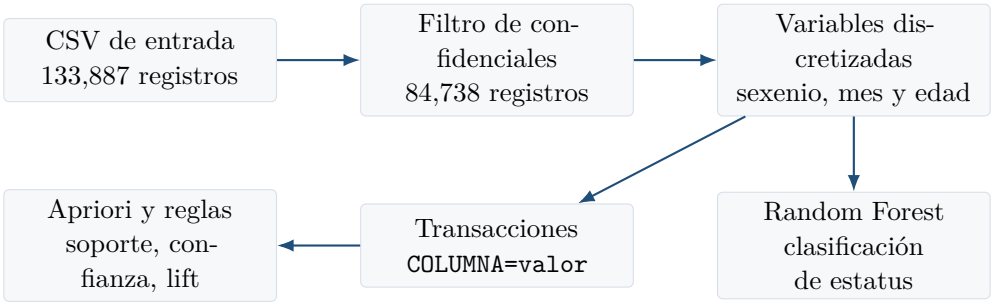

Figura 1: Flujo general seguido en el notebook principal.

2. Dataset y preparación inicial

El notebook principal carga el archivo `dataset/data_secretariado.csv`. El dataset contiene registros individuales de víctimas, con información sobre sexo, fechas, estatus, entidad, municipio y origen del reporte.

Elemento	**Descripción**
Registros iniciales	133,887 registros y 11 columnas.
Columnas principales	`ID_VICTIMA`, `ORIGEN_REPORTE`, fechas de nacimiento, desaparición y registro, `SEXO`, `ESTATUS_VICTIMA`, `ENTIDAD` y `MUNICIPIO`.
Filtrado para minería	Se eliminan filas con `CONFIDENCIAL` en `SEXO`, `ESTATUS_VICTIMA` o `MUNICIPIO`.
Dataset analítico	84,738 registros después del filtrado.

Variables generadas

Las fechas completas no se usan directamente en Apriori porque tendrían demasiados valores únicos. Por eso se convierten a variables discretas más interpretables:

- `SEXENIO_DESAPARICION`: sexenio al que pertenece la fecha de desaparición.
- `SEXENIO_REGISTRO`: sexenio al que pertenece la fecha de registro.
- `MES_DESAPARICION`: mes de desaparición, conservado para detectar posible estacionalidad.
- `GRUPO_EDAD`: edad aproximada al momento de la desaparición, agrupada en rangos.

Además, se excluyen variables que producirían patrones poco útiles: `ID_VICTIMA` por ser identificador único, `ORIGEN_REPORTE` por estar muy ligado a la entidad, fechas crudas por su alta cardinalidad y `ESTATUS_VICTIMA` en Apriori por ser casi universal después del filtrado.

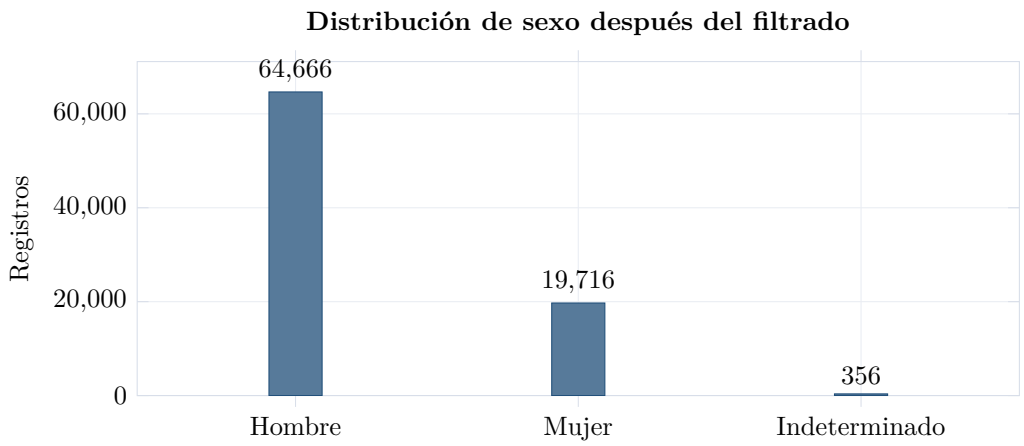

Figura 2: El conjunto filtrado conserva principalmente registros de hombres, seguido por mujeres e indeterminado.

3. Implementación propia de Apriori

Idea del algoritmo

Apriori busca conjuntos de ítems que aparecen juntos con frecuencia suficiente. En esta tarea, cada registro se transforma en una transacción formada por ítems del tipo `COLUMNA=valor`. Por ejemplo, una fila puede convertirse en:

$$\{\texttt{SEXO=HOMBRE}, \texttt{ENTIDAD=TAMAULIPAS}, \texttt{GRUPO_EDAD=18-29}, \texttt{MES_DESAPARICION=09}\}$$

La medida central es el soporte:

$$\text{soporte}(X) = \frac{\text{transacciones que contienen } X}{\text{total de transacciones}}$$

Con `min_support=0.02`, un itemset debe aparecer en al menos 1,695 transacciones para considerarse frecuente.

Estructura de la implementación

La implementación sigue la lógica clásica del algoritmo:

1. contar los ítems individuales y formar los frecuentes de tamaño 1
2. generar candidatos de tamaño mayor combinando itemsets frecuentes previos
3. aplicar la propiedad Apriori: si un subconjunto no es frecuente, el candidato completo tampoco puede serlo
4. calcular soporte solo para los candidatos que sobreviven a la poda
5. repetir el proceso hasta llegar al tamaño máximo configurado o hasta que no existan nuevos frecuentes.

Las funciones clave del notebook son `calcular_soporte_absoluto`, `obtener_itemsets_frecuentes_1`, `generar_candidatos`, `tiene_subconjuntos_frecuentes`, `filtrar_candidatos_por_soporte` y `apriori`.

Resultados de Apriori

Con `MIN_SUPPORT=0.02` y `MAX_K=3`, el algoritmo encontró 286 itemsets frecuentes. El límite de tamaño 3 mantiene las combinaciones interpretables y evita el crecimiento excesivo de candidatos.

Nivel	Candidatos	Frecuentes	Interpretación
Tamaño 1	–	51	Valores individuales que aparecen al menos en 2 % del dataset.
Tamaño 2	1,275	149	Pares de valores frecuentes, muchos candidatos son descartados por soporte.
Tamaño 3	180	86	Combinaciones más específicas, todavía con frecuencia suficiente.

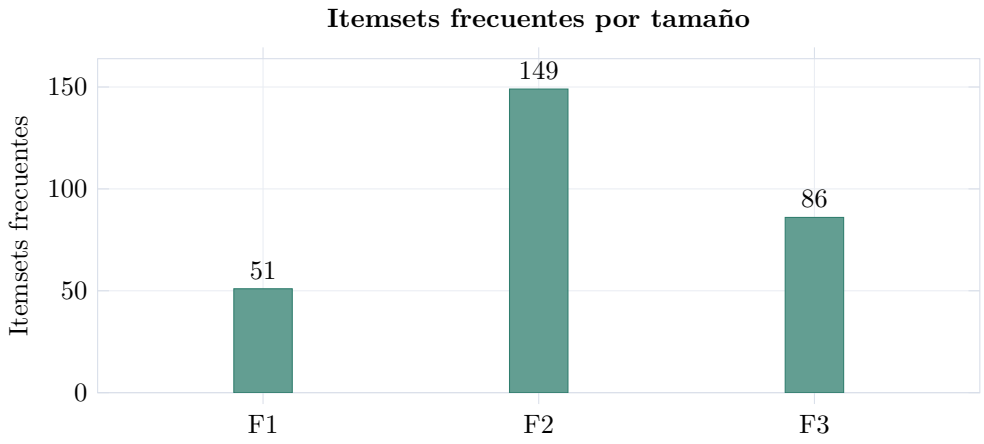

Figura 3: Distribución de itemsets frecuentes encontrados por la implementación propia.

4. Comparación con `mlxtend` y FP-Growth

Para comparar la implementación propia con librerías optimizadas, las transacciones se convierten a un DataFrame one-hot encoded con `TransactionEncoder`. El resultado tiene 84,738 filas y 1,619 columnas, donde cada columna representa un ítem posible y cada celda indica si ese ítem aparece o no en la transacción.

Algoritmo	Tiempo	Itemsets frecuentes
Apriori propio	11.29 s	286
Apriori de `mlxtend`	0.44 s	286
FP-Growth de `mlxtend`	3.01 s	286

Los tres métodos encuentran los mismos 286 itemsets frecuentes. La diferencia principal está en el costo computacional. La versión propia recorre transacciones y candidatos en Python puro,

`mlxtend` usa operaciones vectorizadas, por eso su Apriori es mucho más rápido en este caso. FP-Growth también es eficiente, pero para este dataset el costo de construir el árbol de patrones frecuentes fue mayor que el beneficio obtenido.

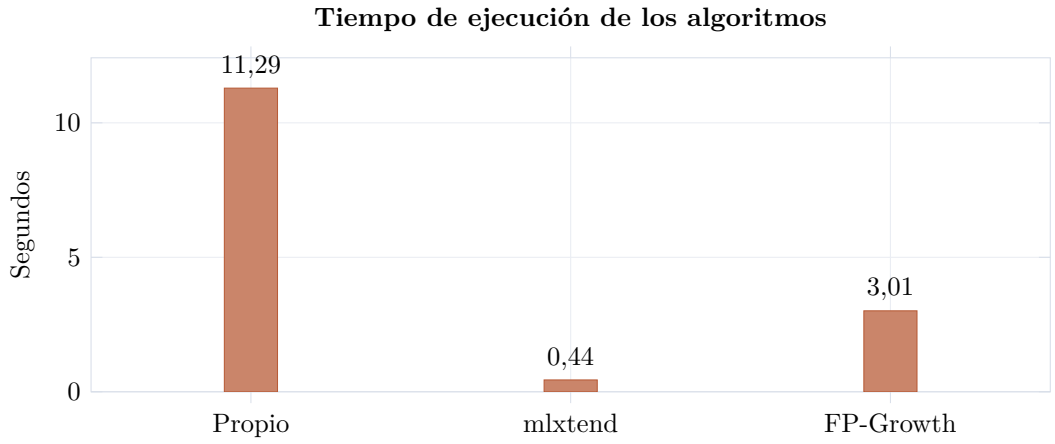

Figura 4: Comparación de tiempos con los mismos parámetros de soporte y tamaño máximo.

5. Reglas de asociación

Métricas usadas

Después de obtener los itemsets frecuentes se generan reglas de la forma $X \Rightarrow Y$. El notebook usa una confianza mínima de 0.70 y analiza tres métricas:

- **Soporte:** proporción de registros donde aparecen juntos antecedente y consecuente.
- **Confianza:** probabilidad de observar el consecuente cuando aparece el antecedente.
- **Lift:** fuerza de asociación ajustada por la frecuencia natural del consecuente.

Un lift mayor que 1 indica asociación positiva. Para evitar reglas casi independientes, el análisis posterior usa lift $\geq 1{,}2$. También se descartan reglas geográficas triviales, por ejemplo `MUNICIPIO=TIJUANA` $\Rightarrow$ `ENTIDAD=BAJA CALIFORNIA`, porque son verdaderas por definición y no aportan conocimiento nuevo.

Resultados generales

Con `association_rules` de `mlxtend` se obtuvieron 196 reglas con confianza mínima de 0.70. Al exigir lift de al menos 1.2 quedan 120 reglas. Después de quitar reglas geográficas triviales y valores desconocidos, el análisis se concentra en 113 reglas interpretables.

Patrón 1: sexenio de desaparición y sexenio de registro

El patrón más fuerte es que las desapariciones tienden a registrarse en el mismo sexenio en que ocurren. Esto aparece de forma consistente con confianzas muy altas.

Sexenio	Confianza aprox.	Lift aprox.
Calderón (2006–2012)	0.98	7.7
Sheinbaum (2024–2030)	0.99	5.6
Peña Nieto (2012–2018)	0.96	3.6
AMLO (2018–2024)	0.94	2.8

La interpretación no debe ser que el sexenio cause la desaparición o el registro. Más bien, las reglas muestran una fuerte alineación temporal entre ocurrencia y registro. En casos recientes, como Sheinbaum, esto también es esperable porque aún no ha pasado suficiente tiempo para observar rezagos largos.

Patrón 2: entidad y sexenio

Algunas entidades aparecen asociadas con periodos específicos:

- **Tamaulipas y Calderón:** es la asociación más fuerte del patrón, con lift cercano a 7.7.
- **Estado de México y Sheinbaum / Peña Nieto:** aparece asociado a ambos periodos, con lift cercano a 5.7 y 3.75 respectivamente.
- **Jalisco y Peña Nieto:** muestra una concentración relevante en ese sexenio, con lift cercano a 3.75.
- **Michoacán, Sonora y Tabasco con AMLO:** presentan asociaciones positivas con el periodo 2018–2024.

Estas reglas pueden reflejar cambios reales en el fenómeno, pero también sesgos de registro: cada entidad puede registrar, actualizar o reportar casos con distinta capacidad institucional.

Patrón 3: sexo

Las reglas con `SEXO` no muestran asociaciones directas fuertes con `ENTIDAD` ni con `GRUPO_EDAD`. Lo que sí aparece son variantes del patrón temporal, por ejemplo:

$$\texttt{SEXO=HOMBRE},\ \texttt{SEXENIO_DESAPARICION=X} \Rightarrow \texttt{SEXENIO_REGISTRO=X}$$

Esto sugiere que el comportamiento de registro por sexenio es parecido para hombres y mujeres. La ausencia de reglas directas no significa que no existan diferencias por sexo, significa que, con soporte mínimo de 2 %, no aparecieron patrones nacionales suficientemente frecuentes.

Patrón 4: grupo de edad

Los grupos de edad que aparecen con suficiente frecuencia en reglas fuertes son 18–29, 30–44 y 45–59. Los grupos 0–11 y 12–17 no generan reglas relevantes con el umbral usado.
El patrón vuelve a ser temporal: dentro de cada sexenio, la probabilidad de que el registro ocurra en el mismo periodo no cambia demasiado entre grupos de edad. Esto indica que el grupo etario no parece ser el factor principal detrás del rezago entre desaparición y registro.

6. Modelo de clasificación

Planteamiento

La segunda parte del notebook busca predecir `ESTATUS_VICTIMA`. Después del filtrado, la variable objetivo queda fuertemente desbalanceada:

- `DESAPARECIDA`: 79,881 registros, equivalente a 94.27 %.
- `NO LOCALIZADA`: 4,857 registros, equivalente a 5.73 %.

Por este desbalance, el accuracy por sí solo no es una métrica suficiente. Un modelo que siempre predijera `DESAPARECIDA` tendría un accuracy alto sin aprender la clase minoritaria. Por eso tambien tomamos en cuenta precision, recall y F1-score, especialmente para `NO LOCALIZADA`.

Modelo 1: entidad y municipio

El primer modelo usa Random Forest con `class_weight="balanced"`. Las variables predictoras son `SEXO`, `ENTIDAD`, `MUNICIPIO`, `SEXENIO_DESAPARICION`, `SEXENIO_REGISTRO`, `MES_DESAPARICION` y `GRUPO_EDAD`. Todas se codifican con `LabelEncoder`, y la división train/test conserva la proporción de clases mediante estratificación.

Clase	Precision	Recall	F1-score	Support
`DESAPARECIDA`	0.97	0.95	0.96	15,977
`NO LOCALIZADA`	0.39	0.48	0.43	971
Accuracy	–	–	0.93	16,948
Macro avg	0.68	0.72	0.70	16,948
Weighted avg	0.94	0.93	0.93	16,948

El modelo predice bien la clase mayoritaria, pero identifica solo cerca de la mitad de los casos `NO LOCALIZADA`. Esto limita su utilidad como herramienta de predicción individual.

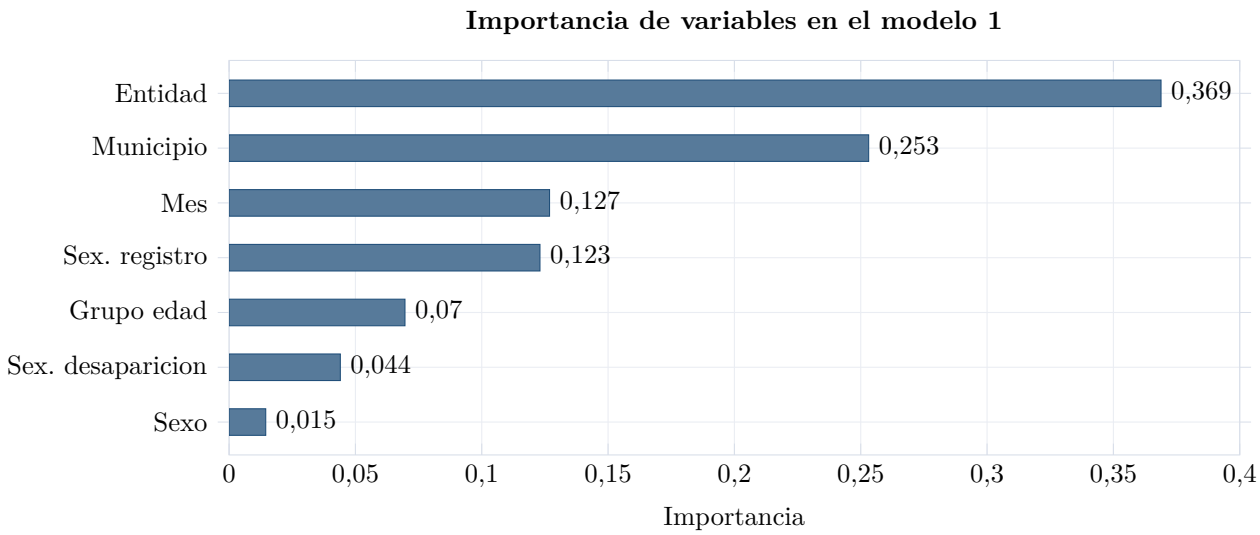

Figura 5: La geografía domina la importancia del Random Forest cuando se incluyen entidad y municipio.

Interpretación de importancias

`ENTIDAD` y `MUNICIPIO` concentran aproximadamente 62 % de la importancia del modelo. Esto debe interpretarse con cuidado, ya que no implica que la ubicación cause el estatus de la víctima, tiene mas sentido pensar que el modelo aprende diferencias administrativas entre entidades: algunas actualizan y reportan estatus con más regularidad que otras.
`MES_DESAPARICION` y `SEXENIO_REGISTRO` tienen pesos similares, alrededor de 12 % cada una. Esto refuerza la idea de que el proceso temporal e institucional del registro influye en la etiqueta observada. `SEXO` tiene una importancia muy baja, consistente con la ausencia de reglas fuertes por sexo en Apriori.

Modelo 2: solo entidad como variable geográfica

En el segundo modelo eliminamos `MUNICIPIO` para reducir redundancia geográfica. Al hacerlo, el accuracy baja, pero mejora el recall de la clase minoritaria:

Métrica	**Modelo 1**	**Modelo 2**
Accuracy	0.93	0.86
F1 `DESAPARECIDA`	0.96	0.92
F1 `NO LOCALIZADA`	0.43	0.39
Recall `NO LOCALIZADA`	0.48	0.74

El modelo 2 detecta más casos de `NO LOCALIZADA`, aunque comete más falsos positivos. Si el interés fuera no dejar pasar casos de la clase minoritaria, este comportamiento puede ser preferible. Aun así, ninguno de los dos modelos es suficientemente confiable para decisiones individuales.

7. Hallazgos principales

1. Apriori encontró 286 itemsets frecuentes con soporte mínimo de 2 %, lo que confirma que existen patrones repetidos en el dataset después del filtrado.
2. La implementación propia produce los mismos itemsets que `mlxtend`, pero es más lenta por estar escrita en Python puro y calcular soportes recorriendo transacciones.
3. El patrón más fuerte en reglas de asociación es la correspondencia entre sexenio de desaparición y sexenio de registro.
4. Las reglas entidad–sexenio muestran asociaciones interesantes, especialmente Tamaulipas con Calderón, Jalisco con Peña Nieto y varias entidades con AMLO.
5. No se observaron asociaciones directas fuertes entre sexo y entidad o grupo de edad bajo el soporte mínimo usado.
6. En clasificación, el desbalance de clases domina el problema: la clase `DESAPARECIDA` se predice bien, pero `NO LOCALIZADA` sigue siendo difícil.
7. La importancia del Random Forest se concentra en variables geográficas, lo que probablemente captura diferencias institucionales de registro.
8. El segundo modelo mejora el recall de `NO LOCALIZADA`, pero sacrifica accuracy y no resuelve completamente el problema de desbalance.

8. Limitaciones

El análisis tiene varias limitaciones importantes:

- Los registros confidenciales reducen la información disponible y obligan a descartar una parte considerable del dataset para Apriori y clasificación.
- Las reglas de asociación muestran coocurrencia, no causalidad. Un lift alto no prueba que una variable cause otra.
- El soporte mínimo de 2 % favorece patrones nacionales frecuentes, pero puede ocultar patrones locales relevantes.
- Algunas asociaciones pueden reflejar prácticas de captura, actualización o reporte, no necesariamente cambios reales en el fenómeno de desaparición.
- Random Forest con `LabelEncoder` es práctico, pero la codificación ordinal de categorías no representa relaciones semánticas entre municipios o entidades.
- La clase `NO LOCALIZADA` tiene pocos ejemplos en comparación con `DESAPARECIDA`, lo que limita el aprendizaje supervisado.

9. Conclusión

La tarea muestra dos usos complementarios de minería de datos. Apriori ayuda a describir patrones frecuentes y reglas interpretables, Random Forest permite explorar qué variables se asocian con el estatus de la víctima. En ambos casos, el hallazgo más importante es que las variables temporales y geográficas pesan mucho, pero deben leerse como señales del sistema de registro y no como explicaciones causales del fenómeno.

El valor del análisis está en identificar patrones agregados: correspondencia entre desaparición y registro por sexenio, concentraciones entidad–periodo, y diferencias administrativas reflejadas en el modelo. Para usar estos resultados en un contexto real haría falta profundizar en calidad de datos, rezagos de registro, tratamiento del desbalance y validación con conocimiento institucional.

10. Repositorio

- **Repositorio del proyecto:** https://github.com/steve-quezada/Tareas_Almacenes-y-Mineria-de-Datos.git